

画检查更新

引用方式: DOI: 10.1039/d4ta00725e

利用计算数据与实验数据[†]对可实验合成晶体结构进行
逆向设计程龙秦: ^{‡a}刘金德, ^{‡a}马世银, 杜继光: ^b江刚^a与赵亮 ^{*a}

晶体结构预测 (CSP) 推动了创新材料的发现与设计。然而, 现有的CSP方法主要依赖密度泛函理论 (DFT) 计算得出的形成焓, 却忽视了DFT结果与实验值之间的 differences 关系, 导致预测结构在实验合成方面存在局限性。为克服这些缺陷, 我们提出了一种新型协同预测方法: 结合先进的深度学习模型、优化算法及实验数据。通过从实验数据中进行迁移学习, 该方法获得的形成焓与实际实验观测结果高度吻合。借助可实验合成的晶体信息, 本方法能够逆向设计出可成功合成的晶体结构。对17种代表性化合物的应用表明, 该方法能以高精度准确识别实验合成结构; 所得形成焓与晶格常数均与实验值高度一致, 充分验证了该方法的 effectiveness 性。这种协同方法弥合了理论预测与实验结果之间长期存在的差距, 为实验合成新材料提供了指导, 并降低了对大量昂贵实验测试的需求。

收到日期: 2024年1月31日
接受日期: 2024年3月26日 DOI:
10.1039/d4ta00725e rsc.li/
materials-a

1. 引言

材料基因组计划 (MGI) 于2011年提出的目标极具雄心: “以至少比当前可行速度快两倍的速度, 以极低的成本发现、开发、制造并应用先进材料”。¹传统上, 新材料的发现依赖于偶然性或试错法, 这两种方法都既费时又劳动密集。然而过去十年间, 基于计算手段的晶体结构预测 (CSP) 方法的出现彻底改变了材料的系统性发现方式。²⁻⁵将第一性原理计算与进化算法、元动力学或粒子群优化等优化算法相结合, 推动了CSP在多个领域取得重大突破。⁶⁻¹⁰目前, 随着药物设计、高压化学、计算材料发现、超硬材料以及行星与地球内部矿物学等多个领域

的重大进展, CSP正引发广泛关注。^{2,5,11,12}例如, CSP在识别高压下硫化氢中的高温超导组分以及解析致密氢的结构方面发挥了关键作用。¹³

然而, 基于密度泛函理论 (DFT) 计算的晶体结构预测方法所耗费的巨大时间与资源, 限制了其在广泛原子体系中的适用性——尤其考虑到构象空间的复杂性以及对大型体系进行局部优化所需的高昂成本。

由于机器学习 (ML) 领域近年来取得的重大进展, 尤其是图神经网络 (GNN) 的出现, 晶体结构预测 (CSP) 领域经历了彻底变革。¹⁴⁻¹⁷这些创新方法带来了众多方法论上的突破和成功应用。机器学习已无缝融入CSP研究方法中, 通过替代昂贵的密度泛函理论 (DFT) 计算显著提升了搜索效率。^{10,18,19}具体而言, 研究人员利用图神经网络在给定数据库中建立了晶体结构与生成焓 (ΔH_f) 之间的关联模型;¹⁸随后采用优化算法加速寻找生成焓最低的晶体结构。此外, CSP领域充分挖掘了机器学习的潜力, 提出了新方法以应对相关挑战。^{10,20}最新研究表明, 全

^a四川大学原子与分子物理研究所, 成都 610065
中国。电子邮箱: zhaol@scu.edu.cn

^b四川大学物理学院, 成都 610064, 中国
可获取电子补充信息 (ESI), 详见DOI:
<https://doi.org/10.1039/d4ta00725e>

[†] 这些作者对本研究贡献均等。

局最优搜索技术结合精准的机器学习势函数能够有效解析复杂的晶体结构。²¹该方法为识别以往难以确定的致密锂晶体相提供了切实可行的解决方案。

CSP的稳定性指标通常由复杂的能量函数（即势能面）定义，该函数常通过密度泛函理论（DFT）计算得出。然而，DFT方法中固有的交换-关联泛函包含多种近似处理方式，可能导致显著误差。此外，DFT计算通常在绝对零度和零压条件下进行，而实验则需在有限温度和压力条件下开展。多项研究已揭示DFT预测的生成焓与实验观测值之间存在明显差异，偏差范围达每个原子0.08至0.18电子伏特²²⁻²⁵。DFT计算值与实验结果之间的差距严重阻碍了基态结构的精准预测，因为当前CSP方法高度依赖DFT计算得到的生成焓数据。在实验数据相对匮乏的材料科学领域，机器学习模型主要基于DFT计算数据集进行训练，因此这些模型不可避免地继承了DFT计算与实验数据之间的差异，并因预测不准确性而进一步加剧这种偏差。

虽然全球能量最低点通常对应稳定晶体结构的实验实现，但自然界更倾向于选择特定的局部最低点（亚稳态）结构。尽管许多材料预期具有有利的形成焓，但其合成过程往往受到动力学和实验条件等多重因素复杂相互作用的阻碍。²⁶一个显著例子是高度复杂且高能的希托夫磷的合成，而其他低能结构则似乎难以制备。^{2,27}因此，大部分设计材料在合成阶段都会面临失败。相反，许多具有实用价值的功能材料却以亚稳态形式合成——即使其形成焓与凸包最小值并不吻合。²⁸由此可见，将晶体结构的可合成性信息整合到CSP系统中至关重要，这将成为降低测试成本、加速实际材料发现的关键步骤。

2017年5月，美国国家科学基金会资助了 MGI 举办的题为“通过计算、实验与理论的协同作用推动材料创新：开拓新领域”的研讨会。^{29,30}尽管目标设定较高，但由于数据驱动研究方法的出现，这一目标直到近期才变得切实可行。^{15,17}现有的大多数化学合成预测（CSP）方法都忽视了理论预测与实验观测之间的差异。此外，这些方法主要仅基于热力学生成焓来评估合成可行性，而忽略了影响合成过程的其他关键因素。针对这些局限性，我们提出了一种高效的CSP方法，该方法将优化算法与先

进的深度学习模型相结合，并充分利用全面的密度泛函理论（DFT）材料数据库及实验数据。我们通过利用现有DFT数据与可用实验数据相结合的深度迁移学习（TL）模型，证明了预测材料性质更接近真实实验观测结果的可行性。我们突破现有晶体结构预测（CSP）方法的局限，开发出一种新型模型：该模型结合形成焓和可合成性信息，能更精准地预测实验合成中更可能形成的晶体结构，从而实现材料的逆向设计。该模型已通过全面验证，成功预测了17种已成功实验合成化合物的晶体结构。研究表明，整合实验数据与可合成性信息可显著提升CSP模型的预测精度，大幅缩小与实验结果的偏差。这项研究有效弥合了实验研究与理论预测之间的长期差距，为材料逆向设计开辟了全新途径。

2. 方法

2.1 数据集

化合物生成焓数据集源自开放量子材料数据库（OQMD v1.5）²³。为确保模型的稳健性，我们系统性地剔除了那些生成焓显著高于大多数数据值的异常数据点，从而使数据集范围限定在每原子 -5 至 5 eV 之间。最终获得共计1,020,343个独特的晶体结构，其中37,525个对应实验观测到的构型（即收录于无机晶体结构数据库 ICSD 中）³¹。实验生成焓数据共包含3,096条记录，在剔除重复项后缩减至2,562条；在这2,562条实验记录中，有1,988条对应的晶体结构已通过实验验证。OQMD 和 ICSD 标注的数据集涵盖了元素周期表中的大部分元素（图S1-4†），生成焓分布直方图如图S5所示†。

2.2 训练方法

在形成焓的预测方面，一个有效的预测模型应具备以下能力：

(1)能够区分能量更优（低能）结构与高能结构；(2)从大量相似结构中准确预测基态结构；(3)在广泛的元素和结构范围内具有泛化能力。本研究采用明确整合键角信息的原子级线图神经网络（ALIGNN）³²来推导晶体结构的特性——这些特性对于区分众多相似结构至关重要。ALIGNN 模型在包含基态结构与高能结构的平衡数据集上进行训练，从而确保形成焓预测的准确

性。将晶体学结构转化为图形表示的过程如图1b所示，ALIGNN的网络架构如图1c所示，详细说明见S1部分。[†]迁移学习在应对材料数据有限这一挑战方面展现出显著潜力³³，其过程如图1e所示。本研究中，迁移学习方法包括在大型DFT数据集上对ALIGNN模型进行预训练；随后利用规模较小的实验数据集对预训练模型参数进行再训练。我们选择冻结整个ALIGNN网络的所有层，仅保留最后两层全连接输出层不冻结。在整个再训练过程中，冻结层的权重保持不变，仅更新未冻结层的权重。

正样本与未标记算法（PUML）是半监督学习中的一个类别，旨在仅使用正样本和未标记样本进行学习。采用图神经网络作为分类器的PUML模型在无机化合物³⁴、二维材料³⁵及硫族化合物³⁶的可合成性分析中展现出显著潜力。本研究利用PUML模型评估候选晶体与可合成晶体之间的相似性（即合成概

率），具体流程如图1d所示：样本空间由随机分布的正样本数据（绿色实心圆，可合成）和未标记数据（灰色实心圆）构成。PUML模型通过多次随机选取部分未标记数据作为负样本（本研究中为100个）来训练ALIGNN分类器。在1,020,343个OQMD数据点中，随机选取了37,525个未标记数据点并标注为负样本，以平衡正样本数据（ICSD标记数据）。在每次迭代中，ALIGNN分类器均训练了50个周期，在合理的计算成本下实现了分类性能的收敛（图S6a[†]）。

2.3 培训设置

该代码使用Python 3.9实现，并采用PyTorch³⁷及PyTorch-Geometric³⁸库构建机器学习模型。均方绝对误差（MAE）与交叉熵损失函数被分别用作回归任务（构型焓预测）和分类任务（可合成性概率预测）的主要评估指标。在每次模型训练过程中，数据会被随机划分为80%–10%–




图1 CSP的流程图及子模块结构。采用优化算法方法的CSP流程图如图(a)所示，该流程图包含四个主要模块：(b) 晶体图生成：负责构建反映材料结构信息的晶体图；(c) ALIGNN 架构：描述用于建模并学习晶体结构与材料性质之间复杂关系的 ALIGNN 框架；(d) PUML 模型：指一种利用正样本和未标记样本进行训练的学习范式，使模型能够识别潜在的理想结构；(e) 转移学习：通过利用庞大的DFT计算数据集及现有实验观测结果，可实现更接近真实实验测量值的材料性质预测。

10%的数据集用于训练、验证和测试。论文中提及的所有性能指标均在测试集上进行评估，以提供模型性能的无偏估计。ALIGNN中用于预测生成焓及合成反应的训练参数与模型超参数配置详见表S1和表S2。[†]对于随机搜索(RS)、粒子群优化(PSO)和遗传算法(GA)，均使用scikit-opt库(<https://github.com/guofei9987/scikit-opt>)。PSO的配置参数中：动量参数(1)设为0.1或0.8；认知参数和社会参数则设为相应值。每个参数取值为0.5，种群规模为40。遗传算法(GA)采用50个个体进行计算，并设置变异概率为0.1或0.8。贝叶斯优化(BO)算法在Hyperopt软件(<https://github.com/hyperopt/hyperopt>)中实现，观测分位数g设为0.25，最大试验次数设为300。结构对称性约束中使用的所有原子半径均为范德华半径，数据来源于Pymatgen。³⁹

3. 结果

3.1 晶体结构预测的工作流程

晶体可通过材料的三类描述符(原子身份、组成与结构，即ACS)进行识别。在晶体结构预测(CSP)领域，通常的目标是根据给定的原子身份和组成来预测所需的晶体结构。晶体结构的确定(记为 $\text{Struct}(\mathbf{L}, \{\mathbf{R}_i\})$)取决于定义晶格常数 $\mathbf{L}$ 以及各原子的坐标 $\{\mathbf{R}_i\}$ 。尽管问题看似明确，但寻找最优结构仍面临巨大挑战。优化算法通过提升搜索效率，在缓解这一难题中发挥关键作用，从而加速找到最优解；引入对称性约束则进一步优化搜索过程。带有对称性约束的结构(记为 $\text{Struct}_{\mathbf{S}, \{\mathbf{W}_i\}}(\mathbf{L}, \{\mathbf{R}_i\})$)可通过指定其空间群($\mathbf{S}$)及对应的维科夫位置 $\{\mathbf{W}_i\}$ 来缩小搜索空间。同时，我们需要一种能够快速、精确地确定晶体结构性质的机器学习模型，作为传统密度泛函理论计算的替代方案。

图1a展示了具体的流程图。首先，基于原子身份和组成信息，我们筛选出一系列符合要求的空间群及对应的维科夫位置。在具有对称性约束的晶体结构预测(CSP)优化过程中，空间群及其对应维科夫位置均成为变量，从而生成 $\mathbf{S}-\{\mathbf{W}_i\}$ 二维离散空间；而在每个空间群和维科夫位置下，晶格常数与原子位置则成为连续变量，由此生成 $\text{Struct}_{\mathbf{S}, \{\mathbf{W}_i\}}(\{\mathbf{R}_i\}, \mathbf{L})$ 。随后，晶体结构被转化为晶体图 $G(\{\mathbf{v}_{ij}\}, \{\mathbf{e}_{ij}\})$ ，并运用多层模型预测形成焓及合成概率(P_{syn})，最终得出反映结构质量的适应度值(FV)。本质上，CSP的任务是通过优化算法确定能最小化适

应度值的空间群、维科夫位置、晶格常数及原子坐标组合。为提升CSP的准确性和灵活性，我们对这些变量进行了两阶段优化。具体而言，我们将晶格常数和原子坐标等连续变量视为一组优化参数，而将空间群和维科夫位置等离散变量视为另一组优化参数。在优化晶格常数和原子坐标时，目标是确定能量最稳定的结构；因此，适应度值仅取决于形成焓。相反，在优化空间群和维科夫位置时，目标则是从局部最稳定结构中筛选出最可能用于合成的结构。因此，适应度值同时综合考虑了形成焓与合成概率两个因素。

3.2 生成焓的预测

最初，我们采用ALIGNN模型利用OQMD数据集集中的数据训练形成焓计算。在测试集中，ALIGNN模型的均方误差(MAE)和决定系数(R^2)分别为每原子0.029 eV和0.994，表明该模型具有出色的稳健性(图2a)。值得注意的是，当前模型的MAE值与Choudhary等人³²先前报道的每原子0.033 eV结果高度吻合。如图2b所示，由于密度泛函理论(DFT)固有的局限性，部分实验观测结构的DFT计算值与实验值之间存在显著差异(MAE=每原子0.112 eV)。机器学习模型不仅继承了DFT与实验值之间的偏差，还引入了模型本身与DFT值之间的额外差异。因此，模型预测的形成焓与实验值之间的差距进一步扩大，其 R^2 值为0.976，MAE值为每原子0.125 eV(图2c)。尽管计算结果与实验数据存在偏差带来了挑战，但鉴于目前难以获取大量实验数据，直接依赖实验数据并不现实。

通过利用深度迁移学习模型对庞大的DFT计算数据集及现有实验数据进行训练，我们能够更精准地预测材料特性，其预测结果与实验测量值的吻合度显著提高。²²ALIGNN模型最初基于DFT计算数据进行训练，得益于丰富的数据源，该模型通常展现出优异的泛化性能。随后，模型进一步利用有限量的实验形成焓数据进行训练。图2d展示了测试集中预测值与真实实验值的散点分布关系。与未使用实验数据的模型(DFT-ALIGNN)相比，整合实验数据的模型(TL-ALIGNN)预测性能明显提升，预测误差降低了27.2%。此外，与DFT数据和实验数据之间的偏差相比，TL-ALIGNN模型预测值与实验数据之间的偏差进一步缩小了18.8%。




图.2 ALIGNN 模型的性能表现: (a) DFT- ALIGNN 预测值与DFT计算值之间的生成焓对比; (b) DFT计算值与实验值之间的生成焓对比; (c) DFT- ALIGNN 预测值与实验值之间的生成焓对比; (d) TL- ALIGNN 预测值与实验值之间的生成焓对比。

3.3 合成过程的预测

鉴于材料合成过程复杂且受多种因素影响, 构建通用理论或采用第一性原理方法来表征可合成性已变得不切实际。在此背景下, 我们利用基于 OQMD 虚拟晶体结构和 ICSD 实验验证晶体的 PUML 模型, 评估候选晶体与可合成晶体之间的相似性 (即合成概率)。经过100轮迭代训练后, 测试集上的平均精度达到 87.1%, 该结果与Jang等人³⁴的研究成果高度吻合。这一高精度表明模型通过迭代训练有效掌握了可合成材料的结构特征。如图S6b所示, 单一模型即可实现较高的预测精度; 随着分类器数量增加, 分类精度也显著提升。因此, CSP中晶体候选物的合成概率最终由100个分类器的预测结果取平均值确定。

3.4 优化算法的适应度值

总体而言, 较低的生成焓意味着材料具有更稳定的晶体结构, 并在一定程度上可反映其实验合成可行性。然而, 晶体的成功实验合成除热力学稳定性外, 还受环境条件、实验参数等多种

因素影响。因此, 设计一个能有效结合生成焓与合成概率这两个因素的适应度值至关重要。理论上, 生成焓的取值范围从负无穷到正无穷, 而合成概率则介于0至1之间。为调和这一差异, 我们考虑使用S型函数将生成焓映射至有界区间 (0至1), 同时保持数学单调性。另一方面, 最优结构既需要更低的生成焓, 也需要更高的合成概率。基于此, 我们设计了如下适应度值: $FV = a(1 - P_{syn}) + (1-a)\text{sigmoid}(\Delta H_f)$, 其中较低的FV值表示更高的优先级。此处, a 为一个取值范围在0至1之间的权重参数, 可通过调整该参数灵活平衡形成焓与合成概率对寻找最优晶体结构的影响。

3.5 晶体结构的对称性约束

对称性在定义材料特性方面起着关键作用, 它不仅影响材料的结构形态 (如结构参数和原子排列方式), 还决定了材料的物理性质。自然界倾向于形成对称晶体结构: 不对称的P1空间群在晶体中极为罕见。不同空间群之间的晶体结构分布并不均匀

^{5,40}。例如，在 ICSD 数据库收录的230个潜在空间群中，有24个空间群涵盖了 ICSD 数据库中三分之二的无机晶体。表征晶体结构主要涉及两个变量：晶格常数以及所有原子的分数坐标。本研究通过引入两个新的结构要素——空间群和维科夫位置，从对称性约束的角度探讨了晶体结构预测（CSP）。具体而言，我们随机选取229个具有对称性的空间群之一，并根据该空间群对应的布拉维晶格生成晶格参数；而原子位置则由该空间群中的维科夫占据情况决定。这些基于物理原理的约束条件将候选结构置于势能面上更优的区域，显著简化了CSP计算过程。为确保实际应用可行性并避免出现不合理结构，我们进一步对晶格常数、原子间距和晶胞体积施加限制：所有原子间距均需超过设定的最小值（即两个原子半径之和的0.5倍）；晶胞角度需控制在20°至160°之间；晶胞体积则限定在0.5至1.5倍 V_a 范围内（其中 V_a 代表构成原子体积之和）。这些约束条件有助于消除构型空间中冗余且不可行的区域，使计算聚焦于CSP算法可有效处理的合理区域。

3.6 不同优化算法的性能表现 晶体结构参数通常涉及多个维度，从而形成一个高度复杂、高维的参数空间，该空间以大量局部极小值为特征。

优化算法在探索这类复杂空间时发挥着关键作用，能够有效降低计算复杂度并加速最优解的发现。本研究采用了四种优化算法：随机搜索（RS）、粒子群优化（PSO）、遗传算法（GA）以及贝叶斯优化（BO）。其中，RS、GA和 PSO 已在基于密度泛函理论的约束满足问题（CSP）中取得显著成效^{3,5,7,10}；而近期被整合到CSP机器学习模型中的BO算法，则展现出卓越的全局极值识别能力。

18,41

以氧化镁为例，我们使用DFT- ALIGNN -CSP模型比较了 RS、PSO、GA和BO四种算法的性能。图3展示了四种不同优化算法在迭代过程中晶体结构的演化特征。RS和BO在态密度整个范围内呈现相对平滑的曲线，表明其在利用现有信息与探索新路径之间取得了平衡，显示出较高的摆脱局部极小值的能力。与BO相比，RS的有效尝试次数相对较少，这可能限制其在有限步数内发现全局最优解；GA（变异概率 $P_m=0.1$ ）和 PSO（惯性权重 $w=0.8$ ）的有效尝试次数较多，但大部分尝试集中在局部极小值附近，存在陷入局部最优解的风险。




图3展示了DFT- ALIGNN -CSP方法在四种优化算法中的计算流程与性能表现。绿色虚线表示各优化算法所需的累计时间，红色实线则描绘了最稳定结构随时间的变化趋势。左图展示了各能级处的态密度分布，有助于了解优化过程中不同能级处结构的分布情况。

遗传算法（GA）可能陷入局部最优而无法找到全局最优解；而粒子群优化算法（PSO）的变异概率与惯性权重则能调控其全局搜索与局部优化能力。如图S7a所示，提高变异概率可进一步增强GA的全局搜索能力，但会降低有效尝试次数。对于 PSO 而言，降低惯性权重会削弱其全局搜索能力（图S7b），而增大惯性权重则不会显著提升该能力。相比之下，玻尔兹曼优化算法（BO）能在开发与探索之间取得平衡，在合理时间内快速寻找全局最优解的能力更强。

3.7 晶体结构预测的验证

随后，研究团队采用DFT- ALIGNN -BO和TL- ALIGNN -BO方法对表1中列出的17种实验合成化合物的结构进行了鉴定。同时运用DFT-alignnbo和TL- ALIGNN -BO方法解析了闪锌矿/方铅矿及岩盐的晶体结构，充分展现了CSP方法从离子体系到共价体系的广泛适用性。所选结构还包括金属化合物与半导体化合物，证明了CSP方法在金属至半导体领域的预测能力。此外，这些结构涵盖了七个周期区的所有元素（包括镧系元素和铜系元素），体现了CSP方法在整个周期表中的普适性。在训练、验证和测试过程中，本研究涉及的17种化合物数据均未被纳入分析。其中BO方法用于在200步内优化空间群和威科夫位置参数，晶格常数及原子坐标则在300步内完成优化。若在拟合度排

名前五的晶体结构（拟合度越低优先级越高）中均包含目标结构，则判定CSP方法应用成功。经实验验证的结构。

从表1中可得出以下几点结论：(1)无论参数a取何值，固定晶体系搜索的成功率均显著高于所有晶体系搜索；(2)无论是固定晶体系搜索还是所有晶体系搜索，当a=0.5时（即同时考虑能量和可合成性评估指标），成功率均更高。(3)在固定晶体系搜索中整合能量评估与合成可行性评估可实现相对较高的成功率（82.4%）。ALIGNN -BO在立方晶体系（HfLi）、六方晶体系（SrCu）、四方晶体系（AuCl）以及三元化合物（BaZrO₃）中的成功应用，证明了其在多种晶体系及多组分化合物中的适用性。在众多化合物中，HfLi和ThO₂尤为值得关注。以ThO₂为例（如图S8所示），采用a=0参数的DFT-alignnbo方法经过62步计算获得了基态结构，但该结果尚未得到实验验证；而当考虑晶体合成可行性（a=0.5）时，TL- ALIGNN -BO预测的最佳结构与实验确认结构一致。然而，赋予晶体合成可行性更高权重并不意味着所识别结构更易通过实验合成。例如，仅考虑形成焓时才能正确识别RbI和LaTe，这表明PUML 模型可能存在误判（精确度=0.87）。

图4展示了 TL- ALIGNN -BO、DFT- ALIGNN -BO 以及 OQMD 数据库预测所得的15种化合物的生成焓和晶格常数与实验值之间的百分比误差。AuCl和CuSr的预测结果可参见图S9†（其预测效果相对较差）。如图4b所示，对于这15种化合物，

表1 ALIGNN -BO算法在采用 different 搜索策略（全晶体系或固定晶体系）及不同适应度值（a=0、0.5和1）时，对17种典型化合物进行构效关系（CSP）分析的性能表现

组合；构成；组成	所有晶体系统的 a			固定晶体系系统		
	均为 0	$\alpha = 0.5$	$\alpha = 1$	$\alpha = 0$	$\alpha = 0.5$	$\alpha = 1$
氢化锂		√	√		√	√
ThO ₂					√	√
CdF ₂	√	√		√	√	
CeS	√	√	√	√	√	√
ZrN	√	√	√	√	√	√
钽钛		√	√		√	√
砷化镓	√	√	√		√	√
氧化镁	√	√			√	√
AuCl				√		
碘化铯	√	√	√	√	√	√
RbI	√			√		
拉特	√			√		
K ₂ Se				√	√	
BaZrO ₃				√		√
InP		√	√		√	√
SrCu				√	√	
CaS	√	√	√	√	√	√
精度	52.9% (9/17)	58.8% (10/17)	47.1% (8/17)	70.6% (12/17)	82.4% (14/17)	64.7% (11/17)




图4展示了基于机器学习模型预测结果与 OQMD 所得结构与实验数据的对比情况。图中展示了TL- ALIGNN -BO、DFT- ALIGNN -BO方法以及 OQMD 数据库计算所得结果在形成焓(a)和晶格常数(b)方面的预测值与15种化合物实验值之间的差异。

TL- ALIGNN -BO、DFT- ALIGNN -BO及 OQMD 数据库计算得出的晶格常数与实验值的误差均在10%以内。其中，DFT计算所得晶格常数与实验值高度吻合，平均误差低于2%（实际为1.83%）；而结合部分实验数据的TL- ALIGNN -BO模型预测值平均误差为2.02%，虽略高于DFT计算结果，但较DFT- ALIGNN -BO模型（2.51%）已有显著改善；相比之下，ML-CSP模型预测值与 OQMD 数据库中的DFT计算结果在生成焓方面均与实验值存在明显偏差，其中DFT计算值与实验值之间的平均误差达10%。该差异为74%，而DFT- ALIGNN -BO方法将该差异扩大至11.28%。使用TL- ALIGNN -BO进行预测可将误差降至8.34%，这与图2的分析结果一致。

4. 讨论

理论化学合成过程（CSP）方法的发展一直是物理学、化学及材料科学领域长期期待的目标。传统的密度泛函理论CSP（DFT-CSP）和机器学习CSP（ML-CSP）通常依赖理论计算得到的生成焓，并运用优化算法寻找能量最低的基态结构。然而，现有CSP方法并未考虑实验测得的生成焓与理论计算值之间的差异。此外，材料的合成过程本身极为复杂，不仅受热力学稳定性影响，还受到动力学参数、合成工艺等多种因素制约。我们的模型利用实验获得的生成焓数据，显著缩小了理论值与实验值之间的差距；同时通过分析结构可合成性，确保预测结构极有可能得到实验验证。

与Cheng等人¹⁸使用的 OQMD v1.3及Materials Project⁴²数据集相比，我们采用了包含超过一百万个结构信息的 OQMD v1.5数

据集。与Xie等人⁴³开发的 CGCNN 以及Cheng等人⁴⁴使用的 MEGNet不同，本研究使用的 ALIGNN 模型进一步整合了晶体键角信息。通过扩展训练数据并改进预测模型，当前版本的 ALIGNN -CSP在周期表中的大多数元素上均展现出强大的泛化能力，并显著提升了预测精度。例如，CGCNN 无法区分某些高度相似的结构（图S10†），而 ALIGNN 则具备识别这些结构的能力。已有研究表明，当BO算法与CSP结合使用时，其性能优于通常与DFT-CSP结合使用的 PSO 和RS算法¹⁸。我们还对CSP框架下的BO、PSO、RS及GA算法进行了深入比较。结果表明，BO算法能够在利用与探索之间取得平衡，并具备在合理时间效率范围内快速寻找全局最优解的更强能力。

这种被称为“属性引导结构设计”的方法论，通过利用材料的结构特性知识作为输入参数来预测其后续性能特征。然而，这种试错式设计过程既耗时又费力。为解决这些局限性，逆向设计范式（结构由属性决定）应运而生，旨在生成符合目标材料性能要求的候选结构。⁴⁵⁻⁵⁰本研究结合了晶体相图（CSP）中的可合成性信息，实现了更易实验合成的晶体结构逆向设计。该方法显著加速了材料设计进程，并降低了实验验证成本。事实上，我们的模型不仅能应用于CSP分析，还可通过引入其他目标函数作为约束条件，拓展至材料的通用逆向设计领域——例如在CSP中加入热导率或光电导率等参数，从而加速开发具有优异热导率或光电性能的新材料。

机器学习方法在晶体相图（CSP）领域的应用仍处于发展初期，面临诸多亟待解决的科学与技术难题。CSP领域的一个普遍

挑战在于如何准确预测复杂系统——这一难题已持续存在多年。我们的研究结果也表明，当前的 ALIGNN -CSP模型在预测复杂系统方面仍有显著提升空间。另一方面，相较于立方晶系，ALIGNN -CSP在其他非立方晶系中的预测能力与性能明显下降，这主要归因于训练数据中其他非立方晶系的比例相对较低（如图S11a所示）。然而在自然界（尤其是 ICSD 数据库收录的晶体结构中），其他非立方晶系所占比例相当可观（图S11b）。提升模型预测精度是提高CSP整体预测准确性的关键方向。然而，除了优化神经网络模型外，更具实质意义的改进可能包括进一步补充和完善数据库，尤其是为其他非立方晶系提供额外的结构数据。同样，更多实验数据也将进一步缩小CSP结果与实验数据之间的差异。

5. 结论

综上所述，我们提出了一种高效的晶体结构预测（CSP）方法，该方法将优化算法与先进的深度学习模型相结合，并充分利用了丰富的DFT材料数据库及实验数据。我们采用了一种整合键角信息的 ALIGNN 模型，从而实现结构与性质之间的精准对应。通过运用深度迁移学习技术学习实验测得的形成焓值，我们的模型能够更准确地预测晶体结构的形成焓，其预测结果与实验值高度吻合。通过将形成焓与可合成性相结合，ALIGNN -CSP模型不仅能预测出具有热力学稳定性的晶体结构，还能更适配实际实验室条件下的合成需求。同时，我们评估了不同优化算法在CSP中的性能，证实BO算法能显著提升模型在广阔化学空间中探索潜在结构的效率。该模型随后被应用于预测17种典型化合物的晶体结构，充分展现了其在涵盖从离子键到共价键、金属到半导体以及整个元素周期表范围内的化合物体系中的泛化能力。预测结果表明：结合实验测定的生成焓数据后，CSP模型显著缩小了预测值与实验测得的生成焓及晶格常数之间的差异；相较于仅基于生成焓的CSP模型，加入合成可行性分析后，该模型识别可实验合成晶体的能力得到大幅提升。本研究弥合了实验研究与理论计算之间长期存在的差距，为材料逆向设计开辟了新的研究路径。

代码可用性

ALIGNN -CSP方法的代码可在[https://github.com/stupid-cloud/ALIGNN -CSP](https://github.com/stupid-cloud/ALIGNN-CSP)获取。

数据可用性

本文所使用的数据集均可在其对应网站上公开获取：DFT生成焓（<http://oqmd.org>）及实验生成焓（<https://github.com/wolverton-research-group/qmpy/blob/master/qmpy/data/thermodata>）。

作者贡献

程龙秦：撰写原始草稿、审阅与编辑；刘金德：研究方法设计；马世银：调研工作；杜继光：资料收集；赵亮：项目监督与管理；江刚：概念构思。

利益冲突

作者声明无利益冲突。

致谢

本研究得到中国国家自然科学基金（项目编号：12304274）和中央高校基本科研业务费专项资金（项目编号：2024SCU12104）的支持。

参考文献

- 1 P. Patel, 《材料基因组计划与能源》，《MRS Bulletin》，2011年，第36卷，第964–966页。
- 2 A. R. 奥加诺夫, 《晶体结构预测：现状与挑战述评》，《法拉第讨论》，2018年，第211卷，第643–660页。
- 3 S. M. Woodley 和 R. Catlow, 《基于第一性原理的晶体结构预测》，《自然·材料》，2008年，第7卷，第937–946页。
- 4 T. S. Thakur、R. Dubey 和 G. R. Desiraju, 《晶体结构与预测》，《物理化学年评》，2015年，第66卷，第21–42页。
- 5 A. R. 奥加诺夫、C. J. 皮卡德、Q. 朱和 R. J. 尼兹, 《结构预测推动材料发现》，《自然·材料评论》，2019年，第4卷，第331–348页。
- 6 J. Graser、S. K. Kauwe 和 T. D. Sparks, 《晶体结构预测中的机器学习与能量最小化方法：综述与新方向》，《化学材料》，2018年，第30卷，第3601–3612页。
- 7 王宇、吕杰、高鹏和马勇, 《通过势能面高效采样进行晶体结构预测》，《化学研究进展》，2022年，第55卷，第2068–2076页。
- 8 王宇、吕杰、朱磊和马勇, 《Calypso：一种晶体结构预测方法》，《计算物理通讯》，2012年，第183卷，第2063–2070页。
- 9 A. O. 利亚霍夫、A. R. 奥加诺夫、H. T. 斯托克斯和Q. 朱, 《进化结构预测算法 USPEX 的新进展》，《计算物理通讯》，2013年，第184卷，第1172–1182页。

- 10 X. Yin 和 C. E. Gounaris, 《无机材料晶体结构预测的搜索方法》, 《当代化学工程观点》, 2022年, 第35卷, 第100726页。
- 11 R. Nikhar 和 K. Szalewicz, 《基于第一性原理的可靠晶体结构预测》, 《自然·通讯》, 2022年, 第13卷, 第3095页。
- 12 朱立、刘浩勇、皮卡德·C·J、邹国涛及马永明在《自然·化学》(2014年, 第6卷, 第644–648页)中预测了氦与铁及镍在地球内核中的反应。
- 13 R. J. Needs 和 C. J. Pickard, 《视角: 结构预测在材料发现与设计中的作用》, 《APL Materials》, 2016年, 第4卷, 第053210页。
- 14 S. D. Griesemer、Y. Xia 和 C. Wolverton, 《利用机器学习加速稳定材料的预测》, 《自然·计算科学》, 2023年, 第3卷, 第934–945页。
- 15 A. Merchant、S. Batzner、S. S. Schoenholz、M. Aykol、G. Cheon 和 E. D. Cubuk, 《面向材料发现的深度学习规模化研究》, 《自然》杂志, 2023年, 第624卷, 第80–85页, DOI: [10.1038/s41586-023-06735-9](https://doi.org/10.1038/s41586-023-06735-9)。
- 16 V. V. 古谢夫、D. 亚当森、A. 德利格卡斯、D. 安蒂波夫、C. M. 科林斯、P. 克里斯塔、I. 波塔波夫、G. R. 达林、M. S. 迪尔、P. 斯皮拉基斯和 M. J. 罗辛斯基, 《晶体结构预测的最优性保证》, 《自然》杂志, 2023年, 第619卷, 第68–72页。
- 17 N. J. Szymanski、B. Rendy、Y. Fei、R. E. Kumar、T. He、D. Milsted、M. J. McDermott、M. Gallant、E. D. Cubuk、A. Merchant、H. Kim、A. Jain、C. J. Bartel、K. Persson、Y. Zeng 和 G. Ceder, 《用于新型材料加速合成的自主实验室》, 《自然》杂志, 2023年, 第624卷, 第86–91页, DOI: [10.1038/s41586-023-06734-w](https://doi.org/10.1038/s41586-023-06734-w)。
- 18 程刚、龚晓刚和尹伟杰, 结合图网络与优化算法进行晶体结构预测, 《自然·通讯》, 2022年, 第13卷, 第1492页。
- 19 李春宁、梁浩鹏、张旭、林哲和魏世华, 《图结构深度学习加速高效晶体结构搜索与特征提取》, 《国家计算材料期刊》, 2023年, 第9卷, 第176页。
- 20 王杰、高浩、韩宇、丁超、潘硕、王毅、贾强、王浩涛、邢丹和孙杰, 《magus: 基于机器学习与图论的通用结构搜索工具》, 《美国国家科学评论》, 2023年, 第10卷, nwad128。
- 21 王晓勇、王振勇、高鹏勇、张春强、吕杰、王浩、刘华峰、王玉清和马永明, 《基于数据驱动的致密锂复杂晶体结构预测》, 《自然·通讯》, 2023年, 第14卷, 第2924页。
- 22 D. Jha、K. Choudhary、F. Tavazza、W.-k. Liao、A. Choudhary、C. Campbell 和 A. Agrawal, 《利用深度迁移学习结合计算与实验数据提升材料性能预测》, 《自然·通讯》, 2019年, 第10卷, 第5316页。
- 23 S.柯克林、J.E.萨尔、B.梅雷迪格、A.汤普森、J.W.杜奥克、M.艾科勒、S.鲁尔与C.沃尔弗顿合著的《开放量子材料数据库(OQMD): 评估密度泛函理论形成能的准确性》, 发表于《计算材料杂志》2015年第1卷第15010页。
- 24 A.贾因、G.奥蒂埃、S.P.翁、C.J.摩尔、C.C.菲舍尔、K.A.佩尔松和G.塞德, 《通过混合 GGA 与 GGA +U 计算得出的形成焓》, 《物理评论B: 凝聚态物质与材料物理学》, 2011年, 第84卷, 第045115页。
- 25 G. Kim、S. V. Meschel、P. Nash 和 W. Chen, 《金属间化合物及其他无机化合物的实验形成焓》, 《Sci. Data》, 2017年, 第4卷, 第170162页。
- 26 J. J. De Yoreo、P. U. Gilbert、N. A. Sommerdijk、R. L. Penn、S. Whitelam、D. Joester、H. Zhang、J. D. Rimer、A. Navrotsky、J. F. Banfield、A. F. Wallace、F. M. Michel、F. C. Meldrum、H. Colfen 和 P. M. Dove, 《晶体生长: 在合成、生物及地质环境中通过颗粒附着实现结晶》, 《科学》杂志, 2015年, 第349卷, aaa6760页。
- 27 V. L. 德林格、D. M. 普罗塞里波、G. 奇亚尼与 C. J. 皮卡德, 《基于数据的无机晶体结构学习与预测》, 《法拉第讨论》, 2018年, 第211卷, 第45–59页。
- 28 W.H.孙、S.T.达切克、S.P.翁、G.奥蒂耶、A.贾因、W.D.理查兹、A.C.甘斯特、K.A.佩尔松和G.塞德, 《无机晶体亚稳态的热力学标度》, 《科学进展》, 2016年, 第2卷, e1600225。
- 29 J. J. de Pablo、N. E. Jackson、M. A. Webb、L.-Q. Chen、J. E. Moore、D. Morgan、R. Jacobs、T. Pollock、D. G. Schlom、E. S. Toberer、J. Analytis、I. Dabo、D. M. DeLongchamp、G. A. Fiete、G. M. Grason、G. Hautier、Y. Mo、K. Rajan、E. J. Reed、E. Rodriguez、V. Stevanovic、J. Suntivich、K. Thornton 和 J.-C. Zhao, 《材料基因组计划的新前沿》, 《npj Comput. Mater.》, 2019, 5, 41。
- 30 J. J. de Pablo、B. Jones、C. L. Kovacs、V. Ozolins 和 A. P. Ramirez, 《材料基因组计划: 实验、理论与计算的相互作用》, 《当代固态材料科学观点》, 2014年, 第18卷, 第99–117页。
- 31 D. 扎戈拉茨、H. 穆勒、S. 鲁埃尔、J. 扎戈拉茨与 S. 雷梅, 《无机晶体结构数据库的最新进展: 理论晶体结构数据及相关特征》, 《应用晶体学杂志》, 2019年, 第52卷, 第918–925页。
- 32 K. Choudhary 和 B. DeCost, 《用于改进材料性能预测的原子级线图神经网络》, 《计算材料杂志》, 2021年, 第7卷, 第185页。
- 33 徐鹏、纪晓、李明和陆伟, 《材料科学中的小数据机器学习》, 《国家计算材料期刊》, 2023年, 第9卷, 第42页。
- 34 J. Jang、G. H. Gu、J. Noh、J. Kim 和 Y. Jung, 《基于结构的晶体可合成性预测——采用部分监督学习方法》, 《美国化学会志》, 2020年, 第142卷, 第18836–18843页。
- 35 N. C. Frey、J. Wang、G. I. Vega Bellido、B. Anasori、Y. Gogotsi 和 V. B. Shenoy, 《利用正样本与未标注数据进行二维金属碳化物及氮化物(MXenes)及其先驱体合成的预测》, 《ACS Nano》, 2019, 13, 3031–3041。
- 36 顾广辉(G. H. Gu)、张杰(J. Jang)、吴俊(J. Noh)、沃尔什(A. Walsh)与郑宇(Y. Jung), 利用图神经网络实现钙钛矿的合成, 载于《国家计算材料期刊》(npj Comput. Mater.), 2022年, 第8卷, 第71页。
- 37 A. 帕斯克、S. 格罗斯、F. 马萨、A. 莱勒、J. 布拉德伯里、G. 查南、T. 基林、Z. 林、N. 吉梅尔沙因、L. 安蒂加、A. 德斯梅森、A. 科夫、E. 杨、Z. 德维托、M. 赖森、A. 特贾尼、S. 奇拉姆库尔蒂、B. 斯泰纳、L. 方、J. 白及 S. 钦塔拉的研究成果, 已于2019年12月1日在第33届国际神经信息处理系统会议论文集部分发表。

- 38 M. Fey与J. E. Lenssen合著的《使用Py Torch Geometric 进行 Fast Graph Representation Learning 》，于2019年 ICLR 图论与流形 Representation Learning 研讨会期间发表。
- 39 S. P. Ong、W. D. Richards、A. Jain、G. Hautier、M. Kocher、S. Cholia、D. Gunter、V. L. Chevrier、K. A. Persson 和 G. Ceder, 《Python 材料基因组学 (pymatgen): 一个用于材料分析的稳健开源 Python 库》，《计算材料科学》，2013年，第68卷，第314–319页。
- 40 V. 乌罗索夫与T. 纳杰日娜，《无机晶体化学中空间群的频率分布与选择》，《结构化学杂志》，2009年，第50卷，第22–37页。
- 41 山下智、佐藤仁、木野宏、宫胁智、津田康和小口智，基于贝叶斯优化加速的晶体结构预测，《物理评论材料》，2018年，第2卷，第013803页。
- 42 A. 贾因、S. P. 奥格、G. 哈蒂埃、W. 陈、W. D. 理查兹、S. 达切克、S. 科利亚、D. 盖特纳、D. 斯金纳、G. 塞德及 K. A. 佩尔松，《评论：材料项目——采用材料基因组学方法加速材料创新》，《APL Mater.》，2013年，第1卷，第011002页。
- 43 谢涛 (T. Xie) 与J·C·格罗斯曼 (J. C. Grossman) 提出的晶体图卷积神经网络，能够实现高精度且可解释的预测结果。
- 材料性能预测，《物理评论快报》，2018年，第120卷，第145301页。
- 44 陈C、叶W、左Y、郑C与翁S.P.，《图网络作为分子与晶体的通用机器学习框架》，《化学材料》，2019年，第31卷，第3564–3572页。
- 45 廖天伟与李刚，《基于元启发式的材料逆向设计——综述》，《材料组学杂志》，2020年，第6卷，第414–430页。
- 46 A. Zunger,《基于目标功能的材料逆向设计》，《自然·化学评论》(Nat. Rev. Chem.)，2018年，第2卷，第0121页。
- 47 J. Noh、G. H. Gu、S. Kim 和 Y. Jung,《基于机器辅助的无机固体材料逆向设计：前景与挑战》，《化学科学》，2020年，第11卷，第4871–4881页。
- 48 J. Lee、D. Park、M. Lee、H. Lee、K. Park、I. Lee 和 S. Ryu,《基于机器学习的逆向设计方法：在材料设计与制造中考虑数据特征与设计空间规模——综述》，《材料视野》，2023,5436–5456, DOI: [10.1039/d3mh00039g](https://doi.org/10.1039/d3mh00039g)。
- 49 D. M. 安斯廷与 O. 伊萨耶夫,《生成模型作为化学科学中的新兴范式》，《美国化学会志》，2023年，第145卷，第8736–8750页。
- 50 K. Ryan、J. Lengyel 和 M. Shatruk,《通过深度学习进行晶体结构预测》，《美国化学会志》，2018年，第140卷，第10158–10168页。