




晶体结构生成式人工智能：综述



皮埃尔-保罗·德·布雷克^{1,2}✉, 王海晨^{1,2}; 詹·马可·里尼亚内塞^{3,4}; 西尔瓦娜·博蒂^{1,2}; 以及米格尔·A·L·马克斯^{1,2}

生成式人工智能的迅猛发展正重塑材料发现领域，它不仅提供了提出晶体结构的新方法，在某些情况下甚至能够预测所需的材料特性。本综述全面梳理了专为无机晶体材料设计的生成模型领域的最新进展，系统阐述了其架构、表征方式、条件化机制、数据源、评估指标及应用场景，并将现有模型整合至统一的分类体系中。

技术的迅猛发展与新材料的发现与开发密切相关¹⁻³。从储能与转换到电子学及催化领域，这些领域的进步都依赖于具有精心设计特性的材料。这一过程中的关键步骤在于对稳定或亚稳态晶体结构进行计算设计与表征，从而确定哪些结构应优先进行实验合成与测试。这一被称为“材料筛选”的原理，是当今材料发现的核心所在。

在此背景下，最早面临的问题之一便是为给定的化学式枚举所有可能的晶体结构。传统上，这项被称为晶体结构预测（CSP）的任务采用多种方法探索势能面以识别全局低能量构型。遗传算法（USPEX^{4,5}）、随机搜索⁶、粒子群优化（Calypso⁷）以及极小值跳跃法⁸等技术已被广泛应用于探索这一复杂势能景观，并通过评估结构能量来迭代优化候选结构。这些方法模拟了自然过程，已成功推动新型材料的设计^{9,10}。

然而，CSP方法应与完全生成式方法区分开来。前者传统上从预定义的化学组成出发，并通常设定每个晶胞中的原子数量；此外，其核心流程基于迭代筛选机制——每个候选结构都需进行精确的能量计算，这一步骤在高精度方法中尤其计算成本高昂。更重要的是，CSP的搜索空间随体系规模呈指数级增长，带来了巨大的组合计算挑战。

相比之下，基于人工智能的生成方法通过大型晶体结构数据库学习底层数据分布及化学规律，因此能够直接提出新颖且合理的晶体结构，而无需对化学性质或化学计量学设定先验约束。这避免了CSP方法中固有的计算密集型搜索及初始能量评估步骤。此外，许多生成模型均可实现这一功能。

基于特定目标特性设定，可为发现具有所需特性的材料提供更直接、高效的途径。

这标志着材料发现与设计领域的一场范式转变。历史上，材料发现主要依赖经验性的试错方法——爱迪生寻找灯丝的过程便是明证。随着时间推移，该领域已从启发式方法发展为基于理论指导的合成研究和高通量计算筛选。如今，生成式人工智能能够实现主动化的材料生成，在实验验证前即可通过计算机模拟对候选材料进行优先排序。


近期多项综述与研究视角已全面探讨了材料科学领域中逆向设计与生成设计方法的整体发展态势¹¹⁻¹⁷。本综述旨在系统梳理无机晶体材料生成模型领域的最新进展，重点聚焦于这些模型的设计架构、表征方式以及通过约束条件整合限制因素的能力。需要特别说明的是，本文仅涵盖基于计算机模拟的晶体结构生成方法（如晶体学信息文件CIF格式），不涉及材料合成、加工处理或实验表征等内容。

本综述的其余部分结构安排如下：“预备知识”章节介绍了生成建模的基础概念，包括概率分布的数学表达式、常用算法以及材料表征方法；“数据来源”章节探讨了训练数据的重要性及当前可用的数据集；“分类体系”章节系统梳理了应用于无机材料的各种生成模型，并根据表征方式、架构设计、条件约束及材料领域特征将其归类为不同类别；“评估指标与基准测试”章节则涵

盖了相关基准测试研究进展及现存技术空白。评估指标。最后，“应用”部分阐述了实际应用场景，“讨论与未来方向”部分概述了未来研究方向，“结论”部分总结了我们的主要发现。

¹跨学科先进材料模拟中心（ICAMS），德国波鸿鲁尔大学。²未来能源材料与系统研究中心，鲁尔大学联盟，德国波鸿。³凝聚态物理与纳米科学研究所（IMCN），比利时鲁汶大学，比利时卢万拉纳夫。⁴WEL研究所，比利时瓦夫尔。✉电子邮件：pierre-paul.debreuck@rub.de

图1 | 晶体结构生成的生成式AI示意图。(1)晶体结构训练数据从多个数据库中收集。(2)这些数据在材料空间中遵循分布 x ，可转换为能量分布 $E(x)$ 。(3)该分布由生成模型隐式学习到，为采样概率 $p(x)$ 提供基础。存在两种实现方式：(4a)无条件采样，可选择后续进行后处理（如针对目标属性 y 的属性筛选 $p(y|x)$ ）；或(3b)条件学习 $p(x|c)$ ，从而实现(4b)直接条件采样。



初步工作；准备工作

问题陈述

生成建模是人工智能与机器学习领域的一项基础性研究范式，其核心目标在于学习给定数据集的底层概率分布 $p(x)$ 。与监督学习模型（通过建立输入到输出的映射关系来预测给定输入 x 的标签 y ，即学习条件概率 $p(y|x)$ ）不同，生成模型能够直接捕捉数据本身固有的概率分布 $p(x)$ 。

其核心目标是训练一个由 θ 参数化的模型，使得 $p_{\theta}(x) \approx p(x)$ ，从而能够根据 $p_{\theta}(x)$ 生成新的样本 x ，这些样本在统计上与从真实数据分布 $p(x)$ 中抽取的样本无法区分。

该框架自然可推广至固体晶体材料：其中 x 表示完整的晶体结构构型（即晶格矢量、原子种类集合及其对应的分数坐标），而 $p(x)$ 则表示此类结构的相应概率分布。实际上，某些构型出现的概率远高于其他构型，这实际上将所有可能（随机）原子排列的空间缩小至接近全局或局部能量最低点的区域。例如，在假设玻尔兹曼分布的情况下， $p(x) = \exp(-E(x)/k_B T)$ 。因此，对应于（亚）稳定材料的低能构型构成了该分布中的高概率模式，也是生成采样的主要目标对象。这一关系如图1所示。

生成模型并非依赖明确的化学规则或直接的能量评估，而是通过已知结构数据集隐式地学习复杂的多模态概率分布 $p(x)$ ，从而捕捉不同材料类别所共有的核心结构特征与键合机制。

生成式架构

在本节中，我们阐述了用于材料生成的主要生成架构所基于的理论基础。此处，“架构”指定定义模型如何从概率分布 $p(x)$ 中采样的概率框架。我们讨论了变分自编码器（VAE）、生成对抗网络（GAN）、Transformer网络、归一化流以及扩散模型。此外，我们特别指出大型语言模型（LLM）作为Transformer架构的一种具体应用形式，其独特之处在于其独特的训练范式。图2展示了这些不同架构与训练范式的示意图。

变分自编码器（VAEs）。由Kingma和Welling¹⁸提出的VAEs将降维技术与概率生成建模相结合。它们通过引入对潜在空间的概率化处理，扩展了经典自编码器架构——即将高维输入 x 映射为低维潜在向量 z 的编码器网络，以及从 z 重建 x 的解码器网络。

VAE定义了一个近似的后验分布 $q_{\phi}(z|x)$ ，通常选择为多元高斯分布 $N(\mu_{\phi}(x), \text{diag}(\sigma^2_{\phi}(x)))$ 。从该分布中可抽取样本 $z \sim q_{\phi}(z|x)$ 并输入解码器，由解码器建模似然函数 $p_{\theta}(x|z)$ 。这种随机编码使解码器对潜在空间中的变化更具鲁棒性，并能通过直接采样先验分布生成新颖样本。

先验分布 $p(z)$ 通常设定为标准正态分布 $N(0, I)$ ，它为潜在空间赋予了平滑且连续的结构。VAE训练的核心在于最大化边缘对数似然函数 $\log p(x)$ 的证据下界（ELBO）。

$$\mathcal{L}_{\text{ELBO}}(\mathbf{x}; \theta, \phi) = \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\theta}(\mathbf{x}|\mathbf{z})] - D_{\text{KL}}(q_{\phi}(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z})). \quad (1)$$

第一项（重构损失）旨在促进从 z 中精确恢复 x ；而第二项（Kullback-Leibler散度）则使近似后验 $q_{\phi}(z|x)$ 向先验 $p(z)$ 靠拢。这确保了潜在空间的分布能够支持平滑采样。

VAE训练完成后，生成新样本 x 的过程十分简单：先从概率分布 $p(z)$ 中抽取样本 z ，再计算出 x ，即 $p_{\theta}(x|z)$ 。这一两步流程将建模数据分布 $p(x)$ 的复杂问题转化为在规范化的潜在空间中进行学习与采样，从而能够生成新的、合理的数据点。

生成对抗网络（GANs）。与显式学习概率分布 $p(x)$ 的方法不同，由Goodfellow等人^{19,20}提出的GANs通过涉及两个独立神经网络（生成器 G 和判别器 D ）的对抗过程来训练样本生成能力：生成器试图欺骗判别器使其认为其输出为真实样本，而判别器则致力于区分真实样本与生成器产生的合成样本。




图2 | 主要生成模型架构与范式的示意图：a 变分自编码器（VAE）；b 生成对抗网络（GAN）；c 自回归变换器；d 归一化流；e 扩散模型；f 大型

语言模型（LLM）——这是一种基于变换器的范式，其区别在于训练策略而非具体架构。详细数学公式及讨论参见正文。

在此双玩家博弈场景中，生成器学习将通常从标准正态分布 $N(0, I)$ 等简单先验分布中抽取的潜在向量 z 映射为类数据输出。 $\hat{x}$ 即 $G(z)$ 。与此同时，判别器的目标是最大化正确区分生成数据与来自真实数据分布 p_{data} 的真实样本的概率。对抗性训练目标可正式表述为：

$$\mathcal{L} = \min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D(G(z)))] \quad (2)$$

通过这一损失函数，生成器能够持续提升其生成与真实数据无法区分的样本的能力；同时判别器则更擅长识别细微的伪影。理想情况下，训练过程会收敛于纳什均衡状态：判别器无法可靠地区分真实样本与生成样本（即对所有输入样本均有 $D(x) = 0.5$ ），而生成器则能准确捕捉底层数据分布 $p(x)$ 。

与VAE（变分自编码器）明确优化基于似然的目标函数并通过正则化为潜在空间赋予结构不同，GAN（生成对抗网络）无需显式定义 $p(x)$ 的数学形式或引入重构损失函数。

然而，生成对抗网络（GAN）在训练过程中常出现不稳定性及模式坍塌现象，即生成器仅能产生有限多样性的样本。

Transformer模型。由Vaswani等人²¹提出的Transformer是一种基础性的深度学习模型，以其可扩展性、可并行化特性以及捕捉长距离依赖关系的能力而著称。该模型摒弃了循环神经网络和卷积运算，转而采用自注意力机制来处理输入序列。

该模型基于输入嵌入向量序列 $\{x_1, x_2, \dots, x_n\}$ 进行运算，这些向量通过位置编码增强以保持词元顺序。在材料科学领域，原子、化学键或对称性描述符等结构信息均可表示为序列形式，这使得Transformer模型非常适合从材料结构数据中学习特征。

仅编码型Transformer通过学习序列的联合概率分布来应用于生成任务。这一过程是通过运用链式法则对序列进行因子分解实现

的：

$$p(x) = \prod_{i=1}^N p(x_i | x_{<i}) \quad (3)$$

此处， x_i 表示序列中的第 i 个标记。这种自回归模型架构可通过从已学习的分布中依次采样标记来生成新的材料结构。

为保持这种自回归特性，解码器采用了掩蔽自注意力层，该层在训练过程中防止对后续位置数据的访问。自注意力机制通过对序列中所有标记表示进行加权求和，从而能够捕捉上下文依赖关系（无论其距离远近）。对于每个注意力头，输入数据会被投影为查询向量(Q)、键向量(K)和值向量(V)，输出则按以下公式计算：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4)$$

其中 d_k 表示关键向量的维度。这一方法通过多头注意力机制得到扩展：该机制并行执行多项此类计算，以捕捉表征不同子空间之间的多样化关系。

该变压器高效且灵活的设计使其在众多序列建模任务中展现出顶尖性能，从而推动其在从自然语言处理到蛋白质折叠及材料发现等多个领域得到广泛应用。

归一化流。归一化流是一类生成模型，通过一系列可逆且可微的映射将简单的概率分布转化为复杂的概率分布。与VAE或GAN不同，归一化流能够通过显式建模数据分布来提供精确的对数似然估计和易于处理的采样方法^{22,23}。

给定一个基础分布 $p_z(z)$ （通常为标准正态分布 $N(0, I)$ ），归一化流定义了一个双射 transformation $f_\theta: z \leftrightarrow x$ ，使得输出 x 服从目标数据

for the computation of the exact density using the change of variables formula:

$$\log p_{\mathbf{x}}(\mathbf{x}) = \log p_{\mathbf{z}}(f_{\theta}^{-1}(\mathbf{x})) + \log \left| \det \left(\frac{\partial f_{\theta}^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right) \right|. \quad (5)$$

通过组合多个simple transformations $\mathbf{z}_0 \leftrightarrow \dots \leftrightarrow \mathbf{z}_K = \mathbf{x}$, 即可在保持计算可操作性的同时对复杂分布进行建模。每个变换必须可逆且其雅可比行列式易于计算。

除了离散流之外, 连续归一化流²³通过用神经网络参数化的常微分方程替代一系列映射函数, 实现了基于连续时间动态的更灵活变换。近年来, 流匹配 (Flow Matching, FM)²⁴提出了一种简化的训练目标: 通过直接匹配分布之间的向量场来学习此类连续流, 从而构建出稳定且可扩展的生成模型。这些模型通过学习结构化潜在空间与高维材料表征之间的平滑映射关系, 能够自主生成新型材料。

扩散模型。扩散模型已成为一类极为成功的生成模型, 其通过系统地逆转渐进噪声化过程来合成数据, 早期应用范围涵盖图像²⁵、点云²⁶及分子构象²⁷, 质量常超越GAN模型。该模型最初受非平衡热力学理论启发 (参见Sohl-Dickstein等人的研究²⁸), 由两个主要部分构成: 固定前向过程——逐步向数据添加噪声直至接近纯噪声; 以及可学习的逆向过程——在每一步均通过去噪操作重建逼真样本。

我们在此阐述去噪扩散概率模型 (DDPMs)²⁹。前向过程被定义为一个马尔可夫链, 该链根据固定的方差分布方案 $\{\beta_t\}$, 在 T 个离散时间步内向数据样本 $\mathbf{x}_0$ 添加高斯噪声。 $T_{t=1}$:

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = N(\mathbf{x}_t | \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}). \quad (6)$$

当 $t \rightarrow T$ 时, 分布 $q(\mathbf{x}_T)$ 收敛为各向同性高斯分布 $N(0, \mathbf{I})$ 。核心任务是学习逆过程 $p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)$, 该过程能够近似真实的 (但难以计算的) 后验分布 $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 。这通常通过训练神经网络 ϵ_{θ} 来实现, 使其能够预测在给定步骤 t 时添加的噪声。训练目标可简化为以下损失函数:

$$\mathcal{L} = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} [\|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|^2], \quad (7)$$

其中 ϵ 表示采样噪声, $\mathbf{x}_t$ 表示第 t 步时 $\mathbf{x}_0$ 的含噪版本。

要生成新样本, 首先starts with pure noise $\mathbf{x}_T \sim N(0, \mathbf{I})$ 出发, 通过迭代应用已学习的去噪函数进行时间反向推演, 最终得到纯净样本 $\mathbf{x}_0$ 。该方法的主要变体包括: 去噪扩散隐式模型——其引入确定性采样路径, 能以更少步骤实现更快的样本生成; 另一种变体则对梯度进行建模³⁰; 还有更广泛的推广方式将过程置于连续时间框架下, 从而发展出基于评分函数的模型, 通过求解随机微分方程 (SDE) 将噪声转化为数据³¹。

大型语言模型 (LLMs)。最后一类涉及LLMs³²⁻³⁴, 这些模型通常基于晶体学数据进行微调。需要特别强调的是, 这类模型并非独立的架构类别: 它们本质上都基于Transformer架构。LLMs的核心区别在于其训练范式——首先在海量通用文本语料库上对大型Transformer模型进行预训练, 随后针对特定科学领域进行微调。

由于材料科学领域的许多生成方法均直接使用预训练LLMs而未修改底层架构, 我们将其单独列为章节以突出这一特征。

其核心思想是将结构信息视为一种语言形式。研究人员使用CIFs (简化的分子输入行输入系统, 简称SMILES) 或其他原子结构的文本表示形式作为训练数据。随后, 大型语言模型 (LLM) 在该数据集上进行微调, 使其习得的语言处理能力能够理解晶体结构的“语法”与“词汇表”——即支配对称性、原子排列方式及化学键形成的规则。通过以生成有效的基于文本的结构描述为具体目标对模型进行再训练, 它便能学会生成新颖的CIFs或其他可进一步被机器或人类解读为具有物理合理性材料的表征形式。

代表; 形象; 象征

构建材料的概率分布 $p(\mathbf{x})$ 需要为变量 $\mathbf{x}$ 提供合适的表示形式。与监督学习中仅需简单描述符 (如平均质量或体积) 即可满足需求不同, 生成建模要求使用可逆表示——这种表示需完整保留所有结构/化学信息, 并能根据其表示形式精确重建材料。

理想情况下, 表示应对平移、旋转和置换具有不变性。然而, 这些不变性并非严格要求, 因为数据增强技术有助于模型学习此类对称性^{35,36}。下文我们将总结晶体生成式AI模型中使用的主要可逆表示方法。

点云或 AXL。描述晶体结构最直接的方法之一是将其表示为 $\mathbb{R}^3$ 中的点集合, 其中每个点对应一个实际原子。晶胞中全部 N 个原子的集合可表示为 $\{s_i, (x_i, y_i, z_i)\}_{i=1}^N$, 其中 s_i 和 (x_i, y_i, z_i) 分别表示第 i 个原子的化学种类及其笛卡尔坐标。接下来, 通过引入晶格 L 来描述晶胞的周期性特征, 该晶格通常由晶格矢量 $(\mathbf{a}, \mathbf{b}, \mathbf{c})$ 的长度以及晶格矢量之间的夹角 (α, β, γ) 定义。因此, 完整的表示形式为 $P = \{s_i, (x_i, y_i, z_i)\}_{i=1}^N, (\mathbf{a}, \mathbf{b}, \mathbf{c}, \alpha, \beta, \gamma)$ 。在文献中, 这种表示法也常被称为 (A, X, L) 表示法: 其中 A 代表晶种, X 代表坐标, L 代表晶格。该表示法具有可逆性 (符合要求), 因为给定任意 (A, X, L) 参数值时, 均可重建对应的晶体结构。

就对称性而言, 该表示法明确指定了原子种类和位置, 但并未直接编码除平移周期性之外的点群或空间群对称性。平移对称性通过晶格参数体现, 因为晶格矢量的长度和角度隐式地定义了底层晶体系统。

体素网格。体素网格表示法将晶体的三维空间离散化为规则的体素网格, 类似于三维图像。网格中的每个体素都存储一个数值, 用于反映该区域内原子的存在情况或密度分布。因此, 原子被表示为连续函数 (通常为高斯函数), 其中心位于晶胞内的分数坐标 (即简写坐标) 处, 从而实现对原子位置的平滑呈现。对于含多种化学成分的材料, 体素网格可设置多个通道, 每个通道专门对应特定元素。网格分辨率是关键超参数, 决定了模型表征的细节程度及计算成本。晶体晶格本身可通过对标准晶胞施加变换来编码: 例如, 可在晶胞内生成以晶胞为中心的高斯函数, 再根据晶格参数 $(\mathbf{a}, \mathbf{b}, \mathbf{c}, \alpha, \beta, \gamma)$ 将其转换为立方体网格。这种表示方式使模型能够处理类图像的三维数据并有效利用卷积运算。由于其灵感天然源自图像处理领域, 体素 (voxel) 成为晶体生成式AI模型中最早使用的表示方法之一。

与原子坐标表示法类似，体素网格并未显式编码晶体对称性（除平移周期性外），而该对称性通过晶格变换被隐式包含。

图。图表示法将晶体结构编码为多重图 $G = (V, E)$ ，其中每个节点 $v_i \in V$ 对应一个原子，每条边 $e_{ij} \in E$ 表示原子 i 与 j 之间的相互作用或化学键。节点通常标注有元素特征（如原子序数、电负性等），而边则常包含距离（键长）或键类型信息。可选地，还可添加次级及更高层级的图来捕捉高阶相互作用（如键角）。与点云或体素表示不同，图本身不具备可逆性且会丢失精确几何信息，因此不适合作为生成模型的独立表示形式；通常需与点云表示结合使用，在生成过程中迭代更新原子位置。

图表示法并未明确编码晶体学对称性，因为它仅捕捉局部原子连接关系，而未参考完整的空间群。此外，图结构通常并不适用于表示晶胞参数³⁷。然而，尽管现代基于图的模型并未显式纳入晶体对称性，但大多数此类模型的设计目标都是在其消息传递框架内强制满足欧几里得变换（平移、旋转和反射）下的不变性或等变性。

互易空间。互易空间表示法利用晶体原子位置的傅里叶变换来描述周期性及长程有序性。该框架中的核心量是结构因子 $F(h, k, l)$ ，其定义为：

$$F(h, k, l) = \sum_j f_j e^{-2\pi i(hx_j + ky_j + lz_j)}, \quad (8)$$

where f_j 表示原子 j 的原子散射因子（或形状因子），而 (x_j, y_j, z_j) 为相应的分数坐标。在实际应用中，散射因子可被学习得到的元素嵌入向量替代或补充，且该求和运算可分解为多个通道进行计算。

为确保可逆性，由参数 $(a, b, c, \alpha, \beta, \gamma)$ 定义的直接晶格 L 必须与结构因子集合一同编码。利用 L 的相关信息，逆傅里叶变换即可从倒易空间表示中唯一地重构周期性位置及晶体结构。

这种表示方法本质上包含了晶体学对称性，但并未将其显式呈现。平移对称性表现为倒易晶格点的离散周期性；点群对称性和空间群对称性则体现为等效结构因子之间的系统性关联或系统的缺失现象（消光规则）。因此，对称性信息蕴含于傅里叶系数的分布模式中，而非显式的对称算符之中。

惠克夫位置。该表示法基于晶体学信息编码了晶体结构。晶体中的每个原子均被分配一个惠克夫位置，即在晶体空间群内定义的一组对称等价点。在三维晶体学中，共有 230 个空间群，对应 1771 个不同的惠克夫位置。

一个维科夫位点由其多重度和标记（例如 4a、4b、8c 等）、对应的空间群以及所有自由参数共同确定。这些参数定义了不对称单元内代表性点的坐标，而空间群的对称操作则生成完整的对称等价原子位置集合。结合原子占据情况（即哪些原子占据哪些维科夫位点）与晶格参数信息，即可唯一重建完整的晶体结构。

与以往的表示方法不同，Wyckoff 形式体系明确地通过空间群及其运算来编码晶体学对称性。所有等效原子位点均通过应用这些

对称操作从单一不对称单元生成，从而消除冗余，并为晶体提供一种紧凑且符合对称性的描述。

条件生成

材料发现领域的许多应用都需要从形式为 $p(\mathbf{x} | \mathbf{c})$ 的条件分布中采样，其中 $\mathbf{c}$ 表示特定约束条件或目标属性（例如所需的化学组成、空间群对称性，或电子带隙、热膨胀系数、超导转变温度等功能特性）。因此，条件模型能够定向生成不仅结构合理且针对特定应用优化的材料。经过适当训练后，这类模型可识别出最可能呈现所需特性的结构（如图 1（3b）、（4b）所示）。本质上，条件建模通过参数化条件变量 $\mathbf{c}$ 来调控生成过程，使得采样 $\mathbf{x} \sim p_\theta(\mathbf{x} | \mathbf{c})$ 能得到具有理想性能的结构。

实际上，条件化处理可根据底层生成架构的不同，通过多种通用机制实现。下文将概述这些基础策略以构建概念框架；采用这些技术的具体模型将在“分类学”章节中详细讨论。

直接输入增强。最常见的方法是通过引入条件变量 $\mathbf{c}$ 来增强模型输入。该条件变量以标量、向量或独热编码形式表示，并被拼接或以其他方式注入到潜在变量、中间特征或输入标记中。

在变分自编码器（VAE）中，编码器和解码器均被扩展以包含条件信息。

$$q_\phi(\mathbf{z} | \mathbf{x}, \mathbf{c}), \quad p_\theta(\mathbf{x} | \mathbf{z}, \mathbf{c}) \quad (9)$$

从而使潜在表示 $\mathbf{z}$ 明确编码目标属性。在生成对抗网络（GAN）中，生成器与判别器均受到条件约束。

$$G(\mathbf{z}, \mathbf{c}), D(\mathbf{x}, \mathbf{c}) \quad (10)$$

对于基于变换器的架构，可通过在输入序列前添加特定条件标记（例如带隙 = 3 eV）或通过交叉注意力层注入条件信息来实现条件化处理。这定义了一个自回归条件分布：

$$p_\theta(\mathbf{x} | \mathbf{c}) = \prod_{i=1}^N p_\theta(\mathbf{x}_i | \mathbf{x}_{<i}, \mathbf{c}), \quad (11)$$

对于扩散模型和流场匹配模型，该条件被嵌入到评分或矢量场网络中。

$$\epsilon_\theta(\mathbf{x}_t, t, \mathbf{c}), \quad f_\theta^{-1}(\mathbf{x}, \mathbf{c}), \quad (12)$$

通常与无分类器引导方法结合使用。该方案同时训练条件模型和非条件模型，并在推理过程中混合使用以控制条件效应强度：

$$\epsilon_{\text{引导}} = \epsilon_{\text{uncond}} + s(\epsilon_{\text{条件}} - \epsilon_{\text{非条件}}), \quad (13)$$

其中 $s > 1$ 为引导尺度。

最后，大语言模型（LLM）框架通过明确描述所需属性的文本提示来实现条件化处理，这可视为一种基于文本的输入增强方法。

条件潜在先验。条件潜在先验提供了一种替代方法，通过根据目标属性来塑造潜在空间本身，从而纳入属性约束。与其从固定的无条件先验分布 $p(\mathbf{z})$ 中采样，不如学习条件先验 $p_\theta(\mathbf{z} | \mathbf{c})$ ，使得从该分

表 1 | 用于训练生成模型的常见无机晶体数据集

数据集	描述	尺寸	URL	许可证
材料项目 ⁴⁰	经密度泛函理论优化的无机晶体 (PBE GGA / GGA +U), 包括实验结构与假设结构	155K	https://materialsproject.org	CC 作者: 4.0
亚历山大 ^{42,43}	经过大规模DFT优化的无机晶体, 兼容MP设置	4.5M	https://alexandria.icams.rub.de	CC 作者: 4.0
ICSD ⁴¹	经实验确定的无机晶体结构; 该子集已纳入MP数据库	300K	https://icsd.fiz-karlsruhe.de	商业 (受限)
AFLOWLIB ⁴⁷	自动化高通量材料性质DFT数据库	3.5M	http://afowlib.org	仅限学术使用
OQMD ⁴⁸	DFT数据库专注于热力学稳定性和相图研究	1.3M	http://oqmd.org	CC 作者: 4.0
耶尔维斯 ¹³⁰	包含使用PBEsol、OptB88vdW和TbmbJ方法计算出的性质的DFT数据库	80K	https://jarvis.nist.gov	开放获取 (工具使用需授权 MIT)

布中抽取的潜在编码 z 很可能被解码为满足所需属性 c 的结构。

在实际应用中, 这一过程通常分为两个步骤: 首先, 训练一个标准生成模型 (如 VAE) 来对结构进行编码与解码; 其次, 另建一个独立模型将属性向量 c 映射至潜在空间。通过从该学习得到的条件先验分布中采样, 可使生成结果偏向对应目标属性的区域。然而该技术相对少见, 因为对于复杂或高维的潜在空间而言训练难度较大, 且条件先验分布可能无法完全涵盖给定属性的所有可行结构。

通过属性预测实现潜在优化。另一种联合策略

该方法在生成模型中同时训练属性预测器 $F_\psi(z)$, 促使潜在变量与目标属性之间建立平滑且单调的关系。这使得通过梯度上升法在潜在空间中实现连续优化成为可能:

$$z_{t+1} = z_t + \eta \nabla_z F_\psi(z_t), \quad (14)$$

其中 η 为步长。解码中间潜在点可生成一系列晶体结构, 其目标属性值逐渐增大。一个有效的补充措施是采用保守正则化方法, 以防止“潜在黑客效应” (即由过度拟合的属性预测模型导致的非物理外推现象)。

奖励引导型。另一类条件化策略依赖于强化学习或奖励引导生成方法。在此方法中, 奖励函数或能量函数 $R(x, c)$ 用于量化生成结构满足目标属性的程度。随后训练生成模型根据该奖励函数生成样本: 要么通过最大化期望奖励 (如标准强化学习方法), 要么按照基于奖励分布的比例进行采样 (如基于 GFlowNet 的方法)。

$$p_\theta(x|c) \propto R(x, c). \quad (15)$$

该公式允许将任意属性预测因子和约束条件灵活地纳入生成过程。一个实际局限在于, 对于每个不同的条件化目标 c , 通常都需要对模型进行重新训练。

约束数据训练。最后一种在概念上较为简洁的方法是: 直接在仅包含满足目标属性 $D(x|c)$ 的结构的数据集上对生成模型进行训练或微调。该策略适用于所有生成架构, 并能在无需显式条件约束的情况下隐式学习概率分布 $p(x|c)$ 。与奖励引导生成方法类似, 针对每个目标属性均需使用独立的模型或进行专门的微调。

综上所述, 目前存在多种条件建模策略, 包括直接输入增强、条件性隐式先验、隐式优化、奖励引导训练以及约束数据训练。如“分类学”章节进一步讨论所示, 最新模型主要依赖直接输入增强技术, 并通常在较小的特定属性数据集上进行微调。强化学习和隐式优化虽应用尚不广泛但前景广阔——它们能够整合

外部属性预测因子, 具备更强的泛化能力、更优的正则化效果, 并可在主动学习循环中实现训练。总体而言, 材料条件生成建模仍处于早期阶段, 现有研究仅针对有限的目标属性展开探索。将这些方法扩展至更广泛的物理与功能约束条件 (包括多目标优化或帕累托导向优化) 将成为未来研究的重要方向。

数据来源

除了架构选择 (如 VAE、GAN) 和结构表示方式外, 获取高质量训练数据至关重要。此类数据通常包含低能量、热力学稳定的晶体结构, 并从基础分布 $p(x)$ 中采样获得。表 1 汇总了该领域的关键资源。

在实际应用中, 大多数数据集均基于广义梯度近似 (GGA) 水平的密度泛函理论 (DFT) 计算³⁸, 通常采用 Perdew、Burke 和 Ernzerhof (PBE) 泛函³⁹。生成晶体结构及其预测性质的准确性从根本上受限于基础 DFT 训练数据的精确性——因为模型会自然地反映出训练数据集中所使用的密度泛函近似的优缺点。此外, 由于 DFT 计算随体系尺寸增大而性能显著下降, 所有大规模材料数据集本质上都偏向于包含小于 20-30 个原子的小单元胞结构。尽管存在例外情况 (如某些复杂氧化物), 但这类案例仅占极小比例。因此必须认识到, 这种偏差会直接影响模型学习到的结构分布特征, 并可能影响模型性能与泛化能力。

一个广泛使用的数据源是材料项目 (Materials Project, 简称 MP)⁴⁰, 该数据库收录了多种基于密度泛函理论优化的无机结构。其中大部分条目源自无机晶体结构数据库 (Inorganic Crystal Structure Database, 简称 ICSD)⁴¹, 并提供了与实验观测化合物的关联链接。通过根据 ICSD 来源对 MP 条目进行筛选, 或设定高于壳层能量阈值 (例如每原子 <80 meV) 来过滤数据, 是一种常见的方法, 可使数据集更偏向热力学稳定或亚稳态相; 不过这种方法并不能严格保证生成化合物的稳定性。

亚历山大数据库^{42,43}显著扩展了现有数据规模, 提供了超过 450 万种在符合 MP 标准的设置下使用 VASP⁴⁴ 计算得到的三维结构。如此庞大的数据量使得基于该数据库训练的 MatterGen⁴⁵ 和 Matra-Genoa⁴⁶ 等生成框架能够显著提升模型质量。

其他重要的资源包括 aflowlib⁴⁷、OQMD⁴⁸ 和 jarvis⁴⁹, 这些工具均专注于高通量密度泛函理论 (DFT) 计算。在此框架下, 值得一提的是 OPTIMADE API——它为用户提供便捷的通用接口, 可访问众多世界领先的材料数据库^{50,51}。支持该 API 的所有数据库完整列表均可在 [optimade 提供商仪表板](#) 上查询。

最后, Xie 等人⁵²为生成模型引入了任务特定数据集, 包括 Perov-5 (一套专为水分解设计的、包含 19,000 种钙钛矿化合物的精确数据集^{53,54}) 以及 Carbon-24 (该数据集通过从头算随机结构搜索方法生成了超过 100,000 种碳同素异形体⁶)。然而,

表 2 | 应用于晶体结构的生成模型分类体系

类别	描述	可能的值
表示	晶体的结构如何？ 以输入/输出格式 进行编码	体素网格
		图维克夫位置
		点云
		互易空间
		等.
架构	核心生成模型框架	变分的 Autoencoder (VAE)
		生成对抗网络 (GAN)
		归一化流
		扩散模型
		Transformer
		经过精细调校的大型语言模型 (LLM)
		等.
调节; 适应	用于指导生成过程的额外 信息	无条件 (无外部约束)
		组成 (元素分数)
		空间群或晶体系统
		带隙 (数值)
		形成能
		目标密度或孔隙率
		等.
材料域	已建模或生成的材料子 集	氧化物、卤化物或任何有 限化学物质
		钙钛矿、立方晶系材料或任何结 构原型
		合金
		所有结构 (无约束)
		等.

生成模型可通过四个关键方面进行区分：晶体数据表示方式的选择、核心模型架构、用于指导材料生成的条件信息，以及目标材料领域（受架构或训练数据限制）。

正如参考文献⁵⁵中最近所讨论的，这些数据集存在一些局限性：训练集和测试集中存在的重复项或多态性结构可能导致基准指标出现误导性结果。

分类学

通过四个关键支柱——表示方法、架构设计、条件设定以及材料领域，可以系统地理解晶体结构生成模型的方法论及其内在运作机制。这些要素共同界定了现有方法的设计空间，并构成了表2和表3中所呈现分类体系的基础。

表示方法定义了晶体结构的编码方式，涵盖点云、体素网格、图结构、倒易空间描述符以及Wyckoff坐标等（如上所述）。这一选择决定了对称性、周期性及原子细节的具体呈现方式。实践中存在多种组合方案，模型通常会同时采用多种表示方法：例如FTCP⁵⁶将倒易空间与实空间特征整合为混合表示；而基于图结构的模型则常与点云结合使用，以迭代优化原子位置。

本文所定义的架构指代基础生成框架，包括生成对抗网络（GAN）、变分自编码器（VAE）、Transformer模型、归一化流、扩散模型以及微调后的大语言模型（LLM）。这些架构能够根据所选表示方式学习晶体结构的底层分布特征。

条件化方法将生成建模从学习无条件分布 $p(\mathbf{x})$ 扩展到学习条件分布 $p(\mathbf{x}|\mathbf{c})$ ，其中 $\mathbf{c}$ 编码目标属性的向量表示。虽然形成能通常被隐式建模，但某些方法会明确基于磁性、电导率或热膨胀等附加属性来指导生成过程。仅当作者明确证明生成过程是基于功能属性进行条件化的时，才标注为“是”；否则则标注为“否”。使用条件化方法时，括号内的数字代表相关机制编号（具体编号参见“预备知识”小节中的“条件化生成”部分）。

材料领域定义了模型可作用的范围，既体现了其架构设计特征，也反映了训练数据特性。该范围可能受化学成分（如氧化物、卤化物）、结构原型（如钙钛矿、立方晶系材料）或其他子领域（如合金或二维材料）的限制。然而，由于训练数据存在保真度不足、对较小晶胞单元的偏好以及其他固有偏差等问题（详见“数据来源”部分），模型在整个材料领域的实际性能无法得到保证。

图3展示了分类体系的前两个维度——架构与表示方式——如何构建一个用于组织现有模型的独立空间，从而直观地概括当前领域的发展现状。

以下章节将详细综述这些模型，并根据其共同的架构设计与表征策略将其归类为若干通用子章节。

生成对抗网络（GANs）与变分自编码器（VAEs）

受图像生成领域取得的成功启发，材料科学领域的早期生成模型采用了类似技术。基于体素表示的GAN和VAE模型成为晶体结构生成的首批方法。这些模型将三维原子排列视为类图像密度网格，并将其压缩至连续的潜在空间中以采样新结构。

Hoffman等人⁵⁷构建了位于10 Å立方体内的结构模型，该立方体被离散化为30 × 30 × 30的网格。每个体素均包含基于以原子为中心的高斯分布计算得出、并按原子序数缩放的密度值。随后采用U-Net架构对该密度网格进行分割以确定原子位置。尽管采用了数据增强技术并在MP数据库上取得了较高准确率，该模型仍难以生成物理结构稳定的三维模型。

iMatGen⁵⁸扩展了体素方法，采用分数坐标及独立网格来表示晶胞（使用变换后的高斯分布）。通过分层两步VAE将材料参数编码至潜在空间。基于通道的设计原理使得该模型可扩展应用于其他化学体系。

ICSG3D⁵⁹采用基于体素化电子密度网格及高斯密度求和的方法来表征晶体结构。该方法利用三维U-Net进行分割以重建原子坐标，并在VAE的潜在空间中附加能量值的一热编码以控制形成能参数。通过在立方二元合金、三元钙钛矿及赫斯勒化合物上训练，ICSG3D展现出对已知结构间的插值能力——例如可通过遍历潜在空间来改变钙钛矿周期序列中A位元素的组成。

ccdcgan⁶⁰提出了一种两阶段方法：首先训练VAE生成结构化的潜在空间，该空间随后作为GAN的输入。该框架将构型能量预测器直接纳入损失函数中，促使生成器通过在潜在空间中寻找能量最低值来生成低能量结构。该研究后续被扩展应用于多组分系统⁶¹。

虽然基于体素的方法占据主导地位，但文献中也存在采用其他表示方法的生成对抗网络（GAN）。例如，CrystalGAN⁶²和GANCSP⁶³直接作用于原子坐标点云数据，其中后者还能对晶体结构组成进行条件化处理。近期的研究进一步优化了体素概念以提升效率：以Uni-3DAR⁶⁴为例，该方法采用八叉树压缩的体素表示法将三维结构转化为紧凑的标记序列，随后通过自回归变换器对这些标记序列进行处理，从而快速生成新的晶体结构样本。

表3 | 根据所提出的分类法在文献中发现的生成模型汇总

缩写词	表示	架构	条件。	领域	Ref.	年
CrystalGAN	点云	GAN	不	氢化物	62	2019
DD3DCS	三维像素	GAN	不	所有结构	57	2019
CondGAN	原子袋	GAN	是 (1)	组合; 构成; 组成	139	2019
iMatGen	体素网格	VAE	不	钒氧化物	58	2019
MatGAN	独热元素	GAN	是 (5)	组合; 构成; 组成	140	2020
GANCSP	点云	GAN	是 (1)	所有结构	63	2020
ICSG3D	三维像素	VAE	是 (1)	立方合金、钙钛矿、赫斯勒化合物	59	2020
CubicGAN	点云	GAN	是 (1)	立方结构	123	2021
CCDCGAN	体素网格	VAE, GAN	是 (3)	双硒材料	60	2021
FTCP	互易空间, 点云	VAE	不	所有结构	56	2022
CDVAE	点云、图	VAE、扩散	是 (3)	所有结构	52	2022
CCDCGAN	体素网格	VAE, GAN	是 (3)	所有结构	61	2022
PGCGM	威科夫	GAN	不	Temaries	83	2023
XYZTransformer	点云	LLM	不	所有结构	91	2023
PCVAE	组成, 原型	VAE	不	原型; 样机	141	2023
LCOM	图表、点云	VAE、扩散	是 (3)	所有结构	65	2023
CHGlowNet	图	GFlowNet	不	所有结构	109	2023
SLI2Cry	图表 (切片)	RNN	不	所有结构	110	2023
SyMat	图表、点云	扩散	不	所有结构	66	2023
晶体 GFN	原型机 (太空集团)	GFlowNet	是 (4)	结构原型	108	2023
GemsDiff	图表、点云	扩散	不	所有结构	67	2023
CGMD	点云	扩散、VAE、流场匹配	不	所有结构	111	2024
DP-CDVAE	点云、图	扩散	不	所有结构	68	2024
CrysTens	点云 (成对距离)	GAN, 扩散	不	所有结构	112	2024
CrystalTextLLM	点云	LLM	是 (1)	所有结构	92	2024
DiffCSP	点云、图	扩散	不	所有结构	69	2024
DiffCSP++	威科夫	扩散	不	所有结构	70	2024
共 CDVAE :	点云、图	VAE、扩散	是 (2)	所有结构	71	2024
NSGAN	组成向量	GAN, GA	不	合金	113	2024
UniMat	点云	扩散	是 (1)	所有结构	81	2024
FlowMM	点云 (平直流形)	流匹配	不	所有结构	104	2024
StructRepDiff	嵌入原子密度	扩散	不	所有结构	142	2024
晶体前体	威科夫	Transformer	是 (1)	所有结构	88	2024
VGD-CG	成分: 单热源	遗传算法、VAE、扩散	是 (1)	组合; 构成; 组成	115	2024
LCMGM	互惠空间	VAE, GAN	不	钙钛矿	143	2024
GenMS	点云	LLM, 扩散	是 (1)	所有结构	99	2024
WyCryst	威科夫	VAE	是 (3)	所有结构	84	2024
材料专家	点云 (对话式)	LLM	是 (1)	所有结构	100	2024
FlowLLM	点云 (平直流形)	LLM, 流匹配	是 (1)	所有结构	105	2024
康德 CDVAE	点云、图	VAE、扩散	是 (1)	所有结构	72	2024
CrystaLLM	CIF 文件	LLM, Transformer	是	所有结构	95	2024
CrysText	CIF 文件	LLM	是 (1)	所有结构	96	2024
CGWGAN	威科夫	GAN	不	所有结构	86	2024
马特拉-热那亚	威科夫	Transformer	是 (1)	所有结构	46	2025
EH-差分	超图, 点云	扩散	不	所有结构	73	2025
CrysBFN	点云 (超环面)	贝叶斯定理的	不	所有结构	106	2025
TransVAE-CSP	图表、点云、RBF	VAE、扩散	不	所有结构	74	2025
晶体流动	图表、点云	连续归一化流	是 (1)	所有结构	144	2025
MatLLMSearch	文本 (JSON)	LLM, 进化搜索	是 (3)	所有结构	101	2025
Mat2Seq	不变序列	LLM	是 (1)	所有结构	102	2025

表3（续） | 根据所提出的分类法在文献中发现的生成模型汇总

缩写词	表示	架构	条件。	领域	Ref.	年
物质生成	点云、图	扩散	是 (1)	所有结构	45	2025
TGDMat	点云, 上下文	扩散	是 (1)	所有结构	75	2025
自然LM-Mat3D	点云	LLM	是 (1)	所有结构	103	2025
CrystalGRW	图, 流形	测地线随机游走	是 (1)	所有结构	79	2025
UniGenX	点云	变压器, 扩散	是 (1)	所有结构	82	2025
DAO-G	图表、点云	扩散 (EBM)	不	所有结构	77	2025
Uni-3DAR	体素 (压缩)	Transformer	不	所有结构	64	2025
Chameleon	图表、点云、文本	扩散, 对比学习	是 (1)	所有结构	76	2025
SymmCD	维科夫 (二进制矩阵), 图	扩散	不	所有结构	89	2025
WyckoffDiff	维科夫图	扩散	不	用于构建结构的参数	90	2025
KLDM	流形, 图	扩散	不	所有结构	80	2025
OMatG	点云、图	随机插值法	不	所有结构	116	2025
CHGGen	点云、图	扩散 (带修复功能)	不	所有结构	78	2025

有关“表征”、“架构”和“条件化”的定义, 请参见表2及正文。仅当作者明确证明生成过程是基于功能属性进行条件化的时, 才将条件化标记为“是”。括号内的数字表示条件化机制的编号, 具体对应“预备知识”章节中“条件化生成”小节中的编号。




图 3 | 二维架构表示空间中模型分类体系的示意图。该空间为离散结构, 以虚线标示; 部分模型位于交叉点处, 融合了多种架构。主要类别以彩色气泡标出, 反映了其历史演变特征。

已确立具有显著贡献的分类方法: 基于点云或体素的生成对抗网络 (蓝色)、图扩散模型 (红色)、基于点云的大型语言模型 (绿色) 以及基于点云的归一化流模型 (黄色)。与指定类别存在架构差异的模型均用 (*) 标注, 详见表3。

基于扩散的模型

2021年, 谢等人⁵²提出了用于周期性材料生成的晶体扩散变分自编码器 (CDVAE)。该模型此后成为后续多种基于扩散方法迭代发展的基础。原始生成流程始于编码器——即将材料映射至潜在空间的周期图神经网络 (PGNN); 基于此潜在表示, 模型可预测材料成分、晶格参数及原子数量, 从而构建初始结构。随后, 扩散解码器通过执行朗之万动力学过程来优化这一初始结构, 同

时对原子坐标进行去噪并更新原子类型; 噪声条件评分网络则指导去噪过程, 该网络采用另一个 PGNN 来估计不同噪声水平下概率密度的梯度, 并明确考虑周期边界间的相互作用。CDVAE 通过SE(3)等变图神经网络保持了置换、平移和旋转不变性, 但在去噪过程中未能实现平移不变性。然而, 基准评估表明, CDVAE 在材料生成方面实现了较高的有效性和覆盖率。

基于 CDVAE 架构, 研究人员开发了多种扩展模型。Qi 等人提出了 LCOM⁶⁵, 该模型通过引入替代性保守模型来最小化潜在空间中的形成能, 从而扩展了 CDVAE 框架; 同样地, SyMat⁶⁶ 框架沿用了 CDVAE 架构, 并进一步增强了其对平移变换的不变性; Klipfell 等人开发的 GemmsDiff 模型⁶⁷也采用了等变图神经网络 (GNN), 进一步拓展了 CDVAE 框架——与原始 CDVAE 在 VAE 后固定晶格参数不同, 该模型允许晶格参数在扩散过程中动态演化。

另一种变体 DP-CDVAE⁶⁸ 通过用 DDPM 替换其评分网络来改进 CDVAE 模型。这一改进使得该模型生成的结构相较于原始 CDVAE 模型能更接近其基态。Jiao 等人提出了 DiffCSP⁶⁹, 该方法采用周期性 E(3) 等变去噪模型对晶格参数和约化坐标同时进行联合扩散处理。与 CDVAE 不同, DiffCSP 从随机初始化的先验分布结构出发, 无需依赖 VAE。该模型展现出优异的有效性和覆盖范围。其后续版本 DiffCSP++⁷⁰ 进一步结合晶体对称性, 通过将扩散过程限定于特定空间群来实现。Con-CDVAE⁷¹ 则将 CDVAE 扩展至基于用户定义属性 (如带隙、形成能及晶体系统) 的条件晶体生成领域: 它在潜在变量中引入属性嵌入, 并构建基于扩散的先验网络以学习生成符合目标属性的潜在向量。Cond-CDVAE⁷² 还将 CDVAE 扩展至条件生成领域, 使其能够同时基于化学组成和外部压力进行预测。通过结合 MP 数据集与高压 Calypso CSP 数据进行训练, Cond-CDVAE 可通过向潜在空间和朗之万动力学中注入条件向量, 在用户定义的条件下生成晶体结构。

MatterGen⁴⁵ 进一步改进了 CDVAE 架构: 完全移除了 VAE 机制 (与 DiffCSP 类似), 并采用涵盖原子类型、坐标及晶格参数的全联合扩散过程。因此, MatterGen 能够在生成过程中动态调整晶格结构。相较于在笛卡尔坐标系中施加高斯噪声, MatterGen 采用包裹正态分布函数在分数坐标系中进行扩散, 这种设计天然符合周期性特征且能适应不同晶胞结构。与早期扩散模型相比, MatterGen 还采用了更大的训练数据集, 并通过在评分网络中嵌入轻量级适配器模块实现条件化生成功能——无需重新训练整个模型即可实现对材料属性的精准控制。

近期的研究探索了多种架构改进方案。EH-Diff⁷³ 采用超图替代图表示法, 通过边连接两个以上原子, 更准确地捕捉多原子相互作用; TransVAE-CSP⁷⁴ 沿用了 CDVAE 的建模方法, 但通过引入具有等变点积注意力机制的 Transformer 增强编码器性能; TGDMat⁷⁵ 结合原子类型、分数坐标及晶格结构的联合扩散机制, 并采用周期性 E(3) 等变去噪模型, 同时整合文本信息以引导用户自定义提示下的生成; Chemleon⁷⁶ 同样融入了文本描述符, 通过对比学习训练文本与结构数据的嵌入向量, 进而应用于扩散过程, 实现仅需 “LiMnO₄ 具有正交晶系结构” 等简单提示即可进行材料采样; DAO⁷⁷ 则通过将能量因素纳入扩散路径, 采用双模型实现扩散计算, 并在非稳定结构上进行预训练以提升模型性能。CHGGen⁷⁸ 提出了晶体宿主引导的图像修复生成方法, 通过将扩散过程约束于对称化的宿主结构上, 以缓解基于图模型中的局部性偏差, 从而提升对称晶体的生成效果。

其他几何方法提供了不同的研究视角。CrystalGRW⁷⁹ 提出了基于流形定义的扩散机制——即使用环面表示坐标系、单纯形表示原子类型, 并采用测地线随机游走而非欧几里得高斯噪声。该方法更符合晶体表征的自然几何结构。受物理朗之万动力学启发, KLDM⁸⁰ 采用流形来表征晶体结构, 但将扩散过程应用于相

关欧几里得空间中的辅助速度变量。这种方法既避免了在曲面流形上直接进行复杂扩散计算, 又保持了几何约束条件。

另一方面, UniMat⁸¹ 提出了一种通用表示方法: 将材料编码为类似元素周期表形状的点云结构, 并在其上应用基于 DDPM 的扩散机制。与 CDVAE 相比, 该方法生成的结构具有更低的分解能。值得注意的是, 扩散机制已成功融入 Transformer 架构中——例如, UniGenX⁸² 通过 Transformer 解码器自回归地生成元素类型 (即化学式), 同时利用应用于 Transformer 后续标记嵌入的扩散头来优化原子坐标。这种混合设计在组合约束和结构约束方面均提供了良好的可控性。

基于 Wyckoff 描述符的模型

最早将对称性信息融入生成模型的研究之一是赵等人⁸³ 提出的 PGCGM 方法。该方法采用仿射矩阵表示对称操作, 并为每组等效位点编码单一分数坐标, 从而在生成过程中隐式保持对称性。研究采用了 GAN 架构, 并结合了受物理原理启发的损失函数: 具体包括基于原子间/原子内距离的损失函数、符合对称性的损失函数以及全坐标平均损失函数。不过该方法仅适用于三元体系, 但很可能可扩展至更复杂的化合物结构。

基于 Wyckoff 位点的应用原理, WyCryst⁸⁴ 模型将这些位点编码为独热矩阵 (即 Wyckoff 基因), 并通过 VAE 函数将其嵌入潜在空间。该潜在空间由属性预测分支引导构建, 确保其结构沿属性梯度分布以实现目标采样。虽然这种方法实现了对称性感知与属性驱动的生成机制, 但模型并未直接学习分数坐标; 因此需要借助 PyXtal⁸⁵ 进行额外步骤来启发式估算这些坐标。

另一种相关方法是由 Su 等人⁸⁶ 提出的 CGWGAN⁸⁶ 提出的, 该方法同样采用了 Wyckoff 描述符, 但采用了两步生成流程: 第一步利用 AGAN 生成由不对称单元、空间群和晶格矢量定义的晶体模板; 第二步在监督力场模型 (具体为 M3GNet⁸⁷) 指导下将原子填充至这些模板中, 以评估其热力学与机械稳定性。

近年来, 曹等人提出了 CrystalFormer⁸⁸——一种仅包含解码器的 Transformer 模型, 该模型通过基于空间群条件采样 Wyckoff 描述符来生成晶体结构。该模型能够迭代预测 Wyckoff 位点、分数坐标和晶格参数, 在保持对称性一致性方面优于早期方法的同时, 实现了较高的准确性和多样性。De Breuck 等人⁴⁶ 的平行研究则提出了 Matra-Genoa——一种自回归 Transformer 模型, 它基于 Wyckoff 位置 (包括离散位点和连续自由坐标) 将晶体结构编码为完全可逆的序列表示。经过对超过两百万个晶体结构的训练后, Matra-Genoa 还能通过在训练过程中显式引入与凸包距离相关的稳定性标记, 实现对热力学稳定性的条件约束。与 CrystalFormer 相结合, MatraGenoa 首次实现了离散 Wyckoff 信息与连续位置数据的整合。

最后, Wyckoff 描述符也可通过其他类型的结构模型 (如扩散法) 得到充分利用。SymmCD⁸⁹ 利用扩散法学习了非对称晶胞及其对应对称操作的联合分布, 将晶体编码为一组简化的晶体学轨道集合, 并采用二元对称表示法; 该方法还能根据空间群和轨道数量进行条件化处理, 最终生成包含原子坐标的完整三维结构。WyckoffDiff⁹⁰ 同样采用扩散法, 但仅作用于 Wyckoff 坐标点——从所有位置出发, 通过扩散元素分配生成由空间群和 Wyckoff 字母定义的原初结构。与 WyCryst 类似, 仍需额外的启发式步骤才能获得相应的分数坐标。

基于大型语言模型 (LLMs) 的模型

最早将大语言模型应用于XYZ、CIF和PDB等结构数据文件的研究之一，由Flam-Shepherd与Aspuru-Guzik⁹¹完成。他们从零开始训练了一种类似GPT的Transformer架构，并采用下一个词预测机制而非微调现有语言模型。尽管这使得他们的工作也可归类为“Transformer”方法，但其核心在于证明大语言模型无需依赖复杂的领域特定表示即可直接生成新颖且有效的晶体结构。这一开创性成果激发了后续利用更先进的大语言模型直接从文本格式建模晶体结构的研究。Gruber等人提出了CrystalTextLLM⁹²——该模型基于晶体的文本点云描述对Llama 2-70B⁹³进行微调。该模型将数值以位元为单位进行分词处理，使语言模型能够有效处理这些数据。这种设计支持灵活的文本条件生成，并允许用户使用诸如“以下为某种块状材料的描述[化学式为Pm₂ZnRh]”等指令提示模型。生成晶格矢量的长度与角度描述，以及晶格内每个原子的元素和坐标信息。该模型还通过屏蔽输入数据的部分区域并提出替代方案来实现填充处理，为用户提供了灵活的操作框架。

Antunes等人通过从头训练一个基于LLaMA的⁹⁴语言模型(CrystalLLM⁹⁵)来探索CIF生成。给定化学式及公式单元数量后，该模型能够逐词预测完整的CIF结构，并成功生成包括钙钛矿、尖晶石、沸石及金属有机框架等多种结构类型。

Mohanty等人提出了CrysText⁹⁶，该模型将CrystalLLM生成的CIFs表示与CrystalTextLLM的预训练大语言模型方法相结合。通过使用经过QLoRA⁹⁸微调的Llama 3.1-8B⁹⁷模型，CrysText在保持基于自然语言提示的大语言模型条件化灵活性的同时，成功学习了晶体学参数之间的关系。

超越直接生成化学结构式(CIF)的传统方法，GenMS⁹⁹提出了一种分层化方案：首先利用大语言模型(LLM)根据自然语言描述预测合理的中间化学结构式；随后基于这些结构式，通过扩散模型生成详细的三维原子结构。这种两步流程不仅优于传统的提示式CIF生成方法，还能生成具有更高合理性、更低形成能且更符合用户需求的结构模型。

其他研究则致力于提升基于大语言模型的晶体生成系统的自主性。丁等人开发了MatExpert¹⁰⁰——一种对话式多步骤智能体系统，其运行流程始于用户定义的材料属性要求。该系统首先通过对比学习从预嵌入数据库中检索相似材料，随后由微调后的大语言模型提出优化改进建议以提升目标材料特性。例如，系统可能建议：“用钠原子替代镁原子，因其与硫原子的配位方式不同，可形成具有边缘共享与角共享几何结构混合特征的NaS₆八面体”。这种设计不仅能够生成最终晶体结构，还能阐明改变化学原理，显著提升了操作过程的透明度。

近期其他研究方法进一步证明了基于大语言模型(LLM)的晶体生成技术具有强大的通用性。MatLLMSearch¹⁰¹研究表明，大语言模型无需微调即可提出新颖的晶体结构。该方法将大语言模型与进化搜索相结合：给定两个母体结构后，让模型提出新结构，从而实现隐式交叉和变异操作；随后对提出的晶体结构进行优化、筛选，并重新输入模型进行新一轮演化。另一项研究Mat2Seq¹⁰²提出了将晶体编码为独特且不变的一维序列的系统化方法，从而实现基于语言模型的晶体生成。NatureLM-Mat3D¹⁰³则采用经过微调的Llama 3-8B模型，将晶体表示为元素列表、空间群及坐标组合。该模型在晶体生成方面表现优异，并通过将多个科学领域数据转化为序列形式进行训练，具备更广泛的科学知识基础模型优势。

采用流匹配模型的分析方法

Miller等人提出了FlowMM¹⁰⁴，这是首次将流形建模(FM)技术应用于晶体结构生成。通过在流形上学习反映晶体几何特征与周期性的对称感知向量场，FlowMM采用黎曼流形建模方法高效地同时实现了晶体结构预测(CSP)和从头构建两种生成方式。该方法在准确性和稳定性方面均优于CDVAE、DiffCSP等先前方法，且所需积分步骤显著减少，推断速度最高可达三倍，同时获得相当或更优的结果。作者后续进一步利用大语言模型(LLM)进行基底分布建模¹⁰⁵：该方法首先使用微调后的LLM采样含噪声的材料描述数据，再通过黎曼流形建模进行优化，最终得到的结构稳定性均高于FlowMM。

尽管CrysBFN¹⁰⁶与流式马尔可夫模型(FM)并无直接关联，但其更接近扩散方法；该方法采用了贝叶斯流网络——这类模型通过迭代贝叶斯更新来调整目标分布的参数。同类研究中的另一项成果是CrystalFlow¹⁰⁶，它将连续FM与基于图结构的等变神经网络相结合，并证明了对压力等外部变量进行条件化处理的可能性。

其他模型

在本节中，我们简要提及不属于前述主要分类的研究成果，因为这些研究结合了多种或不同的表示方法与架构。生成流网络(GFlowNets¹⁰⁷)是一种通用的生成建模框架，它通过基于奖励信号训练的策略模型依次采样动作；凭借其能够按奖励分布比例进行采样的特性，GFlowNets能高效探索搜索空间中的多种构型模式，因此成为晶体生成领域极具前景的方法。在此研究方向中，Crystal-GFN¹⁰⁸模型是最早的尝试之一（尽管未能生成完整的晶体结构）。CHGlowNet¹⁰⁹则采用了基于GFlowNet的分层设计来实现晶体生成。

另一种研究方法聚焦于可逆图表示：SH2Cry¹¹⁰提出了基于循环神经网络(RNN)的可逆切片表示方法，并成功实现了晶体生成。其他相关研究包括CGMD¹¹¹，该方法将点云输入与扩散模型、VAE模型及流匹配模型相结合；CrysTens¹¹²将原子坐标转换为基于成对距离的图像化表示，同时应用生成对抗网络(GAN)和扩散模型，其中扩散模型效果更优；NSGAN¹¹³将GAN与作用于铝合金潜在空间的遗传算法相结合；StructRepDiff¹¹³则在基于嵌入原子法¹¹⁴构建的不变描述符空间中运用扩散模型，通过梯度优化重建原子位置以保持对称性。

后续工作涉及VGD-CG¹¹⁵——一种结合了VAE、GAN和扩散算法的成分生成器，其生成过程基于分解焓、可合成性及带隙等特性进行条件化处理。预测得到的成分随后通过模板预测模型转化为具体结构。

最终，OMatG¹¹⁶通过随机插值函数(SIs)统一了扩散模型与流匹配模型，构建了一个灵活的框架，该框架可将随机微分方程(扩散)和常微分方程(流匹配)作为其极限情形纳入其中。

评估指标与基准

评估生成模型是否表现良好需要进行全面的多指标评估。一个真正有效的生成模型不仅应具备发现具有所需特性、稳定且可合成的新材料的能力，还应具备在实际应用中实现这一目标所需的计算效率与可扩展性。

为实现这一全面评估，模型性能的评价既需要基于领域知识的标准，也需要采用数据统计指标。早期模型主要采用有效性指标：当满足特定化学或物理约束条件时，生成的结构即被视为有

效。例如，电荷（氧化态）必须平衡；原子间的最短距离需合理；模型分配给结构的空群必须与对称性分析结果一致。对于成功的模型而言，其有效性率（即具有物理意义的生成结构占比）通常超过90%。然而，这些基于领域知识的有效性检验并不能保证生成结构的稳定性——后续需通过密度泛函理论计算进行更严格的验证。

覆盖率指标通过计算精确率（生成结构中有效且与参考结构匹配的比例）和召回率（成功预测出的参考结构比例），来评估生成材料与参考测试集的一致性。然而，该指标的准确性高度依赖于测试集的选择标准及其完整性。测试集中缺失的结构本身并不构成问题——生成模型需要具备新颖性和创造性——因此该指标存在明显局限性，在我们看来并不总能有效用于模型间的比较。

现实性指标用于衡量真实参考结构与生成结构之间的差异程度。具体而言，可采用参考结构与生成结构之间的均方根偏差（RMSD）来量化这种差异；另一种方法是利用结构匹配算法比较两者的对称性差异；此外，也可使用属性分布（如能量值、体积参数或条件模型的目标值）中的距离度量（例如瓦瑟斯坦距离WD）。然而，这类基于分布的距离度量在比较时存在局限性——微小的改进未必意味着模型质量提升，而仅表明其与参考集的吻合度更高。其他评估指标还包括将生成几何结构优化至局部最小值所需的步骤数，该数值亦可作为距离度量标准。生成结构与真实结构之间的优化路径越短，表明样本在物理层面更具合理性。实际应用中，通常以经密度泛函理论优化的结构或算法匹配的实验结构作为真实参考基准。另一项相关指标是可合成性指标，用于评估在当前实验室条件下合成所生成结构的可行性。然而，由于缺乏大规模、高通量的合成验证数据，可合成性难以标准化。因此，下文所述的能量相关指标通常能提供更为可靠的替代方案。

稳定性指标的出现时间相对较晚，这使得与先前研究进行比较变得困难。这些指标依赖于对生成结构热力学稳定性和/或动力学稳定性的评估。通常，热力学稳定性（相对于竞争相）通过与凸包的距离来表示；一般而言，当结构位于凸包上方某个阈值范围内（例如100 meV/原子）时，即被视为（元）稳定的。要实现动力学稳定性，布里渊区内的谐波声子必须具有实频率。由于基于密度泛函理论（DFT）进行声子计算计算成本高昂，动力学稳定性检验仅在特定情况下应用，例如用于WyCryst模型的基准测试⁸⁴。近年来，随着通用机器学习原子间势（uMLIPs）精度的提升^{117,118}，部分研究人员开始探索在稳定性检验中用uMLIPs替代DFT的可能性⁴⁵。Szymanski和Bartel的最新研究¹¹⁹进一步表明，稳定性结果对所选能量阈值高度敏感（例如0 vs.（在凸包上方100 meV/原子）并主张采用明确的基线方法——如随机枚举法和基于模板的生成法，结合低成本的uMLIP后过滤技术以有效提升稳定性。然而，在生成模型的基准测试研究中，既缺乏统一的阈值标准，也缺乏标准化的参考凸包定义。因此，基于稳定性指标的比较往往并不直接，需谨慎解读。

唯一性指标用于衡量模型生成多样化候选结构的能力。然而，多样性难以量化，在实际应用中通常采用样本的唯一性作为替代指标：若生成结构未与同批次中其他结构重复，则被视为独特结构。另一指标——新颖性指标，则用于衡量生成结构相较于训练集的新颖程度。与判断生成样本是否相互重复的唯一性指标

不同，该指标侧重于评估生成结构是否与固定参考数据集（通常是训练数据集）存在差异。通过对比所有已报道结构，新颖性可表明该化合物属于全新构型；但需谨慎解读其相对于已知结构的新颖性，因为结构匹配算法有时可能失效或错误区分有序构型与无序构型。这一问题已在多项研究^{120–122}中得到强调，因此在宣称新型化合物或新构型时应格外谨慎。”

另一个类似的指标是再发现率，它衡量模型能够从测试集中恢复出结构的比例。对于这些指标而言，用于判断结构匹配度的算法起着关键作用。例如，某些算法会将无序合金的不同有序构型视为独立结构。因此，在比较模型性能时必须充分考虑不同算法之间的差异。此外，这三个指标均与生成批次大小及参考数据集相关：随着批次规模增大，新颖性与独特性比率通常会下降，而恢复率则会上升；但同一批次内，模型可能多次生成相同新结构，导致新颖性高而独特性低。一个成功的模型应能生成稳定、独特且新颖的结构。因此，这三项指标常被整合为S.U.N.指标⁴⁵。

在某些研究中，研究人员会特别关注原型结构——他们要么将生成的晶体结构归类为不同的原型家族，要么识别出全新的原型结构。原型被定义为一类具有完全相同晶体学特征的晶体结构，且其特征与化学组成无关。这种分类通常考虑化学计量比、空间群以及占据的维科夫位点，不过具体标准可能因研究背景而异。基于原型的评估指标能够有效衡量模型探索新结构模式的能力，而非仅仅局限于对已知结构进行化学变体的生成。

效率指标是生成模型实际部署过程中至关重要的实践考量因素。效率涵盖多个维度，包括计算训练成本、数据利用效率、可扩展性等。近期研究表明，不同模型在资源消耗方面存在显著差异，其训练时长会因模型架构和数据集规模的不同而大幅波动。例如，TGDMat在Perov-5和Carbon-24数据集上仅需500个训练轮次即可完成训练，而CDVAE和DiffCSP则需要超过3000个训练轮次⁶⁹。部分方法通过数据整理工作有效降低了计算成本——在某些情况下，这类数据量甚至比训练成本高出数个数量级。当模型应用于大规模化学空间或高通量筛选场景（需生成数千至数百万种候选结构）时，扩展性能显得尤为重要。然而，大多数基准测试仅关注生成质量，而忽视了效率指标。

我们注意到，上述讨论的评估指标提供了一套稳健且可迁移的评估工具集，主要适用于无条件生成（即从头材料设计）。该场景还受益于多样性指标——这些指标可量化生成元素、晶体对称性、化学计量比及结构尺度（如每个晶胞中的原子数、密度）的多样性。此类指标反映了模型对材料空间进行广泛且无偏探索的能力。相比之下，条件生成任务（例如受化学空间、成分、原型或目标性质约束的任务）通常需要更特定的任务评估标准。对于化学结构预测（CSP），top-(k)匹配指标尤为适用：它既衡量在前k个生成候选物中出现正确基态结构的成分占比，也包含相应的RMSD误差；而对于基于性质的生成任务，则必须额外针对预期目标性质进行验证；最后还需采用应用特定的标准，如供应风险指标（例如……）。当研究目标涉及成分构成、经济性或可持续性约束时，赫芬达尔-赫希曼指数（HHI）可被纳入考量。

我们在本节结尾强调，目前缺乏评估生成材料模型的标准。首先，早期模型受到当时可用训练集和测试集规模有限的限制




图 4 | 生成的晶体结构示例：a cubicGAN、b iMatGen、c CrystaLLM、d MatterGen 和 e Matra-Genoa 模型，分别基于参考文献¹²³、⁵⁸、⁹⁵、⁴⁵及⁴⁶中的 CIF 文件，使用 vesta¹⁴⁵进行重新绘制。

（例如Perov-5或Carbon-24），这些数据集仅涵盖特定结构基元或化学成分；如前所述，在随机划分测试集时还存在明显局限性⁵⁵。尽管最新模型已利用显著更大的数据集（如表1所示），但测试集划分方式仍未标准化。

其次，正如前文所述，匹配算法和参考凸包等其他因素在不同文献中存在显著差异。即使研究采用相同的参考数据集和算法，它们通常会使用不同的评估标准和阈值，这严重阻碍了跨研究的比较。一个尤为值得关注的问题是：许多模型仅依赖形成能作为稳定性指标——要么缺乏对竞争相的适当凸包分析，要么完全忽略这一环节。此外，如前所述关于新颖性指标的部分所讨论的，匹配算法还可能错误地识别出“新相”。

第三，虽然有效性指标和回收率通常被视为关键绩效指标，但诸如“生成结构文件的机器可读性”或“DFT计算的成功终止”这类简单指标并不足以进行有效评估。在基准测试框架中，应更加重视有效性（可反映记忆能力）与创造性（能够探索化学空间）之间的基本平衡关系。当前方法往往过度强调结构正确性，而未能充分评估材料发现的真实潜力。

最后但同样重要的是，现实性指标（尤其是可合成性评估）常常受到参考数据集中存在的偏差影响——这一局限在现有文献中尚未得到充分探讨。这些偏差会系统性地扭曲评估结果并误判模型性能。所有这些相互关联的因素都凸显了建立全面、多标准的基准测试体系的迫切需求。

基于这些原因，我们在本综述中并未尝试直接比较或对模型进行基准测试。由于缺乏标准化评估指标，此类比较难以可靠，凸显了建立通用基准测试集的必要性。若没有此类标准，有意义的跨模型比较本质上将无法实现。

应用程序

除了基准测试之外，生成模型在材料科学领域的真正价值在于其能够发现新型稳定的化合物。这些模型不仅能复现已知数据，还能探索全新的化学结构、原型结构及拓扑构型——图4中多个模型生成的结构示例便印证了这一点。本节将分两个阶段概述其应用：首先是在大规模无约束筛选场景下，模型可生成涵盖广泛结构类别的海量候选结构库；其次是在以性能为导向的定向生成场景中，模型能针对特定功能目标（如电池性能、超导性或光电子特性）进行精准设计。

晶体结构的大规模筛选

CubicGAN模型¹²³是材料科学领域大规模生成筛选的早期范例。该模型经过训练可生成三种立方空间群（#216、#225和#221）中的晶体结构，共

生成了1000万种候选结构——涵盖了从MP相和ICSD相中大多数已知的立方晶体，并识别出24种新型原型结构（其定义基于化学计量比和空间群，不考虑维科夫位置）。通过以下标准筛选后：(i) CIF格式有效性；(ii) 成分唯一性；(iii) 电荷中性；(iv) 负形成能，该模型共生成17,303种三元材料和91,594种四元材料。其中83.4%（14,433种）的三元材料及24.5%（22,414种）的四元材料成功实现DFT优化。力学与动力学稳定性筛选共获得506种稳定结构，其中包括四种新型原型结构。该方法突破了立方对称性的限制⁸³，成功生成1869种经DFT优化的非立方结构，其中约5.3%的结构能量值与MP相凸包的能量值相差不超过250 meV/原子。

CDVAE模型的各种变体⁵²已被应用于低维材料的生成。Lyngby等人¹²⁴利用C2DB数据库中的26,152个二维结构¹²⁵进行训练，生成了10,000个候选结构，其中89%通过了几何形状和电荷中性验证。经过去重处理及元素替换增强后，系统性DFT计算表明：生成集与训练集具有相似的形成能，但成分和结构均存在显著差异。该方法后续被扩展至一维材料¹²⁶，共生成1,895个候选结构，其中1008个具有 E_{hull} 低于200 meV/原子（基于OQMD数据集作为参考壳层的DFT计算结果⁴⁸）。该集合中还包括完全新颖的原型结构。

MatterGen模型基于来自MP和Alexandria数据库的607,683个结构进行训练，进一步验证了生成模型识别S.U.N.结构的能力。值得注意的是，结构唯一性从1000个样本时的100%降至1000万个样本时的52%，而新颖性在100万个样本前始终维持在60%左右，随后下降至约47%；该模型成功复现了训练集中未包含的2000多个实验ICSD结构。对1000个样本的DFT验证表明，生成结构与优化结构之间的RMSE值小于0.076 Å，其中75%的结构与凸包距离在100 meV/原子以内。

目标功能材料的制备

生成模型可通过微调或条件化处理来生成符合特定功能目标的候选材料。例如，MatterGen支持根据成分、空间群以及机械、电子或磁性性质进行条件化筛选。Parida等人¹²⁷以锂离子电池材料为研究对象，设定了 $E_{\text{hull}} \leq 30$ meV/原子的目标值，并生成了32,600个候选结构；通过使用MatterSim原子间势能¹²⁸进行筛选，他们在100 meV/原子的能量范围内识别出12,550种独特的新型结构，其中包括817种不含重元素的锂化合物，其中约11%达到了目标稳定性阈值。

MatterGen软件亦被用于生成适用于热化学水分解（TCH）应用的金属氧化物。在设定 $E_{\text{hull}} \leq 10$ meV/原子及涵盖13种目标化学体系的条件下，该模型生成了约15,000个样品。此外，这些样品均通过S.U.N.检查进行预筛选（为确保稳定性， E_{hull} 值亦由MatterSim势能函数预测得出）。其中最值得关注的候选材料是一种新型热力学稳定的五元氧化物 $\text{Ba}_2\text{SrInFeO}_6$ ，其氧缺陷形成能符合TCH反应的要求。

CDVAE也被用于设计新型传统超导体¹²⁹。该模型基于1058个Jarvis结构¹³⁰进行训练，生成了3000个候选结构，并利用预训练的ALI-GNN模型¹³¹对这些结构的性质进行了筛选。虽然生成结构的元素丰度与训练集相似，但其中包含新颖的化学计量比和晶体结构；不过所有

结构均属于P1空间群，这表明 CDVAE 模型在生成高对称性晶体结构方面存在局限性。

应用 GANCSF 模型构建了适用于光阳极的Mg–Mn–O三元化合物⁶³，并鉴定出23种具有优异水相稳定性和带隙特性的新型化合物。其中两种结构（MgMn₄O₈和Mg₂MnO₄）位于凸包表面或其附近，在DFT计算精度范围内代表稳定的新型物相。

近期，Okabe等人研究表明：通过战略性地屏蔽去噪步骤，结构约束可整合到任何基于扩散的生成模型中以引导化合物生成¹³²。使用在MP-20数据集上训练的DiffCSP作为扩散模型时，该SCIGEN模型在阿基米德晶格中生成了787万种化合物。对26,000个样本进行DFT预过滤计算后，发现有13,800种材料的收敛最大力小于0.01 eV/Å。

针对特定结构条件的另一示例可参见参考文献¹³³。通过对CDVAE模型进行条件化处理，ConditionCDVAE+模型在包含19,926个二维Janus III–VI范德华异质结构的数据集上完成训练，并能为特定化学组成生成新型异质结构。

讨论与未来方向

无机晶体结构的生成式人工智能已从最初针对特定材料类别的可行性验证，发展到能够生成具备对称性认知、结构稳定且有时可精准匹配特定性质的高质量模型。尽管取得了显著进展，仍有许多工作亟待完成。下文我们将围绕方法论、物理原理、控制机制、数据处理及实际应用四个维度，系统阐述并探讨相关研究方向。

如图3所示，方法论设计空间中的多个领域尚未被充分探索。其中部分领域缺乏明确意义（例如扩散模型或基于体系的大型语言模型），而另一些领域则研究不足（例如倒易空间中的扩散过程或维科夫坐标系上的归一化流）。其他研究方向包括掩蔽去噪、流形约束扩散以及晶体学流形上的流匹配（例如固定空间群/维科夫集合），这些方法可通过设计强制实现空间群一致性、电荷中性和最小原子间距，从而降低无效样本比例并减少事后过滤需求。我们还期待更多结合互补架构与表征方式的混合研究方法。

从物理学角度来看，当前大多数模型均假设在T=0 K时晶体完全有序且所有晶格位点均被占据。将理论框架扩展至包含部分占据状态（如合金化、空位及点缺陷）对于催化反应、固态电解质和热电材料等应用领域至关重要。要解决这些非理想特性，可能需要超越单胞结构范畴，对更大尺度的结构进行建模。此外，诸如磁矩和电荷态等辅助信息也可整合到结构表征中。更重要的是，若将生成模型与热力学变量（温度、压力及化学势）相耦合，便能精准调控亚稳态相态及熵稳定结构的形成。

除了基于标准似然函数学习 $p(\mathbf{x})$ 或 $p(\mathbf{x}|\mathbf{Ic})$ 之外，通过与能量替代量 $E_\phi(\mathbf{x})$ （例如uMLIPs或可微性质预测器）相结合，可以得到形式为 $p(\mathbf{x}) \propto \exp(-\beta E_\phi(\mathbf{x}))$ 的玻尔兹曼型似然函数。这可通过基于能量的模型（EBM）which directly parameterize $E_\phi(\mathbf{x})$ 并依赖马尔可夫链蒙特卡洛采样^{134,135}来实现。相关方法将能量作为奖励信号：强化学习可利用 $f(E(\mathbf{x}))$ 进行奖励塑形；而生成流网络（GFlowNets¹³⁶）则学习能够按奖励函数比例采样的策略。

基于分数的方法（其学习的是 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 而非 $p(\mathbf{x})$ 本身）同样可与基于能量的观点相联系，因为该分数可从能量函数中推导出。例如，扩散模型可被解释为基于分数的生成模型³¹。因此，这些生成方法在概念上与全局优化方法（如模拟退火¹³⁷和最小跳跃法⁸）相关联，但原则上更为强大，因其作用于涵盖组合结构及其他关键特征的高维概率分布之上。

后续的发展还将包括更完善的条件控制机制。采用严格条件约束的模型（如组分构成、电荷平衡、空间群、原型类别）将显著提升成功率。许多应用场景还需权衡多种参数之间的关系，例如 E_{hu} 、带隙、离子导电性、临界温度以及元素丰度/毒性等。诸如GFlowNets和基于向量奖励的强化学习等多目标方法，能够明确地学习如何在帕累托前沿上进行采样，而非仅优化单一标量指标。自然语言条件化技术同样前景广阔：正如Chameleon所展示的那样，基于大语言模型的生成器能够将自由文本提示（如“宽禁带、无毒、层状p型掺杂钙钛矿且具有高极化子迁移率”）解析为结构化约束条件，从而支持交互式对话。

在数据层面，模型的性能受限于其训练所用的数据集。现有数据集往往偏向特定化学类型、原型化合物、小晶胞结构以及GGA级能量计算。需要改进数据管理流程，使训练数据与生成目标相匹配，这包括精心设计数据集、明确授权协议、提供透明化的合成方案以及建立可追溯来源以确保结果可复现性。在线训练（即利用新生成的数据对模型进行微调）是一个极具潜力的方向。在条件允许的情况下，添加合成元数据（如温度、气氛环境、前驱体、成功/失败记录等）有助于弥合生成预测与实验室实际操作之间的差距——使模型不仅能预测产物成分，还能指导具体制备方法。

在评估方面，如前所述，目前缺乏严格的基准测试方法。我们需要从简单的合理性验证（有效性、覆盖率、精确率-召回率）逐步提升至包含稳定性、新颖性及时间复杂度等维度的实质性对比基准。由社区维护的测试套件应包含用于评估稳定性的冻结凸包数据集、配备标准匹配算法的固定训练集以检验新颖性，以及明确标注计算成本以评估可扩展性。这些基准测试应涵盖不同化学类型和性质下的条件性任务，而不仅限于非条件性生成任务。借鉴性质预测的研究范例¹³⁸，引入结构与性质参数的校准不确定性值将有助于实现更可靠的筛选与优先级排序。

从规模上看，生成模型将成为自主材料发现领域新候选材料的起点。关键在于，生成式人工智能不应被视为预测“最佳”材料的单一工具，而应作为迭代流程中的组成部分。需要快速、轻量化的模型来为downstream filtering by MLIPs，高通量密度泛函理论计算及实验验证提供候选材料。主动学习循环——即模型提出候选方案、实验室进行验证并循环利用数据——将发挥核心作用。可持续性约束条件（如地球资源丰度、毒性、隐含能耗及使用寿命）也必须纳入材料发现流程。最后，具备可解释输出结果的模型能帮助专家审核并指导生成过程，从而提升可信度并加速洞察力的获取。

结论

生成式人工智能正开始重塑我们探索晶体材料的方式。通过从大型数据库中学习概率分布，VAE、GAN、流模型、扩散模型、Transformer以及大语言模型（LLM）等模型能够提出新颖的结构，并在某些情况下精准调控所需特性。本文综述了这些模型的核心架构、表征方法及数据来源，并将其按照表征类型、条件化策略和应用领域进行分类体系化整理。目前已讨论了超过50种模型，其应用场景涵盖大规模筛选、新型物相发现以及能源与催化领域的前沿研究。

尽管取得了这些进展，用于晶体结构的生成模型仍处于发展的早期阶段。现有评估标准仍较为分散，稳定性评估方法各异，且合成可行性常被忽视。结构无序性、有限温度效应以及多目标之间的权衡关系尚未得到充分解决。值得庆幸的是，通过方法论、物理学原理、控制技术、数据处理以及与材料发现流程的整合等方面的突破，已有许多具有前景的研究路径可加以改进。随着持续发展，生成模型有望成为计算材料科学家不可或缺的工具，加速整个材料领域研究体系的发现与理解进程。

数据可用性

本研究期间未生成或分析任何数据集。

接收日期: 2025年9月3日; 接受日期: 2025年11月17日;

Published online: 06 December 2025

参考文献

- Lewis, N. S. 《迈向成本效益高的太阳能利用》. *Science* 315,798–801 (2007).
- Magee, C. L. 材料创新在整体技术发展中的作用量化研究。《*Complexity*》第18卷, 第10–25页 (2012年)。
- 斯奈德, G. 与托贝勒, E. 复杂热电材料。《*自然*》。《*材料科学*》第7卷, 第105–114页 (2008年)。
- 奥加诺夫, A. R. 与 格拉斯, C. W. 基于从头算演化技术的晶体结构预测: 原理与应用。《*化学物理杂志*》124卷, 244704页 (2006年)。
- 普罗德亚宾金, E. V.; 季霍诺夫, E. V.; 沙佩耶夫, A. V.; 奥加诺夫, A. R. 基于主动学习的机器学习原子间势能加速晶体结构预测。 *Phys. Rev. B* 99,064114 (2019).
- 皮卡德, C. J. 与 尼兹, R. J. 基于从头算方法的随机结构搜索。《*凝聚态物理杂志*》第23卷, 第053201页 (2011年)。
- 王宇、吕杰、朱立和马勇。基于粒子群优化的晶体结构预测。《*物理评论B*》第82卷, 第094116页 (2010年)。
- Goedecker, S. 最小值跳跃法: 一种求解复杂分子系统势能面全局最小值的高效搜索方法。《*化学物理杂志*》120卷, 9911–9917页 (2004年)。
- Yamashita, T. 等. CrySPY: 一种基于机器学习加速的晶体结构预测工具。《*科学与技术先进材料方法*》第1卷, 第87–97页 (2021年)。
- Falls, Z., Avery, P., Wang, X., Hilleke, K. P. & Zurek, E. 用于晶体结构预测的XtalOpt进化算法。《*物理化学C辑*》125卷, 1601–1620页 (2021年)。
- 丹科, A. D. 与 马德, R. I. 《人工智能与材料发现的生成模型——综述》。 *WS Ann. Rev. Funct. Mater.* 3,2540001 (2025).
- Liu, Y. 等. 生成式人工智能及其在材料科学中的应用: 现状与未来展望。《*材料组学杂志*》第9卷, 第798–816页 (2023年)。
- Long, T., Zhang, Y. & Zhang, H. 基于生成式深度学习的材料逆向设计。预印本: <https://doi.org/10.48550/arXiv.2409.19124> (2024)。
- 诺, J.; 顾, G. H.; 金, S.; 郑, Y. 无机固体材料的机器辅助逆向设计: 前景与挑战。《*化学科学*》11卷, 4871–4881页 (2020年)。
- Park, H., Li, Z. & Walsh, A. 生成式人工智能是否解决了逆向材料设计问题? 《*Matter*》第7卷, 第2355–2367页 (2024年)。
- 高原一、水口智、刘斌。利用生成式AI代理加速无机材料设计。预印本: <https://doi.org/10.48550/arXiv.2504.00741> (2025)。
- 祖纳格, A. 基于目标功能性的材料逆向设计研究。《*自然·化学评论*》第2卷, 第1–16页 (2018年)。
- 金玛, D. P. 与 韦林, M. 自编码变分贝叶斯方法。预印本发布于<https://doi.org/10.48550/arXiv.1312.6114> (2022年)。
- Goodfellow, I. J. 等著, 《生成对抗网络》, 载于《*神经信息处理系统进展*》第27卷 (主编: Ghahramani, Z.; Welling, M.; Cortes, C.; Lawrence, N.; Weinberger, K.), Curran Associates出版社, 2014年。
- Radford, A., Metz, L. & Chintala, S. 基于深度卷积生成对抗网络的无监督表示学习。预印本, <https://doi.org/10.48550/arXiv.1511.06434> (2016)。
- Vaswani, A. 等学者指出: “注意力就是你所需的一切。” 见《*神经信息处理系统进展*》第30卷 (Guyon, I. 等编) (Curran Associates, Inc., 2017)。
- Rezende, D. 与 Mohamed, S. 基于归一化流的变分推断。载于《*第32届国际机器学习会议论文集*》第37卷 (《*机器学习研究汇刊*》, Bach, F. 与 Blei, D. 编), 第1530–1538页 (PMLR, 2015年)。
- 丁-L、索尔-迪克斯坦-J 与本吉奥-S. 基于真实 NVP 进行密度估计。载于《*ICLR 会议录 (海报)*》 (OpenReview.net, 2017年)。
- Lipman, Y., Chen, R. T. Q., Ben-Hamu, H., Nickel, M. & Le, M. 生成建模中的流匹配。预印本: <https://doi.org/10.48550/arXiv.2210.02747> (2023)。
- 达里瓦尔 (P. Dhariwal) 与 尼科尔 (A. Nichol): 扩散模型在图像合成领域优于生成对抗网络 (GAN)。载于《*神经信息处理系统进展*》第34卷 (主编: 兰扎托 M.、贝格尔齐默 A.、多芬 Y.、梁 P. 及沃恩 J. W.), 第8780–8794页 (Curran Associates, Inc., 2021年)。
- Cai, R. 等学者: 《用于形状生成的学习梯度场》, 载于《*欧洲计算机视觉会议论文集*》第364–381页 (Springer, 2020年)。
- 施C、罗S、徐M 与 唐J. 基于学习梯度场的分子构象生成方法。载于《*第38届国际机器学习会议论文集*》9558–9568页 (PMLR, 2021年)。
- 索尔-迪克斯坦 (J.)、魏斯 (E.)、马赫斯瓦拉纳坦 (N.) 与 甘古利 (S.): 基于非平衡热力学的深度无监督学习。载于《*第32届国际机器学习会议论文集*》 (《*机器学习研究汇刊*》第37卷, 巴赫F. 与 布莱D. 编), 第2256–2265页 (PMLR, 2015年)。
- 何J、贾因A 与 阿比尔P. 《去噪扩散概率模型》。载于《*神经信息处理系统进展*》第33卷, 第6840–6851页 (Curran Associates 公司, 2020年)。
- 宋Y. 与 埃尔蒙S. 基于数据分布梯度估计的生成建模。载于《*神经信息处理系统进展*》第32卷 (Curran Associates, Inc., 2019)。
- Song, Y. 等学者. 基于随机微分方程的分数量生成建模. 载于《*国际学习表征会议 (ICLR) 论文集*》 (2021年)。
- Radford, A., Narasimhan, K., Salimans, T. & Sutskever, I. 通过生成式预训练提升语言理解能力。预印本 <https://paperswithcode.com/paper/improving-language理解通过> (2018)。
- Devlin, J., Chang, M. - W., Lee, K. 与 Toutanova, K. BERT: 用于语言理解的深度双向变换器预训练。载于《*Computational Linguistics 协会 North American 分会 2019 年会议论文集: Human Language 技术*》第1卷 (Long 和 Short Papers 编) (2018年)。
- Brown, T. 等学者指出: 语言模型属于少样本学习器. 详见《*神经信息处理系统进展*》 (Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M. & Lin, H. 编), 第33卷, 第1877–1901页 (Curran Associates, Inc., 2020年)。
- 基罗加 (F. M.)、龙凯蒂 (F.)、兰扎里尼 (L.) 与 费尔南德斯-巴里维埃拉 (A.) 重新探讨卷积神经网络中旋转不变性所需的数据增强方法。载于《*管理科学中的建模与仿真: 国际管理科学建模与仿真会议论文集 (MS-18)*》, 第127–141页 (Springer, 2020年)。
- Mazitov, A. 等. PET-MAD: 一种用于先进材料建模的轻量级通用原子间势函数. 预印本地址: <https://doi.org/10.48550/arXiv.2503.14118> (2025年)。
- Gong, S. 等学者: 研究图神经网络在晶体结构分析中的应用——捕捉周期性特征的局限与机遇。《*科学进展*》第9卷, eadi3245 (2023年)。
- 莱赫托拉 (S.)、施泰格曼 (C.)、奥利维拉 (M. J.) 与 马克斯 (M. A.) 合著的《*LIBXC 软件库最新进展——密度泛函理论函数库全集*》, 发表于《*SoftwareX*》第7卷第1–5页 (2018年)。
- Perdew, J. P., Burke, K. & Ernzerhof, M. 通用梯度近似方法的简化。 *Phys. Rev. Lett.* 77,3865–3868 (1996).
- Jain, A. 等. 《材料计划: 一种通过材料基因组学加速材料创新的方法》. *APL Mater.* 1,011002 (2013).

41. 贝尔斯基 (A.)、赫伦布兰特 (M.)、卡伦 (V. L.) 与卢克斯 (P.) 合著的《无机晶体结构数据库 (ICSD) 的新进展: 支持材料研究与设计的可访问性》, 发表于《晶体学报B辑: 结构科学》第58卷, 第364–369页 (2002年)。
42. Schmidt, J. 等. 基于机器学习方法确定材料的全局零温相图.《先进材料》第35卷, 2210788页 (2023年)。
43. 王汉昌、施密特、马克斯·A·L·马克斯、维尔茨及罗梅罗: 基于对称性的计算方法用于寻找新型二元及三元二维材料.《二维材料》第10卷, 第035007页 (2023年)。
44. 克雷瑟, G. & 富特穆勒, J. 基于平面波基组的从头算总能量计算高效迭代方案. *Phys. Rev. B* 54, 11169–11186 (1996)。
45. Zeni, C. 等. 一种用于无机材料设计的生成模型.《自然》第639卷, 第624–632页 (2025年)。
46. Breuck, P.-P. D., Piracha, H. A., Rignanese, G.-M. & Marques, M. A. 一种基于Wyckoff表示法的生成材料变换器. 预印本: <https://doi.org/10.48550/arXiv.2501.16051> (2025)。
47. Curtarolo, S. 等人的 aflowlib.ORG: 一个基于高通量从头计算构建的分布式材料性质数据库. *Comput. Mater. Sci.* 58, 227–235 (2012)。
48. 萨尔, J. E.; 柯克林, S.; 艾科勒, M.; 梅雷迪格, B.; 沃尔弗顿, C.《基于高通量密度泛函理论的材料设计与发现: 开放量子材料数据库 (OQMD)》。 *JOM* 65, 1501–1509 (2013)。
49. Choudhary, K. 等. 针对数据驱动材料设计的多种集成模拟联合自动化存储库 (jarvis)。《国家计算材料期刊》第6卷, 第173页 (2020年)。
50. Andersen, C. W. 等人开发了用于交换材料数据的API. *Sci. Data* 8. <https://doi.org/10.1038/s41597-021-00974-z> (2021)。
51. Evans, M. L. 等. OptimaDE API 在材料发现, 设计及数据交换领域的开发与应用. *Digit. Discov.* 3, 1509–1533 (2024)。
52. 谢T、傅X、加内亚O.-E、巴尔齐莱R及雅科拉T合著的《用于周期性材料生成的晶体扩散变分自编码器》, 收录于《国际学习表征会议 (ICLR) 论文集》 (2022年)。
53. Castelli, I. E. 等. 钙钛矿金属氧化物的计算筛选: 实现最优太阳光捕获.《能源与环境科学》第5卷, 第5814–5819页 (2012年)。
54. Castelli, I. E. 等人的研究: 利用计算材料数据库开发出适用于单光子和双光子水分解的新立方钙钛矿材料.《能源与环境科学》第5卷, 9034–9043页 (2012年)。
55. Martirosyan, M. M. 等. 所有结构匹配结果均未呈现显著差异. 预印本详见 <https://doi.org/10.48550/arXiv.2509.12178> (2025年)。
56. Ren, Z. 等. 一种用于具有特定性质的无机晶体通用逆向设计的可逆晶体学表示方法.《Matter》第5卷, 第314–335页 (2022年)。
57. Hoffmann, J. 等. 基于数据的三维晶体结构编码与解码方法. 预印本发布于 <https://doi.org/10.48550/arXiv.1909.00949> (2019)。
58. Noh, J. 等. 通过连续表示法对固态材料进行逆向设计.《Matter》第1卷, 第1370–1384页 (2019年)。
59. Court, C. J., Yildirim, B., Jain, A. & Cole, J. M. 基于表示学习的三维无机晶体结构生成与性质预测.《化学信息与建模杂志》第60卷, 第4518–4535页 (2020年)。
60. Long, T. 等. 基于约束晶体的深度卷积生成对抗网络用于晶体结构的逆向设计.《计算材料杂志》第7卷, 第1–7页 (2021年)。
61. Long, T. 等. 多组分体系晶体结构的逆向设计. *Acta Mater.* 231, 117898 (2022)。
62. 诺伊拉 (A. Nouira)、索科洛夫斯卡 (N. Sokolovska) 与克里韦洛 (J.-C. Crivello): CrystalGAN——一种利用生成对抗网络学习发现晶体结构的方法。预印本发布于 <https://doi.org/10.48550/arXiv.1810.11203> (2019年)。
63. 金, S.; 诺, J.; 顾, G. H.; 阿斯普鲁-古齐克, A. 及郑, Y. 用于晶体结构预测的生成对抗网络. *ACS Cent. Sci.* 6, 1412–1420 (2020)。
64. Lu, S. 等. Uni-3DAR: 通过自回归模型对压缩空间标记进行统一的三维生成与理解. 预印本地址: <https://doi.org/10.48550/arXiv.2503.16278> (2025年)。
65. Qi, H. 等. 基于数据驱动的晶体结构预测中的潜在保守客观模型. 预印本发布于 <https://doi.org/10.48550/arXiv.2310.10056> (2023年)。
66. 罗Y、刘C与季S:《面向对称性感知的周期性材料生成方法》, 载于《神经信息处理系统进展》第36卷 (2024年)。
67. Klipfel, A., Fregier, Y., Sayede, A. & Bouraoui, Z. 用于晶体材料生成的向量场导向扩散模型. 载于《AAAI人工智能会议论文集》, 第38卷 (2024年)。
68. Pakornchote, T. 等学者. 扩散概率模型增强了变分自编码器在晶体结构生成建模中的性能.《科学报告》第14卷, 第1275页 (2024年)。
69. Jiao, R. 等. 基于联合等变扩散的晶体结构预测. 载于《第三十七届神经信息处理系统会议 (NeurIPS) 论文集》 (2023年)。
70. 乔, R.; 黄, W.; 刘, Y.; 赵, D. 和 刘, Y. 空间群约束下的晶体生成。预印本: <https://doi.org/10.48550/arXiv.2402.03992> (2024)。
71. 叶C.-Y.、翁H.-M.与吴Q.-S.合著《Con-CDVAE: 一种条件生成晶体结构的方法》, 发表于《Compt. Mater. Today》第1卷, 编号100003 (2024年)。
72. Luo, X. 等. 用于晶体结构预测的深度生成模型.《国家计算材料期刊》第10卷, 第1–10页 (2024年)。
73. Liu, Y. 等. 用于晶体结构预测的等变超图扩散方法. 预印本发布于 <https://doi.org/10.48550/arXiv.2501.18850> (2025年)。
74. Chen, Z. 等. 基于Transformer的变分自编码器在晶体结构预测中的应用. 预印本: <https://doi.org/10.48550/arXiv.2502.09423> (2025年)。
75. Das, K. 等学者. 基于文本引导联合扩散模型的周期性材料生成方法. 发表于第十三届国际学习表征会议 (ICLR) (2025年)。
76. Park, H., Onwuli, A. & Walsh, A. 基于文本引导生成式人工智能探索晶体化学空间. *Nat. Commun.* 16, 4379 (2025)。
77. Wu, L. 等. 用于晶体结构预测的变分自编码器. 预印本发布于 <https://doi.org/10.48550/arXiv.2503.10471> (2025年)。
78. 钟, P.; 戴, X.; 邓, B.; 塞德, G. 与佩尔松, K. A. 基于宿主引导的修复生成与基底势能进行晶体结构预测.《材料前沿》 <https://doi.org/10.1039/D5MH00774G> (2025)。
79. Tangsongcharoen, K. 等. CrystalGRW: 通过测地线随机游走对具有特定性质的晶体结构进行生成建模. 预印本地址: <https://doi.org/10.48550/arXiv.2501.08998> (2025年)。
80. Cornet, F. 等. 晶体材料生成中的动力学朗之万扩散模型. 预印本发布于 <https://doi.org/10.48550/arXiv.2507.03602> (2025年)。
81. Yang, S. 等人的《面向材料生成的可扩展扩散方法》, 发表于《国际学习表征会议 (ICLR) 论文集》 (2024年)。
82. Zhang, G. 等. UniGenX: 采用自回归扩散法统一生成序列与结构. 预印本地址: <https://doi.org/10.48550/arXiv.2503.06687> (2025年)。
83. Zhao, Y. 等人的研究: 基于物理原理指导的深度学习方法, 用于满足对称性约束条件下的晶体材料生成设计.《国家计算材料期刊》第9卷, 第1–12页 (2023年)。

84. 朱, R., 农, W., 山崎, S. 及希帕尔加翁卡尔, K. WyCryst: Wyckoff无机晶体生成器框架。《Matter》第7卷, 第3469–3488页 (2024年)。
85. 弗雷德里克斯 (S.)、帕里什 (K.)、塞耶 (D.) 与朱 (Q.)。PyXtal: 一个用于晶体结构生成与对称性分析的Python库。《计算物理通讯》261卷, 1078–1079页 (2021年)。
86. 苏T、曹B、胡S、李M与张T-Y. CGWGAN: 基于Wyckoff生成对抗网络的晶体生成框架。《材料与信息学杂志》第4卷, 无编号 (2024年)。
87. 陈, C. 与翁, S. P. 《适用于元素周期表的通用图深度学习原子间势函数》。《自然·计算科学》第2卷, 第718–728页 (2022年)。
88. 曹志、罗晓、吕杰与王磊。基于空间群信息的晶体材料生成变换器。《科学通报》第70卷, 第3522–3533页 (2025年)。
89. Levy, D. 等.SymmCD:基于扩散模型的保对称性晶体生成方法.预印本: <https://doi.org/10.48550/arXiv.2502.03638>(2025)。
90. Kelvinius, F. E. 等.WyckoffDiff——一种用于晶体对称性的生成扩散模型.预印本:<https://doi.org/10.48550/arXiv.2502.06485>(2025)。
91. Flam-Shepherd, D. & Aspuru-Guzik, A. 语言模型能够直接在三维空间中生成分子、材料及蛋白质结合位点, 并以XYZ、CIF和PDB文件格式输出。预印本详见 <https://doi.org/10.48550/arXiv.2305.05708> (2023年)。
92. Gruver, N. 等学者的研究表明,经过微调的语言模型能够生成稳定的无机材料文本.详见《第12届国际学习表示会议(ICLR)论文集》(2024年)。
93. Touvron, H. 等.Llama 2:开源基础架构与精细调优的聊天模型.预印本见<https://doi.org/10.48550/arXiv.2307.09288>(2023年)。
94. Touvron, H. 等人的研究.LLAMA:开放且高效的基础语言模型.预印本发布于<https://doi.org/10.48550/arXiv.2302.13971>(2023年)。
95. 安图内斯, L. M., 巴特勒, K. T. 及格劳-克雷波, R. 基于自回归大规模语言模型的晶体结构生成。《自然·通讯》15卷, 10570页 (2024年)。
96. Mohanty, T., Mehta, M., Sayeed, H. M., Srikumar, V. & Sparks, T. D. CrysText: 一种利用大语言模型生成文本条件化晶体结构的生成式AI方法。预印本地址: <https://doi.org/10.26434/chemrxiv-2024-gjhpq-v2> (2024)。
97. Grattafiori, A. 等.Llama 3 模型群组. 预印本, <https://doi.org/10.48550/arXiv.2407.21783> (2024)。
98. Dettmers, T., Pagnoni, A., Holtzman, A. & Zettlemoyer, L. QLoRA: 量化大语言模型的高效微调。预印本: <https://doi.org/10.48550/arXiv.2305.14314> (2023)。
99. Yang, S. 等.生成式层次化材料搜索.载于《神经信息处理系统进展》第37卷(NeurIPS),2024年。
100. 丁, Q., 米雷特, S. 和刘, B. MatExpert: 通过模仿人类专家实现材料发现的分解方法。预印本发布于 <https://doi.org/10.48550/arXiv.2410.21317> (2024年)。
101. Gan, J. 等人的研究:MatLLMSearch——基于进化引导的大语言模型的晶体结构发现。预印本发布于 <https://doi.org/10.48550/arXiv.2502.20933>(2025年)。
102. Yan, K. 等.晶体材料的不变标记化在语言模型生成中的应用.预印本:<https://doi.org/10.48550/arXiv.2503.00152>(2025年)。
103. Xia, Y. 等.自然语言模型:破译自然语言以促进科学发现.预印本发布于 <https://doi.org/10.48550/arXiv.2502.07527>(2025年)。
104. Miller, B. K., Chen, R. T. Q., Sriram, A. & Wood, B. M. FlowMM: 基于黎曼流匹配生成材料。预印本地址: <https://doi.org/10.48550/arXiv.2406.04713> (2024年)。
105. 斯里拉姆, A., 米勒, B. K., 陈, R. T. Q. 与伍德, B. M. FlowLLM: 基于大型语言模型作为基础分布的材料生成中的流匹配方法。预印本: <https://doi.org/10.48550/arXiv.2410.23405> (2024)。
106. 吴浩等人: 一种用于材料生成的周期性贝叶斯流。预印本发布于<https://doi.org/10.48550/arXiv.2502.02016> (2025年)。
107. 本吉奥, E.; 贾因, M.; 科拉博利夫, M.; 普雷库普, D. & 本吉奥, Y. 基于流网络的非迭代式多样化候选生成模型。《先进神经信息处理与系统》第34卷, 第27381–27394页 (2021年)。
108. AI4Science, M. 等人。Crystal- GFN: 基于所需特性和约束条件筛选晶体。预印本发布于<https://doi.org/10.48550/arXiv.2310.04925> (2023年)。
109. NeurIPS层次化GFlowNet用于晶体结构生成。<https://neurips.cc/virtual/2023/78549> (2023)。
110. Xiao, H. 等.一种基于生成式深度学习的,用于固态材料逆向设计的可逆且不变的晶体表征方法。《自然·通讯》14卷,7027页(2023年)。
111. Novitskiy, L. 等.释放新型条件生成方法在新材料发现中的潜力.预印本见:<https://doi.org/10.48550/arXiv.2411.03156>(2024年)。
112. Alverson, M. 等.生成对抗网络与扩散模型在材料发现中的应用。《数字发现》第3卷,第62–80页(2024年)。
113. 李-Z. 与比尔比里斯-N. NSGAN: 一种基于非支配排序优化的生成对抗设计框架用于合金发现。《国家计算材料期刊》第10卷, 第1–15页 (2024年)。
114. 张Y、胡C与江B. 嵌入原子神经网络势函数: 基于物理启发式表示的高效精准机器学习方法。《物理化学快报》第10卷, 第4962–4967页 (2019年)。
115. Qin, C. 等.基于深度生成模型的半导体材料逆向设计。《材料化学杂志 A》第12卷,第22689–22702页(2024年)。
116. Hoellmer, P. 等.基于随机插值法的开放数据生成.预印本发布于<https://doi.org/10.48550/arXiv.2502.02582>(2025年)。
117. Riebesell, J. 等.一种评估机器学习晶体稳定性预测结果的框架。《自然·机械智能》(Nat. Mach. Intell.)第7卷,第836–847页(2025年)。
118. 洛伊, A.; 孙, D.; 王, H.-C.; 博蒂, S.; 马克斯, M. A. L. 通用机器学习原子间势已适用于声子研究。npj Comput. Mater. 11, <https://doi.org/10.1038/s41524-025-01650-1>(2025)。
119. 西曼斯基 (N. J.) 与巴特尔 (C. J.): 建立无机晶体生成性发现的基准模型。《材料前沿》第12卷, 第8000–811页 (2025年)。
120. Cheetham, A. K. & Seshadri, R. 人工智能能否推动材料发现? 对文章《规模化应用深度学习进行材料发现》的评述。Chem. Mater. 36, 3490–3495 (2024)。
121. Leeman, J. 等.高通量无机材料预测与自主合成面临的挑战。《PRX 能源》第3卷,<https://doi.org/10.1103/PRXEnergy.3.011002>(2024年)。
122. Juelsholt, M. 高通量材料预测领域持续面临的挑战: MatterGen可从训练数据集中预测化合物。预印本发表于ChemRxiv <https://doi.org/10.26434/chemrxiv-2025-mkls8> (2025年)。
123. Zhao, Y. 等.利用深度生成神经网络高通量发现新型立方晶体材料。Adv. Sci. 8,2100566 (2021)。
124. Lyngby, P. & Thygesen, K. S. 基于深度生成模型的数据驱动二维材料发现。npj Comput. Mater. 8, <https://doi.org/10.1038/s41524-022-00923-3>(2022)。
125. 杰丁, M. N. 等.计算二维材料数据库 (C2DB) 的最新进展。《二维材料》第8卷, 044002页 (2021年)。
126. 穆斯塔法 (H.)、林比 (P. M.)、莫滕森 (J. J.)、蒂格森 (K. S.) 与雅各布森 (K. W.)。基于生成式机器学习模型开发出数百种新型、稳定的单维材料。《物理评论材料》第7卷, <https://doi.org/10.1103/PhysRevMaterials.7.014007> (2023年)。
127. 帕里达, C.; 罗伊, D.; 拉斯特拉, J. M. G.; 博米克, A. 基于生成模型挖掘电池材料的化学空间。预印本发布于<https://doi.org/10.26434/chemrxiv-2025-q48jr> (2025年)。

128. Yang, H. 等人的研究:MatterSim——一个涵盖不同元素,温度和压力条件的深度学习原子级模型.预印本地址:<https://doi.org/10.48550/arXiv.2405.04967>(2024年).
129. Wines, D., Xie, T. & Choudhary, K. 基于数据驱动的深度学习模型进行下一代超导体逆向设计.《物理化学快报》第14卷,第6630–6638页(2023年)。
130. Choudhary, K. 等. 针对数据驱动材料设计的多种集成模拟联合自动化存储库 (Jarvis)。《npj Comput. Mater.》第6卷, <https://doi.org/10.1038/s41524-020-00440-1> (2020年)。
131. Choudhary, K. & DeCost, B. 基于原子级线图神经网络的材料性能预测改进方法。npj Comput. Mater. 7, <https://doi.org/10.1038/s41524-021-00650-1>(2021)。
132. Okabe, R. 等. 结构约束整合在量子材料发现生成模型中的应用.《自然·材料》<https://doi.org/10.1038/s41563-025-02355-y>(2025)。
133. Gao, S. 等. 用于范德华异质结构逆向设计的深度学习生成模型.Sci. Rep. 15, <https://doi.org/10.1038/s41598-025-06432-9>(2025)。
134. 勒昆 (Y. Lecun)、乔普拉 (S. Chopra)、哈德塞爾 (R. Hadsell)、兰扎托 (M. A. Ranzato) 与黄 (F. J. Huang)。《基于能量的学习教程》，载于《结构化数据预测》(巴基尔 G.、霍夫曼 T.、肖尔科普特 B.、斯莫拉 A. 及塔斯卡尔 B. 编)，麻省理工学院出版社，2006年。
135. 杜, Y. 与莫达奇, I. 基于能量模型的隐式生成与建模。载于《神经信息处理系统进展》第32卷(沃尔拉赫, H. 等编) (Curran Associates公司, 2019年)。
136. 本吉奥, E.、贾因, M.、科拉博利夫, M.、普雷库普, D. 及本吉奥, Y. 基于流网络的非迭代式多样化候选生成模型。载于《神经信息处理系统进展》第34卷,第27381–27394页 (Curran Associates, Inc., 2021)。
137. 柯克帕特里克 (S. Kirkpatrick)、格拉特 (C. D. Gelatt) 与韦基 (M. P. Vecchi)：基于模拟退火法的优化。《科学》第220卷,第671–680页 (1983年)。
138. 德·布雷克 (P.-P. De Breuck)、埃文斯 (M. L. Evans) 与里尼亚内塞 (G.-M. Rignanese)：数据驱动材料科学中的稳健模型评估与偏差失衡问题——以MODNet为例。《物理杂志：凝聚态物质》第33卷,第404002页 (2021年)。
139. Sawada, Y., Morikawa, K. 与 Fujii, M. 无机化学成分深度学习模型研究。预印本：<https://doi.org/10.48550/arXiv.1910.11499> (2019)。
140. Dan, Y. 等人. 基于生成对抗网络 (GAN) 的无机材料逆向设计化学组成空间高效采样方法。《计算材料科学杂志》第6卷,第1–7页 (2020年)。
141. Liu, K., Gao, S., Yang, K. & Han, Y. PCVAE: 一种基于物理信息的神经网络, 用于确定晶体的对称性与几何结构. In Proc. 2023 International Joint Neural Networks (IJCNN) 1–8 (IEEE, 2023). 会议
142. Sinha, A., Jia, S. & Fung, V. 用于生成周期性材料的表征空间扩散模型。预印本：<https://doi.org/10.48550/arXiv.2408.07213> (2024)。
143. Chenebua, E. T., Nganbe, M. & Tchagang, A. B. 一种用于设计晶格约束型钙钛矿材料的深度学习建模架构。npj Comput. Mater. 10,1–21 (2024)。
144. Luo, X. 等人的研究:CrystalFlow——一种基于流体动力学的晶体材料生成模型.《自然·通讯》第16卷,第9267页(2025年)。
145. Momma, K. & Izumi, F. 西斯塔3 (Vesta 3) 用于晶体、体积及形态数据的三维可视化分析。《应用晶体学杂志》44卷,1272–1276页 (2011年)。

作者贡献

P.-P.D.B.: 概念构思、分析、分类学构建、可视化设计及初稿撰写; H.-C.W.: 指标体系构建、应用研究与数据分析; G.-M.R.: 文稿撰写、审阅与编辑; S.B.: 项目监督、经费筹措及文稿撰写、审阅与编辑; M.A.L.M.: 项目监督、经费筹措及文稿撰写、审阅与编辑。

竞争性利益

S. Botti担任《npj Comput. Mater.》期刊的副主编,但未参与该期刊对本文稿的审阅或决策流程。

附加信息

所有信函及材料索取申请均应发送至Pierre-Paul De Breuck。

重印及授权信息可在此处获取:

<http://www.nature.com/reprints>

出版方声明: Springer Nature对于已发表地图中的管辖权主张及机构隶属关系均保持中立立场。

开放获取 本文依据知识共享署名4.0国际许可协议授权发布,允许您在任何媒介或格式中使用、分享、改编、分发及复制本文内容,但须满足以下要求:正确标注原作者及来源信息;提供知识共享许可协议链接;并注明是否对内容进行了修改。文中使用的图片或其他第三方素材均包含在知识共享许可范围内(除非特别说明出处)。若相关素材未纳入本文知识共享许可范围,且您的使用方式违反法律法规或超出许可范围,则需直接向版权方申请授权。如需查看该许可协议详情,请访问<http://creativecommons.org/licenses/by/4.0/>。

© 作者 2025