

MatterGPT: 一种用于固态材料多属性逆向设计的生成式Transformer模型

陈燕^{1*}、王雪如¹、邓晓斌²、刘一伦¹、Xi Chen²、张云伟³、雷王^{4,5*}、杭晓^{2*}

¹ 多尺度力学与医学科学实验室, SV LAB, 西安交通大学航空航天学院, 中国西安710049

² 岭南大学跨学科研究学院, 香港特别行政区屯门

³ 中山大学物理学院光电子材料与技术国家重点实验室, 广州市510275, 中国

⁴ 南京大学物理学院固态微结构国家实验室, 中国南京市210093

⁵ 南京大学先进微结构协同创新中心

中国南京市, 邮编: 210093

* 通讯作者。

电子邮件: yanchen@xjtu.edu.cn; leiwang@nju.edu.cn; hangxiao@ln.edu.hk。

摘要

针对具有特定性能的固态材料进行逆向设计, 是材料科学领域的一项重大挑战。尽管近期生成模型已展现出潜力, 但其应用仍受到效率低下、结构限制以及开源资源匮乏等局限性制约。通过采用切片(简化线输入晶体编码系统)符号化表示法将晶体结构转化为字符序列, 便能利用Transformer等前沿自然语言处理模型进行晶体设计。借鉴GPT模型在生成连贯文本方面的成功经验, 我们训练了一个生成式Transformer模型完成下一个词元预测任务, 从而生成具备目标性能的固态材料。我们展示了MatterGPT能够从头生成满足特定单一性能的晶体结构, 涵盖晶格无关性(形成能)与晶格敏感性(带隙)两种特性; 此外, 我们还扩展了MatterGPT的能力使其可同时针对多种性能参数进行设计, 有效解决了晶体多目标逆向设计这一复杂难题。我们的方法在生成结构方面展现出极高的有效性、独特性和创新性, 同时能够生成具备超出训练数据分布特性的材料。这项研究标志着计算材料发现领域的重要进展, 为设计适用于能源、电子等各领域的定制化材料提供了强大且开放的工具。

关键词: GPT; 切片; 固态材料; 按需生成; 逆向设计。

引言

材料科学领域的终极目标是设计出具有所需性能的材料——这一概念被称为逆向设计[1]。对于晶体材料而言，这一挑战尤为严峻：其可能结构的化学空间估计已达 10^{100} [2]量级，比药物类分子的化学空间大得多[3]。传统高通量筛选方法受限于现有数据库，难以高效探索庞大的潜在晶体结构化学空间[4]。晶体结构预测（CSP）已成为探索已知材料化学空间之外领域的一种有前景的方法。然而，CSP受到高昂计算成本的制约，且其中使用的许多全局优化算法具有随机性，可能导致构型空间的探索不完整或存在偏差[5]。

近年来，深度生成模型已成为无机材料逆向设计领域的强大工具，其中变分自编码器（VAE）[6]、生成对抗网络（GAN）[7]以及扩散模型[8]等各类架构均处于领先地位。早期基于三维图像或体素的晶体表示方法在可扩展性和准确性方面存在诸多局限：例如Noh等人提出了基于VAE的iMatGen模型，用于逆向生成VxOy晶体[9]；Long等人开发了基于GAN的ccdgan模型，用于生成新型二元Bi-Se晶体结构[10]；Court等人则提出CondDFC-VAE方法，能够通过从VAE潜在空间采样来生成新颖的晶体结构[11]。然而这些方法大多仅适用于特定结构体系，且常受高计算成本、内存占用大等限制，并容易产生无效结构。

为解决这些局限性，研究人员探索了其他表征方法。利用晶体图表示法，谢等人提出了CDVAE[12]——一种晶体扩散VAE框架，该框架通过在扩散过程中优化原子类型、坐标及周期晶格结构来直接重建稳定晶体。在此基础上，焦等人开发了DiffCSP[13]，实现了晶格与分数坐标空间的联合扩散计算。近期，微软研究院AI4Science团队推出了MatterGen[14]——该模型是对CDVAE的改进版本，能够生成具有所需特性的稳定新型晶体。然而，基于扩散的模型必须专门处理离散原子身份问题，且通常存在训练速度和采样效率较低的缺陷[15]；此外，MatterGen并非开源软件，限制了其在材料科学领域的广泛应用。替代方案包括任等人提出的可逆傅里叶变换晶体属性（FTCP）表征[16]，以及朱等人提出的融合威克夫特征表征的WyCryst模型[15]。尽管这些模型能够通过从VAE中采样具有属性结构的潜在空间，逆向设计出具有用户自定义特性的

独特晶体，但其可生成的晶体数量有限且成功率相对较低。尽管已取得这些进展，目前仍缺乏实用的晶体逆向设计框架，能够克服计算成本高昂、难以泛化至不同晶体体系以及难以高效生成符合预期特性的有效结构等局限性。

基于Transformer的模型最初在自然语言处理领域取得突破[17]，随后迅速发展并重塑了生物信息学、化学与材料科学等多个领域[18-22]。在分子设计领域，这些模型借助诸如微笑表情等表征方式[23]，彻底革新了结构生成与优化过程[24]。基于Transformer的方法为材料设计确立了新范式，MolGPT[25]、DNAGPT[26]、ProteinGPT[27]等模型便是明证。然而，将Transformer应用于晶体结构生成仍面临挑战，主要源于现有晶体表征方式的局限性：许多方法依赖晶体学信息文件（CIF）等传统格式，这些格式存在表征冗余且缺乏不变性。例如，CrystaLLM可为无机化合物生成CIF语法[28]，而Gruver等人则提出.....我们通过将晶体结构信息的字符串表示与任务特定的文本提示相结合[29]，对LLaMA-2 70B模型进行了优化以提升材料生成能力。这些方法的根本问题在于其对欧几里得变换的高度敏感性：同一晶体结构由于平移和旋转操作可能导致存在无数种CIF表示形式。这种冗余性严重制约了基于Transformer模型的效率，因为这类模型需要学习相同结构的多种表示方式。此外，大型语言模型（LLM）虽已被用于生成化学上有效的材料成分[30,31]，但往往难以捕捉决定材料性质的关键复杂空间信息。因此，亟需一种既可逆又对欧几里得变换具有不变性的更先进晶体表示方法。

为解决这些局限性，我们在前期工作中开发了简化的线性输入晶体编码系统（slices）[32]——这是一种创新的晶体表征方法。该系统提供了一种可逆且不变的“晶体语言”，类似于分子结构中的微笑符号，能够将晶体结构高效地编码为简单的字符串。在此基础上，我们现推出MatterGPT——一种预训练生成式Transformer解码器模型，专为按需从头生成固态材料而设计。通过将大语言模型与slices表征体系相结合，MatterGPT旨在突破现有晶体结构生成方法的局限性。该模型采用类似ChatGPT的自回归仅解码器Transformer架构，用于学习slices的语法特征以及晶体结构与其性质之间的内在关联。我们已验证MatterGPT具备生成具有特定单一属性（如形成能和带隙）的晶体结构的能力，并能同时针对多种属性进行生成。




图1. MatterGPT的架构结构。 **a**，基于条件式MatterGPT模型进行训练与采样的流程管线。**b**，将切片字符串输入仅包含自回归解码器的Transformer架构（配备掩码多头自注意力模块）前的预处理步骤：在每个切片字符串开头添加起始标记 $i>$ ，并在末尾填充标记 ' $<$ ' 以达到最大长度 N 。首先对切片字符串及目标属性进行嵌入处理后拼接在一起，并采用类型嵌入来区分二者；可训练的位置嵌入则用于捕捉标记间的顺序关系。

结果与讨论

基于单一属性的条件生成

Alex-20数据集源自亚历山大数据库[33]，包含每个晶胞原子数少于20个的材料。在剔除原子序数超过86的晶体、低维结构（0D、1D、2D）以及金属结构以避免偏差后，最终数据集共包含280,033种独特的晶体结构（详见材料与方法部分）。

在采样新型切片之前，我们首先训练MatterGPT模型以学习切片的语法结构及其彼此之间以及与对应属性之间的内在关系，如图1(a)所示。晶体语言切片由三个组成部分构成：原子符号、节点索引和边标签[32]。本研究中，我们采用83个原子符号、20个节点索引（0至19之间的整数）以及27个由3个字符组成的边标签（即‘+’、‘-’和‘o’）。在原始切片论文中，每个边标签均使用三个独立的标记符[32]；我们通过将这些标记符整合为单一标记符来改进该方法，显著缩短了序列长度并提升了学习效率。在MatterGPT模型中，我们共使用132个标记符，其中包含130个切片专用标记符及2个特殊标记符：起始标记符‘>’和填充标记符‘<’。每个切片字符串开头均添加起始标记符‘>’，所有切片字符串均用填充标记符‘<’填充至最大长度 N 。

在此，MatterGPT采用了类似ChatGPT的自回归仅解码器Transformer架构，并配备掩码多头自注意力模块[17]。该模型采用因果语言建模（CLM）目标进行训练，即预测序列中的下一个标记，以生成完整且语法连贯、符合预期特性的片段字符串。图1b展示了MatterGPT的具体架构，所有训练超参数详见表S1。在生成过程中，起始标记‘>’首先输入MatterGPT模型，并逐序列输出下一个标记序列；此过程在采样过程中迭代重复，直至生成长度达到最大值 N 的完整片段字符串，如图1a所示。




图2. 使用MatterGPT针对特定形成能（-1.0、-2.0、-3.0、-4.0 eV/原子）从头生成晶体。a为独特样品；b为新型样品。底部直方图展示了Alex-20数据集中每个原子的形成能分布情况。

对于晶体材料而言，其所有性质完全编码在其周期性晶胞中[34]。然而，生成模型在构建晶体结构时往往会产生一定的晶格误差，导致所学习的结构-性质关系存在偏差[35]。并非所有晶体结构的性质都严格依赖于晶格常数；部分性质对这些参数相对不敏感。因此，这些性质可分为两类：第一类包括那些对精确晶格常数和结构参数高度敏感的性质（如电子能带结构或声子频率），它们会因晶格尺寸的微小变化而发生显著改变；第二类性质则在不同晶格参数范围内保持稳定，更多受整体对称性和成分影响而非具体晶格尺寸，例如形成能、某些力学性质（如体积模量）以及部分光学性质。

表 1 MatterGPT 在目标属性方面的生成性能。

条件：状况	目标	有效性 (%)	独特性 (%)	新颖性 (%)	MAPE
形成能 (eV /原子)	-1.0	92.6	94.2	58.3	12.6
	-2.0	93.6	95.5	58.8	11.9
	-3.0	92.0	96.3	56.2	12.2
	-4.0	95.0	89.9	57.4	10.9
能带隙 (电子伏特)	1.0	94.4	97.2	41.0	51.1
	2.0	96.8	97.7	39.7	33.2
	3.0	95.0	97.3	40.7	31.4
	4.0	93.2	96.8	40.6	32.5

首先，我们以晶格不敏感特性——形成能 (E_f) 作为出发点，该参数是衡量晶体结构稳定性的主要指标之一[10,11, 36]。在训练过程中，目标属性的嵌入向量与切片嵌入向量进行拼接，并使用类型嵌入向量区分属性与切片。位置嵌入向量可训练且能捕捉标记序列的排列顺序，这与原始Transformer模型中采用的方法类似[17]（训练细节参见**材料与方法**部分，超参数信息见**表S1**）。在采样阶段，我们使用MatterGPT生成了500个针对特定 E_f 值（分别为-1.0、-2.0、-3.0和-4.0 eV/原子）的晶体结构；随后将生成的切片重构为晶体结构，并计算其有效性、唯一性和新颖性，以评估MatterGPT对目标属性的生成性能，具体结果如**表1**所示（详细评估标准参见**材料与方法**部分）。生成切片的

有效性均超过90%，表明MatterGPT模型能有效捕捉切片的语法结构；同时，生成切片的唯一性接近或高于90%，说明该模型倾向于生成独特的切片。此外，即使剔除训练数据集中的切片后，仍有超过半数的独特切片得以保留。需注意，在上述所有评估过程中，约4%无法还原为晶体结构的切片已被剔除。

接下来，我们按照Materials Project (MP) 数据库的工作流程，计算MatterGPT生成的晶体在Perdew-Burke-Ernzerhof (PBE) 能级下的形成能 E_f 。如图2a所示，MatterGPT成功为不同切片采样了具有目标 E_f 值的晶体。值得注意的是，当目标 E_f 设为-4.0 eV/原子时，尽管训练数据集中接近-4 eV/原子的数据有限，MatterGPT生成的晶体仍主要集中在目标值附近。各类目标值生成晶体的平均绝对百分比误差 (MAPE) 均略高于10%，表明模型在生成符合目标属性的输出结果方面具有较高准确性。此外，对于新切片而言， E_f 的分布同样以目标值为中心 (图2b)。这两种分布的相似性表明MatterGPT已有效掌握了晶体结构与形成能之间的内在关系，从而能够生成遵循训练数据集中相同结构-形成能关系规律的新晶体结构。




图3. MatterGPT通过靶向特定带隙实现从头晶体生成 $E_g = -1.0$ 、 -2.0 、 -3.0 、 -4.0 eV/原子。

a为独特样品；**b**为新型样品。底部直方图展示了Alex-20数据集中能带隙的分布情况。

为进一步展示MatterGPT在按需生成晶体方面的能力，我们训练了另一个针对晶格

敏感特性——能带隙 E_g 的MatterGPT模型；该参数对于理解材料的电子性质及其在半导体、光伏、氢气生产、储能材料等领域的潜在应用至关重要[37,38]。我们利用训练好的MatterGPT模型针对 E_g 分别生成了500个具有所需能带隙为1.0、2.0、3.0和4.0 eV的晶体。如表1所示，生成结果的有效性与唯一性均超过90%，而新颖性比率约为40%，显著低于形成能所观察到的数值。为获取生成晶体的 E_g 值，我们遵循MP数据库的工作流程计算PBE级别的 E_g （详见材料与方法）。图3显示生成晶体的值分布广泛地围绕目标值展开；此外，当目标 E_g 为2.0、3.0和4.0时，生成晶体的MAPE略高于30%。对于 E_g 为1.0 eV的情况，方向偏差约为50%，这表明生成模型在处理靠近金属-绝缘体转变区的目标材料时方向预测精度较低。结果还表明，针对晶格敏感特性进行晶体按需设计比针对晶格非敏感特性要困难得多。然而，这一结果凸显了我们逆向设计方法的有效性——尤其考虑到块体晶体带隙（ E_g ）对晶格扰动的高度敏感性，这通常使得捕捉带隙与晶体结构之间的内在关系成为一项挑战性任务[39, 40]。此外，考虑到训练数据集的分布偏态特征（即带隙值随数值趋近于零而逐渐集中），[41]所提出的MatterGPT模型能够有效捕捉固有的晶格信息，并学习晶体结构与带隙之间的关联关系。

在图4中，我们展示了三种通过从头计算生成的新晶体结构，其带隙分别最接近目标值of $E_g=1.0$ 、2.0、3.0和4.0 eV。这些材料的能带结构如图5所示。所展示的12种晶体涵盖了六方晶系、正交晶系、单斜晶系和三斜晶系等多种晶系类型，共计包含31种不同的元素。值得注意的是，该方法还可扩展应用于生成具有特定晶系或空间群的新型固态材料晶体[15]——即将晶体对称性信息作为附加条件纳入MatterGPT模型[29]。结果进一步表明，MatterGPT模型能够有效学习训练数据集提供的全面信息，从而在不受空间群、元素类型或其他因素特殊限制的情况下生成新型晶体结构。




图4. 三个新型从头生成且具有目标带隙的晶体的俯视图与侧视图。a-d分别对应 $E_g=1.0$ 、 2.0 、 3.0 和 4.0 eV 。每种生成晶体的PBE能级处能量带隙值均标注于下方。

MatterGPT的成功源于其切片表示方法的卓越性能——该方法能以94.95%的可逆率精准编码关键结构信息。这种对晶体结构的高度精确表征能力，使MatterGPT能够有效学习并解析晶体结构与其性质之间的复杂关系。基于这一特性，下文将展示MatterGPT同时针对多种属性进行逆向设计的能力。




图5. 新建晶体在 PBE 水平上的能带结构
图4.a-d, E_g 分别为1.0、2.0、3.0和4.0 eV。

基于多重属性的条件生成

在实际材料设计中，同时满足多种性能要求至关重要。[38]例如，热电材料必须在高热电品质因数、良好导电性与低热导率之间取得平衡[42]；磁性材料则需要具备高磁密度和较低的赫芬达尔-赫希曼指数（HHI）[14]；而超不可压缩晶体则必须保持稳定[43]。由于晶体具有庞大的设计空间、丰富的元素组合以及复杂的结构-性能关系，实现这些多性能目标尤其具有挑战性。

为应对这一挑战，我们展示了MatterGPT生成符合多种特性要求的从头晶体的能力，并以带隙（ E_g ）和形成能（ E_f ）作为典型示例。我们在Alex-20数据集上训练MatterGPT时，将 E_g 与 E_f 的嵌入向量与切片嵌入向量（图1b）进行了拼接。该模型架构与单属性版本保持一致。

为展示MatterGPT的性能，我们选取了两组属性组合：(-1.0 eV/原子, 2.0 eV) 和 (-4.0 eV/原子, 4.0 eV)（针对 E_g 、 E_f ）。后一组参数位于训练数据集的边缘区域（图6a），充分体现了模型的分布外生成能力。如图6b-c所示，MatterGPT能有效采样出围绕这些目标属性组合分布的晶体结构。需要说明的是，我们仅展示新颖晶体样本，因为独特样本与新颖样本之间的分布差异可忽略不计。图6d-e展示了三种具有最接近目

标值属性的新颖从头生成晶体，这些晶体涵盖了多种元素类型和空间群类型。我们还开发了基于训练好的MatterGPT模型的在线推断工具，支持用户根据指定参数直接生成晶体切片并将其转换为晶体文件（详见材料与方法中的“GUI演示”部分）。




图6. MatterGPT通过靶向所需 (E_g 、 E_f) 配对生成从头晶体。a: 来自Alex-20的训练数据集。**b-c:** MatterGPT针对 $(-1.0, 2.0)$ 和 $(-4.0, 4.0)$ 配对采样出的新晶体的形成能与能带隙分布；颜色表示核密度估计 (KDE) 图。**d-e:** 三个新从头生成晶体在目标配对 (E_g 、 E_f) 下的俯视图与侧视图。

结论与展望

具有所需特性的固态材料逆向设计长期以来一直是材料科学领域的一大挑战。尽管MatterGPT在这方面取得了重要进展，但由于训练数据有限，仍面临诸多困难。与基于分子结构数据（可利用数百万个分子结构）的模型不同，诸如Materials Project[44]、Jarvis[44]和Alexandria[33]等晶体数据库通常仅包含数万条记录。这种数据匮乏现状限制了MatterGPT的全部潜力，凸显了扩展晶体结构数据库以提升逆向设计能力的迫切需求。

尽管存在这些局限性，MatterGPT仍展现出卓越的通用性。它可针对特定任务进行

训练，例如高温超导体[45, 46]、能源相关材料[38]等。基于Transformer架构的可扩展性也使其能够应用于更广泛的通用任务。未来的发展方向可能包括并行切片序列回归与生成[47]、通过任务描述标记实现多任务处理功能[48]，以及通过多模态大语言模型整合推理、发现及生成能力[49]。这些进展将进一步提升MatterGPT在晶体设计和材料发现领域的应用价值。

MatterGPT展现出强大的按需晶体生成能力，在构建具有特定属性的结构以及同时优化多种性能方面表现卓越。作为完全开源项目，我们提供了完整的工具包，涵盖模型架构、模型权重、训练参数、训练数据、数据清洗代码、训练脚本以及后处理可视化工具。这一全面发布的版本为材料科学界提供了开放的实验平台，旨在加速计算材料发现与设计领域的协同研究进展。

材料与amp;方法

晶体的切片表示法

切片表示是一种可逆且不变的晶体表征方式，它编码了晶体信息的三个关键要素：原子符号、节点索引和边标签[32]。如图1所示，切片字符串在序列中嵌入了空格符号，只需在这些空格处分割字符串即可实现简单的分词处理。这种方法生成的分词结果可作为训练MatterGPT模型的输入数据。

将晶体结构编码为切片字符串的过程包括：使用Pymatgen[50]解析结构文件，采用晶体近邻（crystalnn）算法[51]构建结构图，并提取化学组成、键连接关系及平移向量以生成切片字符串。

将切片序列解码为晶体结构的过程采用SLI2Cry算法[32]，该算法包含三个步骤：(1)利用Eon公司的拓扑学方法生成初始结构；(2)基于改进型可极化力场预测的几何结构进行优化；(3)使用通用深度学习力场对结构进行精修。该流程成功重建了94.95%的原始晶体结构，既展现了切片序列的高度可逆性，又保持了其对平移、旋转和置换操作的不变性。

精选数据集

Alex-20数据集源自亚历山大数据库[33, 52]，最初包含每个晶胞原子数少于20个的材料。我们采用了多项过滤步骤以确保数据的质量与可处理性：

1. 元素组成：由于改良型 GFN -FF[53]在步骤中的局限性

(II) 在我们的SLI2Cry重建方案中，我们排除了含有原子序数超过86的原子的晶体[32]。

2. 结构维度分析：我们剔除了低维（0D、1D或2D）结构，因为我们在SLI2Cry重建方案步骤(I)中采用的Eon方法不适用于此类材料的碎片化商图[54]。

3. 金属排除法：为聚焦于半导体和绝缘材料，我们根据其电子特性排除了所有被归类为金属的结构，以避免对回归模型产生偏倚[55, 56]。

应用上述筛选标准后，本研究使用的最终Alex-20数据集包含280,033个独特的晶体结构。该精心整理的数据集确保所有纳入材料均适用于我们的分析，并能被我们的计算方法准确处理。对于Alex-20数据集，其切片词汇表共包含132个标记：其中83个原子符号、20个节点索引、27条边标签以及2个特殊标记（“>”表示起始位置，“<”表示填充位置）。这种全面的标记化方案使MatterGPT能够有效学习并生成多样化的晶体结构。

MatterGPT架构

MatterGPT模型从根本上基于生成式预训练Transformer（GPT）架构[19]，该架构由 n 个模块组成。每个模块均基于Transformer解码器结构构建，该结构包含一个掩码自注意力层以及一个全连接前向层。自注意力机制采用“缩放点积注意力”[17]进行计算，其表达式为：

$$\text{注意力}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V$$

其中 Q 、 K 和 V 分别表示查询矩阵、键矩阵和值矩阵，均源自自注意力机制中的同一输入。在交叉注意力机制中， Q 直接来自输入数据，而 K 和 V 则来自不同的来源。掩码自注意力机制确保序列中的每个标记仅关注前序标记而非后续标记，从而保持模型的自回归特性。

此外，MatterGPT模型采用了多头注意力机制，通过多个注意力头来捕捉标记之间关系的不同方面。每个注意力头均利用自身学习得到的线性投影函数，并分别对 Q 、 K 和 V 进行并行处理。这些注意力头的输出结果随后被拼接并经过线性变换，最终生成注意力输出，从而增强模型捕捉序列中多样化特征及依赖关系的能力。

在采样过程中，为提升MatterGPT的多样性和创造力，我们采用了Gumbel-Softmax采样方法——该方法通过设置采样温度 $T > 1.0$ [57]向预测的logit分布中引入可控噪声。

在我们的实现中，将 T 设为1.2。此外，我们还运用核采样（或top-p采样）来进一步增强采样多样性，同时保持流畅性和连贯性[58]。该方法通过从概率分布的顶端（由累积概率阈值 top_p 定义）抽取标记进行采样；在我们的实现中，将 top_p 设为0.9，确保生成过程中仅考虑累积概率前90%范围内的标记。

MatterGPT继承自Transformer模型，旨在具备高度可扩展性和适应性，适用于材料科学领域的多种任务。其架构能够处理不同规模的数据集，并能通过最小改动应对各种晶体设计挑战。

MatterGPT的实现方案

所有MatterGPT模型均采用Adam优化算法进行50轮训练，初始学习率设置为0.0001。训练参数包括：批量大小为60、嵌入维度为768、共12个Transformer解码器层（每层配备12个注意力头），最终可训练的超参数总数约为8000万个。学习率、批量大小及层数等所有超参数均通过网格搜索法进行精细调优，以确保最佳性能。

该模型采用PyTorch框架实现[59]。我们对MolGPT[25]和miniGPT（<https://github.com/karpathy/minGPT>）的开源代码进行了修改以实现MatterGPT的功能。本研究中的所有代码及数据均可在GitHub上获取（<https://github.com/xiaohang007/slices/tree/main/MatterGPT/>）。我们提供了Jupyter Notebook格式的教程，将代码与详细说明相结合。整个运行环境（包括 slices v2.0.0包及所有必要依赖项）均封装于Docker镜像中，确保结果可轻松复现并便于后续开发。MatterGPT的所有训练与采样操作均在 NVIDIA 4090 GPU上完成。

表 S1 MatterGPT模型的超参数。

优化器	AdamW
学习率	0.0001
批量大小	60
嵌入丢弃	0.1
注意力缺失	0.1
输出投影丢弃	0.1
嵌入大小	768
前馈大小	3072
注意力	12
层数	12

评估标准

晶体生成模型的性能评估采用四个标准：有效性、唯一性、新颖性和 MAPE 性。MatterGPT生成切片的有效性指满足所有切片表示语法要求的切片所占百分比；其唯一性则通过计算有效样本中唯一样本的比例来衡量（具体方法为先将样本转换为规范化的切片字符串，再去除重复项），该指标数值越高表明模型生成多样化样本的能力越强；新颖性则指生成样本中未存在于训练数据集中的新样本所占比例，该值通过使用 Pymatgen 软件包中的 StructureMatcher 工具[50]（默认参数设置：ltol=0.2、stol=0.3、angle tol=5）比较具有相同组成的每对结构之间的原子排列方式来计算得出。

为评估方向性的质量，我们计算了平均绝对百分比误差（MAPE）。

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{P_i - T}{T} \right| \times 100$$

其中 n 表示样本数量， P_i 表示通过密度泛函理论（DFT）计算得出的 MatterGPT 生成晶体的材料属性， T 表示目标值。

DFT计算工作流程

我们采用 Pymatgen 中实现的准时作业管理框架作为管理工具，用于处理包括错误检查、作业管理和错误恢复在内的各项任务[50]。所有密度泛函理论计算均使用维也纳从头算模拟软件包（VASP，版本6.3.1）[60]进行自旋极化计算。交换关联泛函采用 Perdew、Burke 和 Ernzerhof（PBE）参数化的投影增强波（PAW）方法[61][62]。所有计算参数均选择与 MP 数据库[33, 44]兼容。在进行形成能和带隙计算之前，所有结构均首先使用 Pymatgen 中的 MPRelaxSet 设置[50]，在不施加任何对称性约束的情况下进行弛豫处理。

在结构弛豫后，通过形成能计算获得了各化合物的总能量，并采用以下公式计算了每个原子的形成能：

$$E_f = \frac{E_{Total} - \sum n_i E_i}{\sum n_i}$$

其中 E_{Total} 为化合物的总能量， E_i 为元素在标准状态下的能量， n_i 表示化合物中元素 i 的原子数。

在进行能带隙计算时，经过结构弛豫处理后，我们使用MPStaticSet软件进行了自洽场（自洽场）计算以获得基态电子密度。随后根据Pymatgen的标准设置[50]，利用MPNonSCFSet软件沿布里渊区的高对称点计算了能带结构。能带隙由导带最低点（CBM）与价带最高点（VBM）之间的能量差决定。能带结构图通过Pymatgen的标准工具生成，可详细展示材料的电子特性。

图形界面演示

一款基于训练好的MatterGPT模型进行推理的简易网络应用程序已通过HuggingFace空间平台公开发布，访问地址为https://huggingface.co/spaces/xiaohang07/MatterGPT_CPU。该应用采用Gradio SDK[63]开发，其晶体可视化及基础信息分析功能均借助原子模拟环境（ASE）[64]实现。

CRedit作者贡献声明

陈燕：概念构思、方法论设计、调研实施、数据可视化、初稿撰写；修订与编辑；资金筹措；项目监督；修订与编辑。肖航：概念构思、方法论设计；修订与编辑；资金筹措；项目监督；修订与编辑。

利益冲突声明

作者声明，其不存在任何已知的可能影响本文所述研究工作的竞争性经济利益或个人关系。

致谢

陈燕感谢中国国家自然科学基金（项目编号：12302140）、中国中央高校基本科研业务费专项资金（项目编号：sxzy012023213）、中国博士后科学基金（项目编号：2023M732794）以及中国博士后科学基金博士后奖学金计划（B级）（项目编号：GZB20230575）提供的资金支持。

H.X.感谢中国科学技术协会第六期青年精英科学家资助计划（项目编号：2020QNRC001）及国家自然科学基金委员会（项目编号：22203066）提供的支持。

参考文献

- [1] A. Zunger, 《基于目标功能材料逆向设计》，《自然·化学评论》2(4)(2018) 0121。
- [2] A. 沃尔什, 《追求新功能》，《自然化学》7(4) (2015) 274–275。
- [3] J.-L. Reymond, 《化学空间项目》，《化学研究进展》第48卷第3期（2015年），第722–730页。

- [4] J. Noh, G.H. Gu, S. Kim, Y. Jung, 《基于机器辅助的无机固体材料逆向设计：前景与挑战》，《化学科学》11(19) (2019) 4871–4881。
- [5] K.T. Butler, J.M. Frost, J.M. Skelton, K.L. Svane, A. Walsh, 《晶体固体的计算材料设计》，《化学学会评论》45(22) (2016) 6138–6146。
- [6] D.P. Kingma, M. Welling, 《自编码变分贝叶斯方法》，arXiv预印本 arXiv:1312.6114 (2013)。
- [7] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, Y. Bengio, 《生成对抗网络》，《神经信息处理系统进展》第27卷 (2014年)。
- [8] 何杰、A·贾因、P·阿比尔, 《去噪扩散概率模型》，《神经信息处理系统进展》第33卷 (2020年) 第6840–6851页。
- [9] J. Noh, J. Kim, H.S. Stein, B. Sanchez-Lengeling, J.M. Gregoire, A. Aspuru-Guzik, Y. Jung, 《通过连续表示法对固态材料进行逆向设计》，《Matter》第1卷第5期 (2019年), 第1370–1384页。
- [10] T. Long, N.M. Fortunato, I. Opahle, Y. Zhang, I. Samathrakakis, C. Shen, O. Gutfleisch, H. Zhang: 用于晶体结构逆向设计的约束晶体深度卷积生成对抗网络, npj Comput. Mater. 7(1) (2021) 66。
- [11] C.J. Court, B. Yildirim, A. Jain, J.M. Cole, 《基于表示学习的三维无机晶体结构生成与性质预测》，《化学信息与建模杂志》60(10) (2020) 4518–4535。
- [12] 谢涛、傅晓、O.-E. 加内亚、R. 巴尔齐莱、T. 贾科拉, 《用于周期性材料生成的晶体扩散变分自编码器》，arXiv预印本 arXiv:2110.06197 (2021)。
- [13] 焦瑞、黄伟、林鹏、韩杰、陈鹏、卢勇、刘宇, 《基于联合等变扩散的晶体结构预测》，《神经信息处理系统进展》第36卷 (2024年)。
- [14] C. Zeni, R. Pinsler, D. Zugner, A. Fowler, M. Horton, X. Fu, S. Shysheya, J. Crabbe, L. Sun, J. Smith, 《Mattergen: 一种用于无机材料设计的生成模型》，arXiv预印本 arXiv:2312.03687 (2023年)。
- [15] 朱瑞、农伟、山崎盛、希帕尔加翁卡尔·K., 《WyCryst: Wyckoff无机晶体生成器框架》，可于 SSRN 4658842 (2023年) 获取。
- [16] 任 Z、田 S.I.P.、野 J、奥维多 F、邢 G、李 J、梁 Q、朱 R、阿伯勒 A.G.、孙 S: 具有目标特性的无机晶体通用逆向设计的可逆晶体学表征, 《Matter》第5卷第1期 (2022年) 第314–335页。
- [17] A.瓦斯瓦尼、N.沙泽尔、N.帕马尔、J.乌什科雷特、L.琼斯、A.N.戈麦斯、L.凯泽、I.波洛苏欣, 《注意力就是你所需的一切》，《神经信息处理系统进展》第30卷 (2017年)。
- [18] K.M. Jablonka, Q. Ai, A. Al-Feghali, S. Badhwar, J.D. Bocarsly, A.M. Bran, S. Bringuier, L.C. Brinson, K. Choudhary, D. Circi, 《大型语言模型如何改变材料科学与化学的14个实例：关于大型语言模型黑客松的思考》，《数字发现》 (2023年)。
- [19] A. 拉德福德、K. 纳拉辛汉、T. 萨利曼斯、I. 苏茨克弗, 《通过生成式预训练提升语言理解能力》 (2018)。
- [20] S. Noy, W. Zhang, 《生成式人工智能对生产力影响的实验证据》，《科学》381(6654) (2023) 187-192。
- [21] 王 Z、陈 A、陶 K、韩 Y、李 J, 《MatGPT: 从过去到现在再到未来的材料信息学范式》，《先进材料》(Adv. Mater.) (2023) 2306733。
- [22] 王杰、谢崇义、王明、王旭、吴哲、江丹、廖斌、张旭、杨博、何强, 《基于条件变换器、知识蒸馏与强化学习的多约束分子生成》，《自然·机器学习》3(10) (2021) 914-922。
- [23] D. Weininger, 《微笑：一种化学语言与信息系统》，《化学信息与计算机科学杂志》第28卷第1期 (1988年), 第31–36页。1. 方法论及编码规则介绍。

- [24] 胡勇、M.J. 布勒：用于解释性与预测性材料科学的深度语言模型，《APL机器学习》第1卷第1期（2023年）。
- [25] V. Bagal、R. Aggarwal、P. Vinod、U.D. Priyakumar，《MolGPT：基于变换器-解码器模型的分子生成》，《化学信息与建模杂志》62(9) (2021) 2064–2076。
- [26] D.张、W.张、B.何、J.张、C.秦、J.姚，DNAGPT：一种适用于多种DNA序列分析任务的通用预训练工具，bioRxiv（2023年）2023.07.11.548628。
- [27] 郭浩、霍明、张瑞、谢鹏，《ProteinChat：实现蛋白质三维结构上的ChatGPT级功能》（2023年）。
- [28] L.M. 安图内斯、K.T. 巴特勒、R. 格劳-克雷斯波，《基于自回归大型语言模型的晶体结构生成》，arXiv预印本 arXiv:2307.04340（2023年）。
- [29] N. Gruver、A. Sriram、A. Madotto、A.G. Wilson、C.L. Zitnick、Z. Ulissi：经过精细调校的语言模型可生成稳定的无机材料文本，arXiv预印本 arXiv:2402.04379（2024）。
- [30] 傅宁、魏磊、宋勇、李强、辛瑞、S.S. 奥米、董瑞、E.M.D. 西里瓦尔达内、胡杰，《材料变换器：用于生成式材料设计的深度学习语言模型》，《机器学习：科学技术》第4卷第1期（2023年）第015001页。
- [31] 魏磊、李强、宋宇、斯特凡诺夫·S.、董瑞、傅宁、西里瓦尔达内·E.M.、陈峰、胡杰，《晶体成分变换器：一种用于材料生成与优化设计的自学习神经语言模型》，《先进科学》(2024) 2304305。
- [32] 肖浩、李然、石旭、陈宇、朱磊、王磊、陈晓：一种基于生成式深度学习的固态材料逆向设计可逆且不变的晶体学表征方法（2023）。
- [33] J. 施密特、L. 佩特森、C. 维尔多齐、S. 博蒂、M. A. 马克斯：基于晶体图注意力网络的稳定材料预测，《科学进展》7(49)（2021）eabi7948。
- [34] C. 基特尔、P. 麦克尤恩，《固体物理学导论》，约翰威立出版社，2018年。
- [35] 龚思、严科、谢涛、邵宏、戈麦斯-邦巴雷利·R.、吉思、格罗斯曼·J.C.，《基于图神经网络的晶体结构分析：捕捉周期性的局限与机遇》，《科学进展》9(45)（2023）eadi3245。
- [36] F. Faber、A. Lindmaa、O. A. Von Lilienfeld、R. Armiento，《形成机器学习模型的晶体结构表征》，《国际量子化学杂志》115(16) (2015) 1094–1101。
- [37] A. 波尔曼、M. 奈特、E.C. 加内特、B. 艾勒、W.C. 辛克，《光伏材料：当前效率与未来挑战》，《科学》352(6283)（2016）aad4424。
- [38] A. Jain、Y. Shin、K. A. Persson，《基于密度泛函理论对能量材料的计算预测》，《自然·材料评论》1(1)（2016）1–13。
- [39] J. Heyd、J.E. Peralta、G.E. Scuseria、R.L. Martin：采用Heyd-Scuseria-Ernzerhof屏蔽混合泛函评估能带隙与晶格参数，《化学物理杂志》123(17)（2005年）。
- [40] T. 格林森、J. 哈泽尔、M. 利特尔约翰、C. 威廉姆斯，《III-V族四元合金的能带隙与晶格常数分布图》，《电子材料杂志》第7卷（1978年）第1–16页。
- [41] 卓勇、曼苏里·阿·特赫拉尼、伯格霍奇，基于机器学习预测无机固体的能带间隙，《物理化学快报》第9卷第7期（2018年）第1668–1673页。
- [42] G.J. 斯奈德、E.S. 托伯勒，《复杂热电材料》，《自然·材料》7(2)（2008）105–114。
- [43] G. Cheng、X.-G. Gong、W.-J. Yin：一种结合通用机器学习潜力、通用属性模型与优化算法实

现全空间逆材料设计的方法，《科学通报》（2024年）。

[44] A. Jain、S.P. Ong、G. Hautier、W. Chen、W.D. Richards、S. Dacek、S. Cholia、D. Gunter、D. Skinner、G. Ceder，《评论：材料项目——采用材料基因组学方法加速材料创新》，*APL Mater.* 1 (1) (2013) 011002。

[45] D. Wines、T. Xie、K. Choudhary，《基于数据驱动的深度生成模型进行下一代超导体逆向设计》，《物理化学快报》第14卷第29期（2023年），第6630–6638页。

[46] K. Choudhary、K. Garrity，《基于BCS激发屏蔽效应、密度泛函理论及深度学习设计高临界温度超导体》，《计算材料杂志》第8卷第1期（2022年）第244页。

[47] J. Born、M. Manica，《回归变换器可实现分子语言建模中的并发序列回归与生成》，《自然·机械智能》5(4) (2023) 432–444。

[48] R.K. Luu、M. Wysokowski、M.J. Buehler：利用扩散建模与变换器深度神经网络实现从头化学设计的生成式发现——以深共晶溶剂为例，《应用物理快报》122(23)(2023)。

[49] I. 斯图尔特、M. 布勒，《基于多智能体建模的多模态生成式人工智能分子分析与设计》（2024）。

[50] S.P. Ong、W.D. Richards、A. Jain、G. Hautier、M. Kocher、S. Cholia、D. Gunter、V.L. Chevrier、K.A. Persson、G. Ceder，《Python材料基因组学（pymatgen）：一个用于材料分析的稳健开源Python库》，《计算材料科学》第68卷（2013年），第314–319页。

[51] N.E. Zimmermann、A. Jain，《用于量化配位环境及晶体结构相似性的局部结构序参数与位点指纹特征》，《RSC Advances》10(10) (2020) 6063–6081。

[52] J. 施密特、N. 霍夫曼、H.C. 王、P. 博尔利多、P.J. 卡里科、T.F. 塞尔凯拉、S. 博蒂、M.A. 马克斯，《基于机器学习的材料全局零温相图测定》，《先进材料》35(22) (2023) 2210788。

[53] S. Spicher、S. Grimme，《材料、有机金属及生物化学体系的稳健原子级建模》，《Angew. Chem. Int. Ed.》59(36) (2020) 15665–15673。

[54] J.-G. Eon，《周期网的欧几里得嵌入：晶体结构拓扑诱导几何描述符完备集的定义》，《晶体学学报A辑：晶体学基础》67(1)（2011）68–86。

[55] S.G. Jung、G. Jung、J.M. Cole：基于梯度提升与统计特征选择的工作流程自动预测无机材料能带间隙，《化学信息与建模杂志》第64卷第4期（2024年），第1187–1200页。

[56] A. 塔拉帕特拉、B.P. 乌贝鲁阿加、C.R. 斯坦内克、G. 皮拉尼亚：基于机器学习的双钙钛矿氧化物带隙预测，《材料通讯》4(1) (2023) 46。

[57] E. Jang、S. Gu、B. Poole，《基于Gumbel-Softmax的分类变量重参数化》，arXiv预印本 arXiv:1611.01144（2016）。

[58] A. 霍尔茨曼、J. 布伊思、L. 杜、M. 福布斯、Y. 乔伊，《神经文本退化的奇特案例》，arXiv预印本 arXiv:1904.09751（2019年）。

[59] A. 帕斯克、S. 格罗斯、F. 马萨、A. 莱勒、J. 布拉德伯里、G. 查南、T. 基林、Z. 林、N. 吉梅尔沙因、L. 安蒂加，《Pytorch：一种命令式风格的高性能深度学习库》，《神经信息处理系统进展》第32卷（2019年）。

[60] G. Kresse、J. Furthmuller，《基于平面波基组的金属与半导体从头算总能量计算效率》，《计算材料科学》6(1)（1996）15–50。

[61] P.E. Blochl，《投影增强波方法》，《物理评论B辑》第50卷第24期（1994年）第17953页。

- [62] J.P.珀杜、K.伯克、M.埃尔恩泽霍夫，《简明广义梯度逼近法》，1996年。
- [63] A. 阿比德、A. 阿卜杜拉、A. 阿比德、D. 汗、A. 阿尔福赞、J. 佐，Gradio: 野生环境中机器学习模型的无干扰共享与测试，arXiv预印本 arXiv:1906.02569（2019）。
- [64] A.H. Larsen、J.J. Mortensen、J. Blomqvist、I.E. Castelli、R. Christensen、M. Dulak 、J. Friis、M.N. Groves、B. Hammer、C. Hargus，《原子模拟环境——一个用于处理原子的Python库》，《物理：凝聚态物质》29(27)(2017):273002。