

迈向自动化发现：逆向材料设计领域中生成模型、多模态学习与闭环工作流程的综述

阿南德·巴巴^{1,*}、罗杰里奥·阿尔梅达·戈维亚¹、詹-马可·里尼亚内塞^{1,2,*}

¹比利时鲁汶新天主教大学凝聚态与纳米科学研究所。

²WEL 研究所，巴斯德大道6号，瓦夫尔，比利时。

摘要

逆向材料设计正将材料发现方法从传统的前瞻性预测转向在物理约束条件下针对特定目标提出候选材料的定向方案。本文综述了晶体结构生成建模、多模态学习以及晶体固体闭环设计流程领域的最新进展，探讨现代生成器如何从大型数据库中学习化学-结构先验信息以实现周期性结构的可控采样，并对比了变分自编码器、归一化流、自回归模型及扩散模型等主流建模方法。特别关注了如何通过表征选择、训练目标设定、采样时间指导以及生成后筛选与优化等环节，在整个工作流程中有效落实可行性约束与物理先验条件。同时阐述了多模态学习如何整合晶体结构、热力学数据、电子信息、显微图像、光谱特征、加工环境信息及科学文献等多种数据维度，构建更具普适性且可迁移的化学空间表征体系。此外，我们还探讨了多种逆向设计策略，特别是那些将条件生成与潜在优化、贝叶斯优化、强化学习及主动学习相结合的策略。最后，我们重点分析了常见的失败模式（如替代指标滥用、多样性崩溃、分布偏移以及稳定性与可综合性的差距），并提出了基于有效性、新颖性、独特性、稳定性和成本等维度分阶段评估的发现级评价方法。

进展与潜力

人工智能驱动的材料发现正推动研究范式从以预测为中心的工作流程，向能够自主提出、评估并优化候选材料的自动化发现平台转型。生成建模、多模态学习、主动学习以及材料逆向设计均促进了这一转变，但其全部潜力取决于这些技术如何在具备验证意识的材料发现工作流程中协同作用。本综述整合了这些要素，阐明如何将候选材料生成、目标参数设定、验证成本及闭环反馈纳入统一的材料发现框架体系。这种整合至关重要，因为仅依赖快速筛选是远远不够的：人工智能工作流程可能生成看似有潜力但存在稳定性差、无法合成、物理约束条件支撑不足或基于过度优化的替代目标选取的候选材料。我们探讨了主要失效模式——稳定性与可合成性之间的差距，并展示了如何通过分阶段评估来诊断这些问题。因此，本综述为构建更可靠的自动化发现工作流程以应对未来材料领域的挑战提供了实用框架，并勾勒出实现自主驱动实验室的整合路径。

1 引言

材料发现领域正经历一场根本性变革，从传统的试错方法转向基于预定义功能需求的自主搜索策略。数十年来，主流工作流程始终遵循“提出成分或结构、计算或测量特性、迭代优化”的模式。近年来，机器学习（ML）与深度学习（DL）的突破性进展彻底重塑了这一循环效率：通过提供计算高效的预测模型、具备不确定性感知能力的选择策略以及能直接生成合理晶体结构的生成模型，这些技术革新显著提升了流程效能。这种转变重构了材料发现的本质——搜索不再局限于可枚举物质的筛选，而是以预设目标为指导，并受物理条件与实际可行性约束。逆向设计则通过明确哪些候选材料能够实现特定性能特征，重新定义了整个过程，将材料发现转化为定向搜索问题，引导研究聚焦于结构-成分空间中可能存在关键权衡关系的罕见区域。

这一转变得益于以数据为中心的材料研究体系：高通量计算与标准化工作流程使大规模材料评估成为常规操作；而大型开放数据库则使先验知识具备机器可读性且可重复利用[1–7]。与此同时，主动学习与不确定性感知决策机制为如何将资源密集型模拟和实验分配给最具信息价值的研究对象提供了系统化方法[8–14]。

与传统筛选方法不同，生成模型旨在通过学习对物理上合理结构的先验知识，从而使搜索过程从具有统计学和物理意义的区域开始。近期研究涵盖了多种模型家族及条件化策略，从旨在实现类似晶体结构预测（CSP）生成的深度生成模型[15–19]，到专为在更广泛的化学空间中进行可控设计而设计的通用型生成器[20–25]。

另一个同样重要的方面是：材料知识本质上具有多模态特性。用于理解、设计和验证材料的证据分散存在于多种形式中，包括结构描述、显微图像、衍射图谱、光谱数据、工艺记录、热力学参数、器件曲线以及科学文献等。多模态学习旨在将这些信息整合为比单一模态更稳健的表征形式；对于逆向设计而言尤为关键的是，这种表征形式更便于进行条件设定与约束参数定义[26–32]。

这些进展表明逆向材料设计可采用闭环范式：生成性预测模型与验证、合成及测量系统耦合，并根据成功或失败的结果进行迭代更新[33–36]。然而要实现这一愿景，还需在多个方面取得突破。逆向设计方法必须同时满足结构有效性、稳定性及目标功能性的多重约束条件，同时还要对分布偏移、数据集偏差以及定义不明确的目标保持稳健性。另一挑战在于：通过密度泛函理论（DFT）预测为稳定的材料并不总能通过实验实现——部分材料需要狭窄的生长窗口，部分受动力学势垒限制，还有些则会被更易形成的物相所取代。这种不匹配性使得严格评估至关重要。除目标性能评分外，逆向设计研究还应采用统一方案评估有效性、新颖性、独特性和稳定性，从而公平比较不同的闭环策略[37–39]。随着基础模型方法进入材料科学领域，这些问题将变得愈发重要，因为许多下游工作流程都将依赖共享的预训练先验知识与表示方法[40–43]。

在本综述中，我们重点阐述了生成式晶体结构建模、多模态表示学习以及逆向设计工作流程在自动化材料发现领域交叉领域的最新进展。讨论聚焦于逆向设计的核心要求：可操控性、约束满足性和可验证目标；随后比较了主要类型的生成式方法及其如何整合物理与化学约束条件，探讨了用于目标指定的多模态对齐策略以及可控逆向设计方法。




图1. 四个主要晶体结构生成模型家族的概述。 (a) 变分自编码器 (VAE)：编码器 $q_\phi(\mathbf{z}|\mathbf{x})$ 由参数 ϕ 定义，将晶体结构 $\mathbf{x}$ 映射为潜在代码 $\mathbf{z}$ 的后验分布，其特征为均值 μ 和方差 σ^2 。生成的潜在样本 $\mathbf{z} \sim q_\phi$ 被输入到解码器 $p_\theta(\mathbf{x}|\mathbf{z})$ 中，该解码器由参数 θ 定义，用于重构 $\hat{\mathbf{x}}$ 。训练过程可最大化证据下界 (ELBO)： $\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi}[\log p_\theta(\mathbf{x}|\mathbf{z})] - D_{KL}[q_\phi(\mathbf{z}|\mathbf{x}) \parallel N(\mathbf{0}, \mathbf{I})]$ ，其中 D_{KL} 是使后验分布向标准高斯先验 $N(\mathbf{0}, \mathbf{I})$ 近化的库尔巴克-莱布勒散度。生成过程涉及对 $\mathbf{z} \sim N(\mathbf{0}, \mathbf{I})$ 进行采样，并通过 p_θ 进行解码。(b) 生成对抗网络 (GAN)：生成器 G_θ 将潜在噪声 $\mathbf{z} \sim p(\mathbf{z})$ 转换为候选结构，而判别器 D_ϕ 则估计 P (真实概率)，即样本源自真实晶体分布 p_{data} 的概率。两个网络通过面板顶部所示的极小极大目标函数联合优化；判别器的对抗损失信号会反向传播至上层网络。日期 G_θ 。(c) 归一化流 (NF)：由 K 个可学习的可逆双射函数 $\{f_1, \dots, f_K\}$ 组成的序列，通过变量变换关系： $\log p(\mathbf{x}) = \log p(\mathbf{z}) + \sum_{k=1}^K \log |\det \partial f_k / \partial \mathbf{z}_k|$ ，将高斯基础分布 $p(\mathbf{z}) = N(\mathbf{0}, \mathbf{I})$ 映射到晶体分布 $p(\mathbf{x})$ 。其中每个雅可比项表示第 k 步的体积变化。由于每个 f_k 具有可逆性，该架构同时支持生成过程 (从潜在变量到数据，从左到右) 和精确推断 (从数据到潜在变量，从右到左)。(d) 去噪扩散概率模型 (DDPM)：前向 (噪声化) 过程 $q(\mathbf{x}_t | \mathbf{x}_{t-1}) = N(\sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$ 会通过 T 步骤，按照噪声调度 $\{\beta_t\}$ 将晶体 $\mathbf{x}_0$ 逐渐转化为高斯噪声 $\mathbf{x}_T$ 。学习得到的逆向 (去噪) 过程 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = N(\mu_\theta(\mathbf{x}_t, t), \sigma_\theta^2(\mathbf{x}_t, t))$ 通过评分网络 $\varepsilon_\theta(\mathbf{x}_t, t)$ 进行参数化，该网络可预测每一步的噪声成分，从而实现从噪声中迭代恢复晶体提案 $\hat{\mathbf{x}}_0$ 。在所有图示中， ϕ 和 θ 表示可训练的网络参数。

该图明确了评估原则并概述了关键挑战，这些因素将决定这些系统能否可靠地加速材料发现，而非仅生成合理的样品。图1展示了主要晶体结构生成模型家族的概览。

2 逆向材料设计作为一种闭环框架

逆向材料设计重新定义了材料探索的本质：从预测给定候选材料的特性，转变为在约束条件下寻找满足设计目标的候选材料。在正向建模中，通常需要学习映射 $\hat{y}(x)$ 或分布 $p(y | x)$ ，其中 x 表示候选材料（成分与结构）， y 表示目标属性（功能特性、稳定性裕度、成本或其他设计准则）。而在逆向设计中，目标转向于寻找既能满足所需属性又具备可行性条件的候选材料 x [8, 44–45]。

该过程可正式表述为在可行性条件下的目标优化问题：

$$x^* \in \arg \max_{x \in X \cap C} U(x) \quad (1)$$

其中 X 表示候选设计空间， C 代表受严格物理、化学及合成要求（包括热力学稳定性与结构完整性）约束的可行流形， x^* 表示最优候选方案， $U(x)$ 为编码所需单目标或多目标设计目标的效用函数。此处可行性可能涵盖几何有效性、电荷平衡、稳定性准则、对称性、密度以及可合成性指标[8, 37]。

2.1 提案评估反馈作为运营循环环节

从操作层面而言，逆向设计遵循一个包含三个主要步骤的迭代循环[8, 33, 46–47]：

1. **提案**：采用条件生成、潜在采样、启发式枚举或物理驱动全局优化等提案机制生成候选材料[37]。
2. **评估**：采用多层次模型与筛选标准对候选方案进行评分，通常从低成本的有效性验证开始，逐步使用替代预测指标，最终进行高保真度验证（包括松弛处理、密度泛函理论、高级模拟或定向实验）[8]。
3. **反馈**：根据结果（包括失败案例）更新改进方案与评估方法，使后续迭代能够将精力集中于具有潜力的领域，同时保持足够的多样性及合理的不确定性水平[8, 38]。

这些步骤定义了自动化材料发现的运行流程，其目标是在整个发现过程中最大限度减少人工干预。

2.2 逆向设计为何如此困难？

逆向设计极具挑战性，因为它不仅仅是一个预测问题，而是在一个庞大、结构化且往往行为复杂的设计空间中进行的约束搜索问题。从操作层面来看，成功不仅取决于找到具有理想预测特性的候选方案，更需要确保这些方案在物理上合理、化学上可行，并且值得投入后续验证的成本。这导致了若干在正向建模中不存在的失败模式：

约束主导性：许多可行性约束条件具有较高难度：轻微违反这些约束可能导致非物理结构或无效的化学反应。几何合理性（如无重叠、符合实际的原子间距离、合理的密度）、化学合理性、电荷中性和对称性一致性往往决定了后续评估是否具有意义。因此，约束处理定义了有效的搜索空间[37]。在等式（1）中，这相当于将候选空间从 X 限制到可行区域 $X \cap C$ 。

优化过程引发的失效模式：在逆向设计过程中，搜索流程可能利用预测模型的缺陷。随着候选方案生成策略日益激进，该方法可能会提出偏离训练阶段所见示例类型、进入模型预测可

靠性较低区域的材料方案。这可能导致表面看似改进的结果在后续验证中无法成立。为降低此类风险，逆向设计工作流程需要采用考虑约束条件的目标函数、基于不确定性评估的候选方案筛选机制，并将验证步骤直接嵌入设计循环中[8, 37]。

验证瓶颈：生成模型能够以较低成本生成候选方案，且通常内置了稳定性评估目标或过滤机制。然而，探索过程仍受限于高保真验证所需的计算资源消耗，例如结构松弛分析、严格的稳定性评估以及（在适用情况下）合成与表征分析。因此逆向设计本质上也是一个预算分配问题：必须将有限的验证资源分配给那些同时具备潜力、可行性及信息价值的候选方案，同时避免降低多样性[33, 38]。

2.3 定向搜索算法：路线图

这一提案-评估-反馈循环过程可通过多种算法框架进行调控，这些框架在代价高昂的验证条件下需在可控性、多样性和样本效率之间取得平衡。本文综述重点探讨潜在空间优化、引导扩散采样、学习嵌入中的贝叶斯优化、强化学习策略搜索以及基于生成循环的主动学习方法，并从其控制参数设置、约束条件处理方式以及在优化压力下的典型失效模式等方面（第5.2–5.6节）进行了详细分析[8–14, 38, 48]。

2.4 在这一过程中，方案制定、多模式协同与优化设计发挥着关键作用。

该评估体系的每个组成部分都在闭环逆向设计框架中扮演独特角色。晶体结构生成器（第3节）作为**提案引擎**：通过从已学习到的合理晶体先验分布中采样，并结合条件化信号引导，将设计意图转化为候选结构；多模态学习（第4节）充当**设计接口**：它将异构的证据数据（包括结构信息、光谱特征、文本描述及处理背景）整合至共享表征空间，从而实现目标设定、候选结构检索以及基于更丰富设计意图的生成；优化框架（第5节）是**搜索策略**，负责分配验证预算、更新提案策略并收敛至高实用性可行候选方案；评估与部署模块（第6节）提供**真实反馈**，防止替代指标被滥用，确保新颖性与稳定性声明的可信度，并最终判定设计方案能否转化为可实验实现的材料。理解这四种角色如何相互作用以及各自可能出现的缺陷，是本综述的核心主题。

3. 作为材料提案引擎的晶体结构生成

采用逆向材料设计的生成式晶体建模至关重要，它可将候选结构的生成过程从组合性的瓶颈环节转变为可控且数据驱动的操作流程。与传统方法逐一枚举候选结构并进行排序不同，生成模型能够学习合理周期结构的分布规律，并引导采样过程朝向目标参数和可行性约束方向发展。这一特性在以下场景中尤为实用：当化学空间过于庞大无法进行全面筛选、需要同时满足多重约束条件时；或当验证预算限制了可测试候选结构的数量时[15–21, 23, 37, 49–50]。

3.1 生成有效晶体的意义何在

周期性晶体可形式化为一个元组。

$$x = (\mathbf{L}, \mathbf{Z}, \mathbf{S}) \quad (2)$$

其中 $\mathbf{L} \in \mathbb{R}^{3 \times 3}$ 为晶格矩阵， $\mathbf{Z} = (Z_1, \dots, Z_N) \in \mathcal{AN}$ 表示位于 N 个晶体位点上的原子种类（例如原子序数），而 $\mathbf{S} = [\mathbf{s}_1, \dots, \mathbf{s}_N]^\top \in [0,1)^{N \times 3}$ 为分数坐标。实空间位置关系如下：

$$\mathbf{r}_i = \mathbf{L} \mathbf{s}_i, \text{ 其中 } i = 1, \dots, N \quad (3)$$

通过定义 $\mathbf{s}_i \equiv \mathbf{s}_i + \mathbf{n}$ （其中 $\mathbf{n} \in \mathbb{Z}^3$ ）来实现周期性。

在此表示方法中，晶体生成相当于学习此类元组上的分布： $x \sim p_{\theta}(x)$ ；或（对于逆向设

$$\text{计）} x \sim p_{\theta}(x | y)。 \quad (4)$$

其中 y 用于编码设计意图（目标特性、组成结构、对称性特征或其他约束条件）。对称性可通过将 $(\mathbf{L}, \mathbf{S})$ 限制在空间群一致的参数化范围内（例如Wyckoff自由度）来实现；而化学合理性则可在采样与筛选过程中通过电荷中性或氧化态约束来确保[37, 51]。

这种结构使得晶体生成在本质上与标准分子生成方式存在显著差异：周期性边界条件将局部配位情况与全局晶胞参数相耦合，且可行性约束条件往往较为严苛（例如重叠、不现实的密度值或不一致的配位模式）。因此，生成器所采用的表示方法会强烈决定：(i)哪些约束条件能够被有效施加；以及(ii)在约束条件设定和优化过程中会出现哪些失效模式[37]。目前普遍采用以下步骤：

1. **连续几何表示法**：在此方法中，晶格参数和分数原子坐标均直接进行参数化。该表示法非常适合基于梯度的引导控制及扩散驱动采样，但需要仔细处理其不变性及物理有效性[16–17, 19, 23]。
2. **离散表示法**：结构以序列形式进行序列化处理，例如采用类似CIF的标记形式。该表示方法可利用自回归建模并自然地与文本结合，但必须通过约束性解码及生成后筛选（如对称性检查、化学有效性过滤器以及基于MLIP或DFT的松弛处理）来确保物理有效性[49, 52–53]。
3. **对称性感知表示法**：晶体通过空间群和维科夫位置进行编码，这种编码方式在构建上能确保整体结构的一致性，但在存在无序结构、缺陷或低对称性目标时可能限制其灵活性[37]。

3.2 生成模型家族及其逆向设计权衡关系

多种生成模型家族已被应用于周期性晶体的研究。在最基本的层面，生成模型可学习晶体候选结构的概率分布。

$$x \sim p_{\theta}(x) \quad (5)$$

其中 x 表示晶体结构， θ 表示模型参数。在逆向设计中，我们通常需要满足预定义条件 c 的候选方案（例如目标成分、对称类或所需性能范围）。因此该问题转化为条件生成问题。

$$x \sim p_{\theta}(x | c) \quad (6)$$

换言之，这是一种引导式生成方法，能够在保持可行性的同时，使样本朝着更高的设计实用性方向发展。

对于逆向设计而言，模型的价值不仅在于其能生成合理的晶体结构，更在于它能够被引导至目标方向、整合物理与化学约束条件，并且在超出训练数据分布范围时仍保持可靠性[15–17, 20–21, 37, 49]。

早期的三维网格、体素及生成对抗网络（GAN）生成器：最早的一批晶体生成器借鉴了计算机视觉领域的理念。晶体被表示为三维网格或张量结构，生成模型则通过训练来生成这些体积化表征。从概念层面而言，这些方法具有重要意义，因为它们确立了晶体生成可以被表述为可学习的生成问题，而非单纯的穷举枚举。然而在实际应用中，这类模型往往难以应对晶体物质的独特结构——周期性特征、精确化学计量比、原子种类以及物理意义明确的坐标参数，并非通用图像风格生成器能够自然满足。因此通常需要进行大量后处理才能恢复晶体的周期性结构并确保基本化学有效性[54–55]。

潜变量生成器：潜变量模型为每个晶体引入一个连续的隐藏表示 z ：

$$z \sim p(z), \quad x \sim p_{\theta}(x | z) \quad (7)$$

其中 z 是从先验分布 $p(z)$ 中采样的潜在代码，而 $p_{\theta}(x | z)$ 是由 θ 参数化的条件解码器。关键在于，潜在空间中的邻近性反映了晶体之间的结构相似性，从而有助于插值计算、可控扰动及优化过程。在逆向设计中，通常会在潜在空间而非直接在晶体空间中进行搜索：

$$z^* \in \arg \max_z U(g_{\theta}(z)) \quad (8)$$

其中 g_{θ} 表示解码器， $U(\cdot)$ 为目标依赖型效用函数。这一特性使得潜在变量模型特别适用于提案与优化流程——即先生成候选结构，再根据预期目标进行调整。扩散编码器VAE通过采用更强的解码器进一步拓展了这一思路，通常能显著提升样本质量。其主要局限在于：若在搜索过程中未引入先验分布、可行性过滤条件或显式约束[16, 23]，潜在空间中的优化过程可能导致解码结构偏离化学或物理层面合理的区域。

归一化流：基于流的模型能够在简单的基础分布与晶体表示之间学习一个可逆映射关系：

$$z \sim \mathcal{N}(0, I), \quad x = f_{\theta}(z), \quad \log p_{\theta}(x) = \log p(z) + \log \left| \det \frac{\partial f_{\theta}^{-1}(x)}{\partial x} \right| \quad (9)$$

其中 f_{θ} 为可学习的可逆双射（流）， $p(z) = \mathcal{N}(0, I)$ 表示高斯基础分布， I 代表单位协方差矩阵；雅可比项为 $\log |\det \mathcal{J}_{f_{\theta}^{-1}}|$ 反映了变换过程中的体积变化。由于该变换具有可逆性，流方法能够提供精确的似然函数、高效的采样方案以及直接的潜在变量操控能力。在逆向设计中，当约束条件或条件信号可以直接纳入采样过程时，这种方法尤为实用。流方法的优势在于其数学表达清晰且密度建模易于处理；其局限性则更为实际：晶体结构具有高度结构性，在完全可逆框架内施加对称性、原子离散性及严格可行性条件往往并非易事[21]。

自回归序列模型：自回归模型将晶体视为一系列标记，并逐步进行生成分解：

$$p_{\theta}(x \mid c) = \prod_{t=1}^T p_{\theta}(x_t \mid x_{<t}, c) \quad (10)$$

其中 x_t 表示晶体序列中的第 t 个标记， $x_{<t} = (x_1, \dots, x_{t-1})$ 表示位置 t 之前的所有标记， c 为可选的条件信息（如组成或对称性线索）， T 为序列总长度。在晶体应用中，这些标记可能对应于类似CIF的语法结构、结构描述符或序列化的几何信息。该方法体系的主要优势在于其灵活的条件化能力：组成信息、对称性线索或文本衍生提示均可自然地融入序列生成过程。这使得自回归模型在设计界面包含离散规范或需要与科学语言直接对接时尤为适用。其不足之处同样显著：句法正确性并不等同于物理正确性；外观合理的序列并不能保证几何合理性、电荷平衡或低能量结构。在实际应用中，这些模型通常依赖解码器、规则或生成后筛选机制，以确保句法正确的输出结果同时具备科学意义[49]。

扩散模型与基于评分的生成器：扩散模型之所以备受关注，是因为它们既能模拟复杂的高维分布，又能支持渐进且可控的生成过程。简而言之，这类模型能够逆向处理噪声生成过程。

$$x_T \rightarrow x_{T-1} \rightarrow \dots \rightarrow x_0 \quad (11)$$

其中 x_T 表示完全含噪声的样本， x_0 为纯净的晶体候选结构，而中间状态 x_t 则代表沿逆向轨迹逐步去噪后的结构。该方法从噪声状态出发，通过迭代去噪过程逐步逼近晶体候选结构。逆向设计可通过采样过程中的条件去噪或引导机制实现；例如可利用目标评分来指导逆向过程。扩散模型的优势在于能够在满足目标属性、对称性或成分约束的同时保持多样性；其核心优势在于能够实现复杂约束下的可控采样。然而，该模型易受引导机制导致的脆性影响：来自不完美预测器的过度激进信号可能生成在计算机模拟中看似最优但在外部验证中失效的候选结构[17, 56–57]。

这些模型家族在架构、表示方式和优化风格上各不相同，但其带来的实践启示却更为广泛。没有任何单一模型家族能够独立解决逆向设计问题。一个有效的提案引擎不仅需要生成候选方案，还必须与可行性控制、不确定性感知排序以及下游验证过程保持兼容。换言之，关键点不仅在于哪个模型家族能生成最真实的晶体样本，更在于哪个模型家族能最有效地融入闭环发现工作流程——该流程要求候选方案需经过引导与约束优化、可行性筛选、高保真验证以及迭代模型反馈等环节。因此最佳选择取决于具体研究场景：问题是否需要严格的可控性、难以处理的约束条件能否轻松整合、高效的潜在参数优化能力、离散提示条件设置能力，或是昂贵验证条件下稳健的引导采样能力[37–39]。

逆向设计仅在目标条件下的候选结构在生成后仍保持物理可行性和可验证性时才具有实用价值。因此，评估条件设置的实际效用不仅需考察模型是否能将样本导向预期目标，还需考量这些样本是否满足设定约束条件、保持化学与结构多样性，并能经受后续的松弛处理或验证步骤（如几何优化、稳定性筛选或高精度计算）[9, 37, 39]。

表1.晶体结构生成的算法家族：学习范式与结构表示方法。

家庭	核心学习理念	典型表示法
VAE 模型与潜在变量模型 [16, 23]	ELBO 最大化；逆向设计中的隐式遍历	晶格、坐标及物种作为连续的潜在编码
自回归变换器 [22, 49]	$p(\mathbf{x})$ 在离散标记上的自回归因子分解	CIF或结构标记（原子类型、坐标、对称性）
归一化流[21]	通过可逆双射获得的精确似然值	可逆变换下的连续晶体学描述符
扩散与..... 基于分数的 模型[17, 20, 24–25]	评分网络逆转了前向噪声效应 过程	原子、晶格以及相关物质状态 联合扩散
生成对抗网络[54–55]	对抗性训练；无明确似然函数	体素网格或单元胞潜在编码
基于能量的强化学习方法 杂交种[37, 58]	基于物理学原理的奖励机制能够有效引导用户行为。 生成先验	具有扩散特性的骨架结构 代理属性模型

3.3 约束条件的界定：效度与可行性的阶段性审视

一个核心的实际问题是物理约束何时被施加。对于以材料发现为导向的工作流程而言，将约束处理视为分阶段流程进行处理是十分有益的。

*阶段A：表示层面的约束。*表示方法能够强制实现不变性或全局结构（包括考虑对称性的参数化），从而减少源端的无效自由度[37]。

*第B阶段：训练时间限制。*可通过损失函数、先验分布或正则化项来促进模型可行性，这些机制能惩罚不合理的几何结构或化学构型，从而提升样本的平均质量[37, 51, 56]。

*第C阶段：采样时间约束。*这些约束可在采样过程中实施（如引导扩散法、约束性解码规则），而这正是实践中实现逆向设计可控性的常见途径。

*第D阶段：生成后筛选与验证。*结构生成完成后，候选结构必须通过严格的可行性验证，包括距离与密度检查、适用情况下的电荷中性或氧化态合理性验证以及基本键合合理性检查。随后需进行弛豫计算与稳定性评估（例如采用 MLIP、力场或基于DFT的方法进行验证），并包含振动稳定性筛选以识别动态不稳定的候选结构，方能提出新的结构发现声明[37, 90]。

表1和表2汇总了四个阶段中所有主要的晶体生成算法家族：表1概述了它们的统计学习目标与结构表示方法，而表2则阐述了其在逆向设计应用中的实际优势及常见缺陷。

表2.晶体结构生成家族的实际权衡关系及逆向设计作用。

家庭	核心优势	常见的失效模式	逆向设计任务
VAE；以及 潜在变量模型	平滑潜在空间； 梯度特性转向	有效性漂移；后验 倒塌	潜在空间 最优化
自回归 Transformer	灵活的条件设定 组成或文本	长程一致性失效； 需要进行后代筛查。	条件生成 从结构或文本层面来看
归一化流	精确概率；直接潜在操控	可逆架构中非平凡的硬约束条件	似然评分；后验引 导优化
扩散与..... 基于分数的 模型	高质量与多样性； CFG 导引；等变 对称	采样成本高昂；效果不佳 适用于大型细胞	从头生成（新数据） 房产投资指南
生成对抗网络（GANs）	快速单次采样	模式崩溃；有效性未强制要求	高通量 候选人预筛选
基于能源的； RL杂交种	使用以下方式实现目标： 基于物理原理的选择	奖励黑客；稀疏 反馈	靶向抽样 在属性约束条件下

4 多模态学习作为逆向设计的通用化学学习潜在空间

多模态学习旨在通过共享表示空间内不同形式的数据进行联合学习。在逆向设计领域，面临的挑战不仅在于化学空间的庞大规模，更在于材料相关证据分散存在于多种模态中——包括晶体结构、成分组成、实测与计算性质数据、显微图像、光谱分析结果、加工条件以及科学文献等。多模态学习通过构建统一的表征空间（即一种通用描述语言）来解决这种碎片化问题，使这些异构化的描述能够实现可比性和互操作性[26–27, 29–32, 40, 59]。

在本综述中，我们使用“通用化学学习潜在空间”这一术语来指代具有以下三个实用特性的化学空间学习映射：

- 一致性：**对同一材料的不同描述（例如结构与文本、或工艺过程与显微图像）均被归入兼容的位置。[26, 31, 60–61]
- 属性感知：**空间中相邻的材料往往具有相似的行为特征，多个属性可联合表示而非逐一呈现。[27, 39–40, 43]
- 设计可用性：**该空间能够在实际约束条件下支持前文已讨论的主要逆向设计操作——设定目标、检索相关证据以及生成候选材料。[22–23, 26–27, 50]

图2展示了多模态材料机器学习工作流程：多种输入模态（晶体结构、成分信息、微观结构图像、文本数据）被整合到一个共享模型中，该模型支持性能预测、跨模态检索及材料设计。

实际上，没有任何单一模态能够全面反映材料的完整状态。结构特征、物理性质、加工历史、实验数据以及计算表征结果各自仅能提供部分信息，唯有将这些信息综合起来，才能为材料的理解与设计奠定更完整的基础。因此，多模态学习具有重要价值——它能将这些分散的证据形式整合到一个共享的表征空间中，使不同模态的信息能够相互补充、相互制约、相互印证。对于逆向设计而言这一点尤为关键：因为有潜力的候选方案往往需要基于多个部分信息量




图2. 多模态材料机器学习工作流程示意图。该框架将五种不同的输入模态编码并融合为统一的多模态 *ML* 模型，包括：（i）以原子图或晶体学信息文件（*CIF*）形式编码的晶体结构；（ii）成分数据（含元素比例及衍生描述符）；（iii）显微图像（如扫描电子显微镜（*SEM*）、透射电子显微镜（*TEM*）及光学显微照片）；（iv）从科学文献和实验报告中提取的文本数据；以及（v）基于等变图神经网络嵌入和结构稳定性评估得出的物理信号。在此整合空间中可实现三项下游任务：性质预测（如带隙、热力学稳定性）；跨模态检索（通过结构、图像和文本联合查询识别化学结构相似的候选物）；以及基于共享潜在空间的大规模基础模型生成进行材料设计。核心模型作为关键支撑组件：通过将这五种异构模态整合至统一表征中，它能够在单一统一框架内支持目标指定、候选排序及约束生成。

的信号进行评估，而非仅依赖单一描述；同时，许多高价值模态仍存在分布稀疏、获取成本高昂或难以获得等问题[26, 29, 31–32, 40, 47, 59]。

4.1 通用空间对逆向设计的作用：推理、探索与创造

我们可以将多模态技术与它所支持的三种发现操作相结合：

- 原因：**多模态模型能够根据可用的任何证据推断出物质特性，并整合那些原本可能孤立存在的信号——例如通过将处理条件与微观结构相关联，进而与物质特性建立联系。这样一来，即使现有证据不完整或存在噪声，这些模型也能支持更为连贯的推理过程[26–27, 31, 62]。
- 搜索：**当异质性证据被置于共享空间后，多模态学习可实现跨模态检索：用户可通过文本、部分测量数据或结构信息进行查询，并根据模型学习到的化学相似性概念检索邻近材料。这一方法对于类比发现以及在实验或计算资源有限的情况下对候选对象进行排序或优先级划分具有重要应用价值[26–27, 30, 40, 60–61]。
- 创建：**当一个通用空间与材料提案框架相结合时（无论是通过将生成器与共享表示条件关联以生成符合预期属性的结构，还是通过遍历该空间直至达到目标行为后再解码候选材料），它便成为一种设计工具。文本引导生成和多模态条件生成便是这一方向的具体范例。[22, 26, 28]

表3.典型晶体结构生成模型及其在通用化学学习空间中的作用：结构表示与核心机制。各模型按家族类型排序，并在文中作为支持上述推理-搜索-创建操作的生成平台示例进行引用。

模型	表示	核心机制
3D GAN生成器 ^[54–55]	三维网格或离散化单元格	具有周期性的对抗性训练后处理
CDVAE ^[16]	周期图、分数坐标、晶格	采用扩散解码器的VAE；周期性所强制实施的不变性条件
DiffCSP ^[17]	分数坐标，晶格	晶格与原子位置的等变去噪
自监督生成模型 ^[37] 讲台	SE(3)等变性 变压器潜在空间	基于对抗性可靠性信号的自监督训练方法
CrystaLLM ^[49]	CIF语法作为离散标记	自回归CIF模型；输出结果可通过重新排序进行调整
Chemeleon ^[22]	对齐文本与晶体嵌入	对比性文本结构对齐； 文本条件扩散
MatterGen ^[20]	原子、坐标、联合扩散下的晶格	基础扩散模型；适配器 微调；CFG与推理
CrystalFlow ^[21]	周期性晶体空间上的可逆映射	精确似然流；直接潜在模型操作
主动学习循环 ^[12, 48]	具有主动学习功能的扩散生成器	迭代生成-评分-标注-松弛-微调循环
基于变换的扩散 ^[20, 24–25]	基于晶体标记的变压器去噪技术	联合晶格与原子建模；其规模与Transformer的容量成正比

表3提供了支撑这三种功能的代表性晶体结构生成器的系统级参考框架，清晰展示了其核心表示形式与内部工作机制。

4.2 承担多种功能角色的多模态模型

多模态学习对于逆向材料设计正变得日益重要，因为材料发现所需的信息很少仅存在于单一模态中。从逆向设计的角度来看，关键问题不仅在于不同模态能否结合使用，更在于这种结合是否能强化特定的操作功能：*评估、检索、文本引导式提案*。

多模态评估方法：部分模型主要通过融合互补信息源来提升性质预测或候选物排序能力，从而强化评估环节。^[62]CrysMMNet将结构编码器与精心设计的文本描述符相结合，实现性质预测中的多模态融合。现有研究表明，文本能够提供全局或领域层面的信息线索——这些线索仅从晶体结构中难以稳定提取，包括基于既有科学认知积累的对称性相关信息。若多模态融合能生成更优或更稳定的性质预测结果，则候选物排序与优先级确定将更具可靠性；这种多模态方法虽不直接生成结构信息，但仍能显著提升逆向设计性能。^[27, 41–42]MultiMat同样从包含结构/组成信息与多种计算性质数据的大规模语料库中学习可迁移的联合表征，不仅将材料属性嵌入共享潜在空间，还将多种性质参数共同纳入同一潜在空间。这使得设计目标能够以剖面图而非单一标量值的形式呈现，从而支持基于已知高性能示例的相似性发现。

多模态检索：多模态学习的核心功能之一是跨模态检索。通过将异构证据映射到共享的嵌入空间，模型可利用文本描述、部分测量数据或参考结构作为查询条件，检索与其所学习的化学及结构相似性表征相近的相关材料。CLaSP[60]及相关对比方法（如 CLICS[61]）将结构表征与科学文本对齐，既提升了结构嵌入的鲁棒性和语义组织性，又实现了文本到结构的检索。这对逆向设计尤为重要，因为设计意图通常首先以定性的科学语言而非完全明确的数值目标向量形式表达[31]。

文本条件化提案中的多模态方法：Weston 等人 [63]报道的磁热力学工作流程展示了多模态技术的实际应用：将文献文本挖掘为结构化的训练数据，并将其与预测、候选结构生成及基于密度泛函理论（DFT）的验证相结合。文本不再被视为单纯的辅助背景信息，而是成为可直接应用于提案-评估-验证循环的设计资源[29–30]。Chemeleon[22]进一步拓展了这一方向，通过整合语言描述与晶体结构表征，并使晶体结构生成过程受文本提示引导。该模型无要求所有目标条件均以固定数值标签表示，而是允许用户通过自然语言指定设计方向，进而生成符合该提示要求的候选晶体结构。

集成逆向设计系统的多模态方法：超越简单的数据检索或性能预测，多模态学习能够将结构对齐直接整合到建模机制中。MatMCL[26]将工艺参数、微观结构图像（如扫描电镜图像）及实测性能数据置于共享嵌入空间中，使工艺-结构-性能链在统一表征框架内协同运作。该方法支持跨模态任务，例如从工艺条件下检索相似形态特征，或根据合成变量生成合理的微观结构——这一能力在实验验证型问题中尤为重要，因为工艺历史与最终功能响应密不可分[23]。MEID-Net[28]通过结合等变结构编码、结构与目标信息的多模态对齐、基于目标驱动的生成以及下游验证，将多模态特性构建为集成逆向设计系统。该方法的关键在于将共享表征转化为可操作的设计空间，在此空间中目标函数、结构参数与优化目标可实现关联、协同探索与联合优化。因此，这表明了集成化工作流程的重要性：在该流程中，多模态理解、候选方案生成以及基于验证的决策均被视为同一逆向设计循环中的相互关联环节[79]。

4.3 局限性与亟待解决的问题

该领域仍处于早期发展阶段，现有的大多数系统都专注于特定模态。此外，所有此类功能模块普遍存在若干共同局限：*模态不完整*是实际应用中的常态：许多有用的信号要么成本高昂，要么分布稀疏，这要求模型即使在证据不完整的情况下也能正常运行；*基础性不足*始终是个持续存在的挑战——文本与结构之间的语义对齐并不能保证生成结果在物理上有效或能量上稳定；最后，*数据集不匹配*会在基于精选计算数据库训练的模型应用于以噪声、缺失数据和过程变异性为主导的实验场景时引发分布偏移。为解决这些问题，对多模态逆向设计系统的稳健评估应重点检验以下方面：当模态缺失时性能是否得以保持、跨模态检索在分布偏移下是否依然可靠、以及多模态条件化是否能提升下游任务的成功率。第6节所述的分阶段评估框架为实现这

些验证提供了有效途径。

5 逆向设计与采样优化

在第3节至第4节中，我们已明确晶体生成器可作为可扩展的方案生成引擎，且多模态学习有助于构建通用化学表征空间；接下来我们将探讨逆向设计这一实际操作难题：当目标相互冲突、约束条件复杂、不确定性难以避免且高保真验证成本高昂时，如何实现可靠的搜索？

逆向设计并非一个直接输出最终结果的单一整体模型，而更应被理解作为一种具备不确定性感知能力的流程体系，它整合了以下四个环节：(a) 提案生成、(b) 约束条件处理、(c) 基于替代指标的评估以及(d) 选择性高保真验证，并将反馈机制与提案策略相衔接。表4总结了主要逆向设计范式及其在实际约束条件和验证预算下的局限性。

表 4.无机晶体材料的主要逆向设计范式：提案策略
constraint handling, and key limitations.

范例	优化策略	约束处理	钥匙限制
状态条件扩散 ^[15, 20]	针对属性目标进行条件	CFG；对称性与化学条	替代偏倚；需进行DFT筛选
文本引导设计 ^[22, 30]	采样；根据自然语言描述生成数据	件；对比性文本-晶体排列； 文本条件扩散	文本中的结构基础薄弱
基于流的设计 ^[21]	精确似然抽样或潜在在变量操控	条件网络；基于梯度的潜在编辑	硬约束在流程外部处理
潜在空间优化 ^[16, 23, 44]	基于梯度的连续潜在空间导航	可微性质头；有效性正则化项	在严格限制下折叠
强化学习 ^[58]	政策旨在最大化稳定性和财产回报	奖励塑造；动作空间约束	奖励黑客攻击；若无替代者实施则成本高昂
贝叶斯定理的优化 ^[9, 77-78]	基于概率替代变量的序列查询	不确定性感知获取；约束性惩罚	正在经历种种困难.....高维空间
主动学习循环 ^[12, 48]	迭代生成-筛选-标注-微调循环	多样性筛选条件；新颖性阈值	多样性崩溃；选择偏倚
LLM引导搜索 ^[49]	采用重排序或树搜索的大规模池生成	能量与属性预测因子；语法过滤	依赖预测因子；需要物理方面的确认

图3展示了包括潜在优化、引导扩散、贝叶斯优化（BO）、强化学习（RL）及主动学习在内的多种框架如何在预算约束条件下融入该循环结构。

5.1 为逆向设计选择搜索策略

选择逆向设计搜索策略的核心在于使搜索方法与设计问题的实际结构相匹配。实际上，合适的方法取决于梯度数据的可获得性、替代指标的可靠性、对结构多样性的要求，以及每个设计周期内可用于高质量验证的计算资源预算。




图3. 反向设计优化的算法选择指南。 每个实心圆代表一个相对于两个轴定位的优化引擎。x轴表示搜索行为，范围从局部细化（左）到全局探索（右）；y轴代表高保真验证吞吐量，即每次迭代可支持的密度泛函理论（DFT）或实验评估次数；对于引导扩散等生成方法，该轴反映下游筛选能力而非生成循环内的评估次数。缩写说明：GD——梯度下降潜在优化（如Adam）；pSGLD——预条件随机梯度朗之万动力学；CFG——应用于引导扩散生成器的无分类器引导；CMA-ES——协方差矩阵自适应进化策略；RL/GRPO——强化学习策略优化（如群组相对策略优化）。

权衡关系总结于图3中，该图可作为状态空间映射图。横轴反映局部细化与全局广泛探索之间的平衡程度，纵轴则表示每次迭代允许进行的高保真验证水平。

当存在连续的潜在表示和可微分的替代函数时，潜在梯度下降法通常是进行局部优化最高效的选择[64–65]。虽然该方法能快速逼近目标值，但极易受到替代函数误差和表示偏差的影响。相比之下，协方差矩阵自适应进化策略（CMA-ES）更适用于具有复杂性或难以微分的目标函数，因为它采用黑箱式种群搜索机制，并能更自然地保持多样性[66]。朗之万型更新算法则处于中间状态：随机梯度朗之万动力学（SGLD）及其预条件版本pSGLD将梯度信息与可控随机性相结合，既能实现精确优化，又能对有潜力区域进行不确定性感知下的探索[67–68]。

引导扩散方法位于规则图谱中全局探索性更强的一端。无分类器引导（CFG）提供了一种实用机制，能够在保持随机采样多样性的同时，将生成过程导向所需条件[69]。近期材料模型研究进一步表明，基于扩散的生成器能够大规模制备稳定且符合特定性能要求的无机晶体

[20]。在逆向设计领域，这使得扩散方法成为理想的高通量提案引擎：它能生成庞大的候选结构库，但这些候选结构仍需经过筛选、去重及下游验证。

当逆向设计被嵌入到顺序工作流程中时，策略优化方法就显得尤为重要。此时，挑战点从单纯的候选方案生成转变为需要决定接下来应进行哪项实验或模拟、按何种顺序执行以及在何种资源约束条件下实施。近端策略优化（PPO）强化学习系列方法为这类顺序决策问题提供了标准框架[70]；近期材料科学研究已开始将强化学习直接应用于同时满足性能与合成目标的无机材料逆向设计[58, 71]。尽管如此，贝叶斯优化和主动学习仍是材料发现领域最成熟的筛选与协调框架[8, 72]。诸如caméo和A-Lab等闭环平台充分说明了这一点：在实际工作流程中，优化器的价值不仅取决于提案质量，更取决于其在实验约束条件下将提案高效转化为可验证结果的能力[72–75]。

5.2 管道设计蓝图：提案、筛选、验证与更新

逆向设计工作流程可表述为一个具有约束条件、预算限制且多目标的搜索问题。设 $x \in X$ 表示候选材料，其中 X 为允许成分与结构组成的设计空间；令 $\mathbf{f}(x) = (f_1(x), \dots, f_K(x))$ 表示目标性能或目标函数向量；并设 $C \subseteq X$ 表示由物理、化学、几何或加工约束定义的可行子集。其目标是在有限的高保真评估预算 B 下，识别出具有高实用性的可行候选材料：

$$\max_{x \in C} U(\mathbf{f}(x)), \text{ 使得成本}(E(x)) \leq B. \quad (12)$$

此处， X 表示完整的候选空间， C 表示可行区域， $\mathbf{f}(x)$ 是目标向量， $U(\mathbf{f}(x))$ 是将多个目标映射为排序标准的标量效用函数， $E(x)$ 表示昂贵且高保真的评估方法（如密度泛函理论 DFT 或实验），而 B 为总验证预算。

一个实用的逆向设计流程通常包括以下阶段：

1. **候选方案**：候选方案首先通过一种提案机制（例如条件生成模型）生成。

$$x \sim q_\theta(x | c). \quad (13)$$

此处， $q_\theta(x | c)$ 表示具有参数 θ 的参数化提议分布，而 c 代表设计意图（如目标特性、组成限制、对称性要求或基于文本的约束条件）。该阶段决定了设计空间中哪些区域会被探索，从而显著影响设计的多样性和可实现的发现结果。

2. **低成本可行性筛选**：随后对候选方案施加低成本的严格约束条件，以在替代评估前剔除明显无效的结构；

$$\text{IC快速}(x) \in \{0,1\}, \text{ 仅当 IC快速}(x) = 1 \text{ 时才保留 } x. \quad (14)$$

此处， $\text{IC fast}(x)$ 为一个指示函数， C_{fast} 表示满足快速可行性检验条件的候选集合。这些检验条件可能包括不存在原子重叠、符合可接受的原子间距离范围、满足密度或体积边界要求、电荷中性、化学计量一致性，以及其他对后续有效评估所必需的基本不变量。

3. **基于代理变量的不确定性评分方法：** 剩余候选方案通过针对目标函数和软约束条件建立的快速预测模型进行评估。对于具有 K 个目标函数的多目标问题，该代理变量为每个目标函数 $k=1, \dots, K$ 同时提供预测均值和不确定性估计值：

$$(\mu_k(x), \sigma_k(x)), \quad k = 1, \dots, K. \quad (15)$$

其中， $\mu_k(x)$ 表示第 k 个目标函数的预测值， $\sigma_k(x)$ 则表示相应的预测不确定性。随后可采用一种考虑不确定性的标量化效用函数对候选方案进行排序，该函数能平衡预测性能、基于不确定性的探索行为以及约束条件违反情况：

$$\hat{U}(x) = \sum_{k=1}^K w_k [\mu_k(x) + \beta \sigma_k(x)] - \lambda \Phi(x). \quad (16)$$

此处， $\hat{U}(x)$ 为替代效用函数， w_k 是分配给第 k 个目标函数的权重系数， β 控制预测不确定性如何纳入决策规则； $\Phi(x)$ 是针对预测约束违反情况的惩罚项，而 λ 则控制该惩罚项的强度。正值 β 会生成以探索为导向的上置信界形式，倾向于选择既具有潜力又存在不确定性的候选方案；而负值 β 则会产生更为保守的风险规避型效用函数。

更一般地， $U(x)$ 可以被替换为一个获取函数 $a(x)$ （例如期望改进值或约束期望改进值），以平衡资源开发、不确定性驱动的探索以及可行性。

4. **选择性高保真验证：** 仅少量候选方案会被推进至成本高昂的评估阶段：

$$S \subseteq \{x \in X: \text{IC fast}(x) = 1\}, \quad |S| \text{ 由可用预算决定}. \quad (17)$$

此处， S 表示用于高保真验证的样本批次， $|S|$ 为其规模。在此阶段，需采用严格方法对候选模型进行评估，以确定客观真实值并进行可行性分析。这一步骤对于减轻代理模型误差的影响以及确保预测不确定性得到正确校准至关重要。

5. **基于反馈的模型与数据集更新：** 验证后的结果被纳入累积数据集中：

$$D \leftarrow D \cup \{(x, \mathbf{f}(x), \text{可行性}, \text{元数据}): x \in S\}. \quad (18)$$

其中， D 表示当前数据集， $\mathbf{f}(x)$ 为经过验证的目标向量；其余项则记录可行性结果及辅助元数据（如松弛状态、合成条件、来源或不确定性估计值）。随后利用扩展后的数据集对提议模型和替代预测器进行更新，例如通过重新训练、微调、重新校准或策略调整。

为减少向近乎重复候选结构的趋同现象，逆向设计流程通常会明确监测新颖性或多样性指标，例如通过与先前观察到的结构之间的最小距离来评估。

$$\text{新颖性}(x) = \min_{x' \in D} d(x, x'). \quad (19)$$

此处， $d(x, x')$ 表示候选方案之间的差异度量指标，由此可推导出新颖性 (x) 以量化候选方案 x 相对于现有数据集的独特性。该指标的连续化表达形式——采用基于组合的描述符（如Magpie特征）或基于结构的描述符（如平均最小距离）——相较于二元阈值能更

细致地评估独特性和新颖性，从而构成了用于生成模型基准测试的连续稳定-独特-新颖（SUN）指标体系[87]。基于局部新颖性距离构建的材料空间地理式导航图，还能实现实时针对大型结构数据库的重复检测，即使候选方案通过晶胞变换或元素替换被伪装时亦然[88]。基于此类度量的多样性感知选择有助于维持设计空间的覆盖范围，并提升闭环发现的长期效率。

5.3 隐含空间采样优化：基于有效性控制的快速转向算法

当生成器提供连续的潜在表示 z 时，一种自然策略是优化 z 以提升预测效用，同时使其向合理性方向正则化。形式上，可通过求解相关数学问题来实现。

$$z^* \in \arg \max U(g_\theta(z)) \quad \text{s.t.} \quad z \in \mathcal{Z}_{\text{valid}} \quad (20)$$

其中 g_θ 为解码器， $U(\cdot)$ 为效用函数， $\mathcal{Z}_{\text{valid}}$ 为潜在空间中的可行性正则化区域。实际应用中，通常采用基于梯度的方法（如Adam算法、Langevin动力学）在可行区域 $\mathcal{Z}_{\text{valid}}$ 内迭代更新潜在变量 z ，并利用快速属性头或代理模型对每一步解码得到的晶体结构进行评估。

潜在空间优化方法的主要优势在于其快速性以及多目标标量化方法的兼容性。由于梯度流经解码器，该方法能够高效地向目标区域移动；同时加权求和运算可同时处理多个目标函数。其主要缺陷之一是代理函数的滥用：若属性头部不完善，梯度上升法可能会将 z 引入预测模型过于自信但解码结构在物理上不可行或不稳定的区域。应对措施包括：（i）在解码后施加严格的可行性约束；（ii）引入考虑不确定性的效用项以惩罚过度自信的外推行为；（iii）使用通过高保真松弛或稳定性检验的候选参数重新初始化或锚定潜在搜索；（iv）采用多样性考量机制以避免陷入狭窄的结构族中[16, 23, 44]。

5.4 引导式扩散采样：在保持多样性的同时实现可控性

扩散模型通过从噪声出发并迭代去噪，生成候选结构样本。在晶体生成过程中，该模型学习一个逆向过程：将含噪声的表示 x_t 映射为更清晰的候选结构 x_{t-1} ，最终得到晶体提案 x_0 。简言之，这一过程可表述为：

$$x_T \sim N(0, I), \quad x_{t-1} \sim p_\theta(x_{t-1} | x_t, c) \quad (21)$$

其中 x_T 为纯高斯噪声， $p_\theta(x_{t-1} | x_t, c)$ 表示学习得到的逆向转移函数，而 c 则表示可选条件信息（如构图、对称性、文本提示或目标属性信息）。扩散模型在逆向设计中的主要优势在于：可在去噪过程中引入可控性，而非仅依赖事后滤波。

核心思想在于采样时间引导：与仅从已学习的数据先验中抽取样本不同，逆向轨迹会优先选择更符合目标条件的候选路径。这种引导机制可源自显式条件网络、属性预测适配器或无分类器引导方法。以无分类器引导为例，其条件去噪器与非条件去噪器被整合为统一框架。

$$\hat{\epsilon}_\theta(x_t, c) = \epsilon_\theta(x_t, \emptyset) + w \left[\epsilon_\theta(x_t, c) - \epsilon_\theta(x_t, \emptyset) \right] \quad (22)$$

其中 $\epsilon^{\theta}(xt, c)$ 表示引导噪声预测结果， $\epsilon^{\theta}(xt, c)$ 与 $\epsilon^{\theta}(xt, g)$ 分别代表条件性与非条件性去噪器输出，而 $w \geq 0$ 表示引导强度。当 $w=0$ 时采样遵循非条件模型；随着 w 增大，样本会被更强烈地导向所要求的条件状态。

引导扩散方法在逆向设计中具有显著优势，因为它能够引导生成过程朝目标方向发展，而无需将所有样本强制集中到设计空间的同一小区域内。与直接潜在优化（容易快速使搜索过度集中在少数高分候选结构上）不同，扩散方法在整个去噪过程中始终将采样范围保持在模型学习到的合理晶体分布范围内。这既能有效保持多样性，又能满足特定设计要求。不过其效果取决于引导强度：当引导力度过弱时，采样结果仍会偏向通用先验分布，目标结构难以被准确捕获；当引导参数校准得当时，生成的候选结构既合理又相关；若引导过强，则样本间相似度过高、伪影增加，且模型可能利用引导预测器中的误差，产生内部评分良好但外部验证失败的候选结构[20, 23–25, 37, 57, 76]。因此，引导扩散更应被视为基于学习先验分布的有偏采样方法，而非无约束优化过程。其价值在于能够在合理性、多样性和目标导向生成之间提供可调控的平衡点，这在下流验证成本高昂且候选批次需同时具备高富集度与高可靠性时尤为实用。

5.5 贝叶斯优化：昂贵验证条件下的样本效率

贝叶斯优化（BO）非常适用于那些每次高精度评估成本都很高的逆向设计问题，例如当验证过程需要进行密度泛函理论弛豫、相稳定性计算、实验合成与表征时。与无差别地评估大量候选方案不同，BO会构建目标函数的代理模型，并利用获取函数来决定下一步应测试哪个候选方案。若将候选方案 x 的真实目标函数表示为 $f(x)$ ，则BO会用顺序决策过程替代对 f 的直接全局优化。

$$f(x) \approx \hat{f}(x), \quad x_{t+1} = \arg \max_{x \in \mathcal{X}} \alpha_t(x) \quad (23)$$

其中 $\hat{f}(x)$ 为替代模型， $\alpha_t(x)$ 为第 t 次迭代时的获取函数。其核心思想是在有限的验证预算范围内，将资源集中于最具价值的对象：即那些表现良好、信息量丰富或兼具这两者的候选模型[8–11, 13–14, 77]。

在BO方法中，替代指标同时提供期望值和不确定性估计值。

$$\hat{f}(x) = (\mu(x), \sigma(x)) \quad (24)$$

其中 $\mu(x)$ 用于估计模型性能，而 $\sigma(x)$ 则反映模型在搜索空间中该位置的不确定性程度。随后可基于这两个参数构建获取函数。例如，上置信界（UCB）即为典型代表。

$$\alpha_{\text{UCB}}(x) = \mu(x) + \kappa \sigma(x) \quad (25)$$

其中 $\kappa > 0$ 为控制探索与利用权衡关系的参数。该数据采集方式优先选择那些预测表现良好和/或位于模型不确定性区域的候选对象。预期改进值（EI）为：

$$\alpha_{\text{EI}}(x) = \mathbb{E}[\max(f(x) - f^+, 0)] \quad (26)$$

其中 $f(x)$ 表示候选点 x 处的目标值，而 f^+ 代表当前观测到的最佳值。该准则优先选择那些有望改进迄今获得最佳观测结果的候选点。在这两种情况下，选择下一次实验不仅是因为其可能获得高分，更因为其能有效提升搜索效率。

这一点在逆向设计中尤为重要，因为有潜力的候选方案还必须保持可行性。若可行性由约束条件 $g(x) \leq 0$ 描述，则可对采集方案进行调整。

$$\alpha_{\text{共集}}(x) = \alpha(x) \times P(g(x) \leq 0) \quad (27)$$

其中 $\alpha(x)$ 为基团获取函数（例如 UCB 或EI）， $g(x) \leq 0$ 表示可行性约束条件，而 $P(g(x) \leq 0)$ 则是约束满足的预测概率。这可避免搜索过程反复选择那些在替代目标函数下看似理想但实际可能缺乏结构合理性、化学合理性或实验可操作性的候选方案。

然而，BO方法在晶体设计中的成功程度在很大程度上取决于数据表示方式。材料的搜索空间通常并非简单的连续域，而是具有高维度、结构化且类型混合的特点——既包含成分或空间群等离散变量，也包含晶格参数或潜坐标等连续变量。传统的BO方法在此类空间中难以有效运作。因此，当搜索过程在结构紧凑且具备化学意义的嵌入空间中进行时，BO方法通常能发挥最佳效果。

$$z = \phi(x), \text{ 其中 } z \in \mathcal{Z}_d, \text{ 且 } d \ll \dim(x) \quad (28)$$

其中 $\phi: X \rightarrow \mathcal{Z}_d$ 为学习得到的嵌入函数， z 表示紧凑的低维表示，且 $d \ll \dim(x)$ 表明该嵌入维度远低于原始晶体表示。BO算法则作用于 z ，并将选定点解码或映射回材料候选库中。简而言之，当搜索空间已被组织成邻近点对应化学意义显著变化的形式时，BO算法效果最佳。

另一个问题是材料数据往往存在噪声、分布稀疏且具有方法依赖性。实验测量结果会因条件不同而有所差异，计算得出的物理性质取决于所采用理论框架，且许多研究对象仅在少数材料中得到观测。因此，需要建立一个简化的观测模型。

$$y = f(x) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma_n^2) \quad (29)$$

其中 y 表示观测值（含噪声的测量结果）， $f(x)$ 为真实目标值， ε 为方差为 σ_n^2 的高斯噪声。虽然该模型可作为起点，但材料发现过程中的实际不确定性往往具有异方差性、偏倚性或源依赖性。在此背景下，不确定性并非单纯的统计便利因素，而是物理问题本身的一部分。因此可靠的生物信息学优化（BO）依赖于经过精确校准的替代指标以及对噪声的合理处理——因为不准确的不确定性估计会直接导致错误的实验设计决策[9–10, 77]。

一个与之密切相关的扩展方法是目标导向的基准优化（BO），其中包括t-EGO等方法。其核心目标并非单纯最大化标量评分，而是识别最有可能符合特定属性范围的候选方案。若设计目标为目标区域 T ，则该优化过程可表示为：

$$x_{t+1} = \arg \max_{x \in \mathcal{X}} P(f(x) \in T) \quad (30)$$

其中 T 表示目标属性窗口， $P(f(x) \in T)$ 表示候选材料 x 落入目标区域的预测概率， $\mathcal{X}$ 为设计空间。该公式可选择性地结合可行性项。这通常更符合实际逆向设计的要求——其目标并非一定是某个属性的绝对最大值，而是寻找一种既能满足特定性能标准又具备可行性的材料[9, 78–79]。

5.6 强化学习：基于显式约束条件的策略搜索

强化学习（RL）被公认为最适合解决序列决策问题。与直接一步预测最终材料候选方案不同，强化学习通过在设计环境中执行一系列操作来学习策略，从而最大化累积奖励。在材料选择场

景中，这些操作可能包括添加或替换原子、调整成分组成、改变结构模体，或探索潜在的设计空间。简而言之，该策略旨在实现奖励值的最大化。

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t r_t \right] \quad (31)$$

其中 π 表示策略， r_t 为第 t 步的奖励值， $\gamma \in (0,1]$ 为折扣因子， T 为训练轮次长度。强化学习（RL）的核心优势在于其能够自然地编码序列化的设计决策，并能引导探索行为聚焦于候选空间中罕见但潜在高价值的区域[58]。

这种情况尤其适用于逆向设计并非一次性预测问题，而是一个多步骤构建过程的情形。例如，我们可能希望逐步构建结构、通过连续修改来优化候选方案，或在权衡即时改进与长期可行性的不同选项中做出选择。在此类场景下，强化学习为设计提供了自然的表述方式：状态描述当前候选方案，动作对其进行修改，而奖励则衡量该修改是否使搜索过程朝预期目标推进。

一个简单的约束强化学习模型可表示为：

$$\max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t r_t \right] \quad \text{其中。对所有 } t \text{ 都有 } \mathbf{x}_t \in \mathbf{C} \quad (32)$$

其中 $\mathbf{C}$ 表示可行性约束条件，例如组成规则、结构有效性、电荷平衡、对称性要求或化学合理性。在实际应用中，奖励函数可综合多个指标。

$$r(x) = \sum_{k=1}^K w_k f_k(x) - \lambda \Phi(x) \quad (33)$$

其中 $f_k(x)$ 为期望特性， w_k 为其权重系数， $\lambda > 0$ 用于控制不可行性惩罚强度，而 $\Phi(x)$ 则用于惩罚不可行性或不良特性。

主要困难在于，奖励函数很少直接对应真正的科学目标。更常见的情况是，它仅基于快速预测模型、代理模型或简化启发式方法构建出可计算的近似值。因此，核心缺陷并不神秘：智能策略可能会学会最大化奖励信号，却无法实现真实的设计目标。这通常被称为奖励黑客攻击。在当前语境下，“代理利用”或“代理博弈”等术语本质上指代同一问题——即优化替代目标而非真实的物理目标。

这一问题在逆向设计中尤为突出，因为许多奖励机制都是基于近似的属性预测指标，而非直接依赖物理层面的验证结果。例如，强化学习智能体可能会发现某些候选方案能获得极高的预测奖励，原因在于这些方案利用了代理模型存在过度自信或预测不准确的区域。这类方案在策略层面看似最优，但一旦经过参数调优、稳定性验证或实验测试后往往表现不佳。因此，潜在风险不仅在于泛化能力不足，更在于会系统性地偏离具有科学意义的最优解。

因此，以探索为导向的强化学习流程必须严格控制动作空间和奖励定义。首要保障措施是设置约束性动作空间，防止策略提出明显无效的动作；其次需采用稳健的奖励设计，将硬性约束与软性目标明确分离，而非完全依赖奖励塑造；第三要纳入定期的物理层面验证，通过高精度计算或实验反复检验策略效果，避免其无限优化替代奖励函数。

从实际应用角度来看，强化学习（RL）只有在满足三个条件时才能发挥最大价值。首先，设

计过程必须真正遵循顺序性原则，使得策略方法相较于一次性生成法更具优势；其次，动作空间需要被充分限定，从而通过结构设计排除大量无效候选方案；第三，奖励信号需频繁地根据高保真度评估结果进行校准，以防止模型偏离代理驱动型解决方案。在此条件下，强化学习可成为逆向设计中极具效力的搜索策略；反之则可能轻易演变为一种代价高昂的错误目标优化手段[58]。

5.7 基于生成式循环的主动学习：负责任地完成整个学习闭环

主动学习（AL）通过反复循环执行候选方案生成、筛选、选择性验证及模型更新四个步骤，将反馈机制具体化应用于逆向设计中。每次迭代均依次经历四个阶段：生成新的候选方案；对候选集进行筛选与多样化处理；以高保真度验证选定方案；并利用最终结果更新模型。从形式上讲，累积的数据集会持续更新。

$$\mathcal{D}_{t+1} = \mathcal{D}_t \cup \{(x, y(x)) : x \in \mathcal{S}_t\} \quad (34)$$

其中 $\mathcal{D}_t$ 表示第 t 次迭代中的标注数据集， $\mathcal{S}_t$ 为用于高成本验证的选定批次， $y(x)$ 则表示新获得的高保真结果（例如松弛能量、稳定性或实验测量值）。这是将逆向设计转化为累积发现过程最现实的方法之一，因为高成本标签会被分配到那些预期能有效降低不确定性、改进提议模型或最有效地明确决策边界的位置[8, 12–14, 48]。

主动学习的吸引力由此可见一斑：与将验证预算均匀分配给所有候选方案不同，该循环机制会利用现有模型来判断哪些额外证据最具价值。从原理上讲，这能显著加速知识发现过程——尤其是在高保真标注数据稀缺且成本高昂的情况下。然而在实际应用中，逆向设计中的主动学习并不总是有益的。一旦模型开始自主选择未来的训练数据，其决策过程就可能逐渐产生偏见：这种偏见虽能提升短期准确率，却会削弱长期的知识发现价值。其中两种失败模式尤为值得关注。

选择偏差：随着循环迭代的推进，标注数据集不再反映更广泛的候选空间；相反，其分布逐渐集中在当前模型或获取规则偏好的区域附近。换言之，训练分布会逐步向策略本身已认定为有潜力的选项方向偏移。若策略存在校准偏差，这将加剧早期错误并形成自我确认的搜索轨迹。严格来说，若原始候选分布为 $p(x)$ ，而主动学习器根据获取规则 $\alpha_t(x)$ 进行选择，则标注数据实际上是从一个带有偏见的分布中抽取的。

$$q_t(x) \propto p(x) \alpha_t(x) \quad (35)$$

其中 $p(x)$ 表示设计空间上的原始候选分布， $\alpha_t(x)$ 为第 t 次迭代时的采样规则，而 $q_t(x)$ 则是主动学习器产生的有偏采样分布。这意味着模型的训练越来越侧重于自身的偏好而非更广泛的设计空间。当策略校准良好时，这种反馈机制具有积极作用；但若存在代理误差或盲区，则可能产生负面影响——因为它可能会掩盖那些最初从未被采样的关键区域[8, 12]。

多样性崩溃：第二个风险在于反复微调会将生成器逐渐锁定在候选空间中的某个狭小模式。一旦某些区域开始显现潜力，优化循环就会不断回到这些候选方案的近似副本，从而逐步削弱结构多样性、成分新颖性及探索性覆盖范围。即使测量命中率有所提升，这种情况仍可能发生——因为模型实际上是在学习利用狭窄的局部区域，而非拓展发现边界。在生成式逆向设计中，这一问题尤为严重，因为提案模型本身会根据验证结果进行更新。若缺乏明确的新颖性或

覆盖率标准，优化循环可能会收敛于一个受限的候选方案集合：这些方案虽易于模型优化，却缺乏科学价值。

这两个问题密切相关：选择偏差会集中数据分布，而多样性崩溃则会缩小候选方案的分布范围。两者共同作用，会导致对进展的误判。例如，虽然满足当前目标条件的候选方案比例有所上升，看似有所改善，但搜索过程可能同时变得代表性降低、创新性减弱，并且更难发现真正新颖的材料。因此，仅报告命中率提升是不够的。

对主动学习逆向设计方法的更全面评估不仅应报告循环机制识别目标匹配候选项的频率，还应阐明其性能实现的具体机制。至少应包含以下内容：(i)在统一验证标准下的通过率；(ii)保留候选项的多样性或唯一性；(iii)相对于训练集或已知参考集的新颖性。一种简单的新颖性度量指标可表述为：

$$\text{新颖性}(x) = \min_{x' \in \mathcal{D}_{\text{ref}}} d(x, x') \quad (36)$$

其中 $d(x, x')$ 表示结构距离或表征空间距离， $\mathcal{D}_{\text{ref}}$ 为参考集。同样地，多样性可通过成对距离或覆盖率指标来汇总选定批次 S_t 中的数据，而非仅报告成功候选者的数量。

从实际应用角度来看，逆向设计中的负责任主动学习所需的方法远不止迭代性重训练。它需要具备能够平衡实用性与覆盖范围的获取策略、不会过快失效的提案机制，以及能区分真正创新发现与对狭窄区域重复利用的评估方案。这通常意味着在获取规则中引入多样性考量的批量选择机制、新颖性阈值或明确的探索条件，从而确保即使在利用现有成果的同时，循环过程仍能持续探索尚未充分开发的领域。

更广泛的启示在于：主动学习并非仅仅是一种提高标注点数量的效率手段。在逆向设计中，它实际上是一个决策层，决定了模型后续能够学习的内容。若运用得当，它能显著提升数据利用效率并增强研究目标的针对性；反之若使用不当，则可能放大现有模型的盲区，并围绕一个狭隘且可能产生误导的成功定义形成闭环[8, 12–14, 48]。

5.8 采样优化过程中的挑战

在各类优化策略中，主要风险在于：在不完美的可行性模型下对代理变量（如替代变量、引导预测因子、奖励函数）进行优化，这可能导致搜索过程进入对优化器而言看似理想但实际不可实现的区域。在潜在空间优化中，这表现为 z 中的替代变量操纵行为与过度自信漂移现象，进而引发有效性先验设定、解码后的硬门机制、不确定性惩罚项以及周期性高保真重置等问题。在引导扩散方法中，核心挑战在于引导参数的校准问题：弱引导会产生通用样本，而强引导则可能抑制多样性并放大预测偏差，因此需要在固定匹配标准下进行精细调参并实施明确的多样性和新颖性监控。在贝叶斯优化领域，瓶颈在于高维混合离散/连续空间中的表示建模与扩展性——若缺乏强大的嵌入表示或稳健/含噪声的贝叶斯优化变体支持，不确定性参数的校准效果可能不佳，且数据采集优化过程易出现不稳定现象。在强化学习中，当奖励机制依赖替代指标时，奖励黑客攻击和参数设定错误十分常见；因此必须采用基于构建的可行性分析、约束动作空间以及物理层面的验证机制。在主动学习循环中，选择偏差与多样性下降可能随训练轮次不断累积；因此学习过程需明确平衡利用价值、覆盖范围与新颖性；评估指标应包含通过率及多样性和覆盖率等指标，而不仅限于命中率。




图4. 包含算法暴露区域的晶体逆向设计系统的失效模式图。每个带标注的框均表示一个代表性失效模式，其位置依据两个定性轴确定。x轴表示**检测难度**，从左侧的低难度/易检故障（如原子整体重叠）到右侧的高难度/难检故障（如隐藏分布偏移）递增；y轴表示**修复成本**，从底部的低成本（如应用简单后过滤或局部结构修复）到顶部的高成本（如重新训练、重新设计目标函数或修改完整发现流程）递增。标记形状与颜色共同编码各失效的主要来源：蓝色实心圆（●）表示生成器源故障（模型设计或表示问题）；橙色实心方块（■）表示优化器层面的故障（搜索或引导路径异常）；红色实心三角形（▲）则表示评估流程层面的故障（基准测试或数据问题）。图例及图表中的半透明椭圆标记代表算法家族的近似暴露区域，表明特定逆向设计方法类别特别易出现以下故障类型：**GD**——梯度下降潜在优化法；**SGLD**——随机梯度朗之万动力学；**DIFF**——引导扩散生成法；**EVO**——进化优化算法（如CMA-ES）；**RL**——强化学习策略优化；**ALL**——跨算法家族共有的故障模式。右上象限代表关键故障状态：在此状态下，高检测难度与极高的修正成本相结合，对自动化发现结论的可信度构成最大威胁。

6 从故障模式到可靠的部署

大规模生成晶体候选物的能力已不再是逆向设计中的主要瓶颈。更持久的挑战在于评估环节：基准数据必须在强优化压力下保持可靠性，并在不同研究中具有可比性[37–39]；同时应将其视为一项系统性的工作，用于识别、揭示并控制失效模式。图4通过根据常见缺陷的易检测性及修正成本对它们进行分类，总结了这一观点。

这凸显了一个关键点：并非所有故障都会产生相同的科学影响。部分故障可通过低成本过滤器早期识别，而另一些则可能直至后续验证或实际应用阶段才显现，甚至会直接否定该发现的有效性。因此，诸如梯度下降（GD）、随机梯度朗之万动力学（SGLD）、引导扩散生成（DI-

FF)、进化优化(EVO)、强化学习策略优化(RL)以及所有算法家族共有的故障模式(ALL)等标签应被视为参考性而非绝对标准。某些异常现象在特定优化场景下更为常见,但最具破坏性的故障往往出现在基准测试层面且与具体方法无关。

最低层级的问题对应*可行性与有效性缺陷*。这类问题通常最容易被发现,且若能及早处理,修正成本也最低。在晶体生成流程中,常见问题包括原子重叠、不合理的原子间距、化学成分不合理以及对称性不一致[16, 37]。此类检查现已成为标准流程,但文献同样明确指出:通过这些检查并不意味着体系具备热力学稳定性、可合成性或实际应用价值[37]。因此,这些检查应被视为必要的前提条件,而非直接证明研究成果的有效性。

原子碰撞就是一个典型的例子。当在潜在空间或替代空间中进行优化时,若优化过程到达一个形式上得分较高的区域,而该区域对应的结构又不符合物理规律,则就会产生此类碰撞。由于这类问题通常可通过简单的几何规则识别,因此应立即通过最小距离过滤、单元合理性检查以及(在可行的情况下)低成本预松弛处理来消除[16, 37]。与此密切相关的是电荷违反现象以及更广泛的化学不合理性类型。在无机化合物筛选中,基于《半导体材料类比与化学理论》(SMACT)的氧化态和电负性规则仍是有效的初步筛选工具,因为它们能在昂贵的验证阶段之前高效排除大量不可能的候选结构[51]。对称性破坏是另一种重要的失效类型,尤其对于基于扩散机制的生成器而言。近期研究表明:当对称性是任务的核心要素时,直接将其编码到模型中比事后修正更为可靠[17]。

中间区域存在*优化过程中的病态现象*。这些现象更为隐蔽,因为优化器表现看似良好:评分提升、循环收敛,但科学目标可能并未以可靠的方式得到推进。核心问题在于对不完美替代指标的过度优化。Matbench Discovery在稳定性筛选中清晰地展示了这一点:强大的回顾性回归性能并不能自动转化为良好的材料发现决策[80]。在逆向设计中,这实际上是古德哈特定律的一种实际应用形式:一旦某个替代指标成为优化目标,搜索过程就会陷入其盲区,而非识别出具有物理意义的候选材料。

标记为*代理黑客攻击*的要点正体现了这一风险。在基于梯度驱动的工作流程中,搜索过程可能会利用替代误差而非优化底层物理目标函数。最有效的防护措施是分阶段评估:首先进行严格的有效性验证,其次采用基于替代指标的筛选机制,并在整个循环过程中定期进行高保真验证[37, 80]。强化学习环境中的奖励黑客攻击则是该问题更为明显的表现形式。更广泛的人工智能文献早已将此视为优化后代理目标函数的核心失效模式[81–82]。对于逆向设计工作流程而言,这意味着操作奖励应被视为近似值而非真实基准。因此,必须设置独立的物理终点指标、针对简单基线进行审计,并明确控制优化压力。

多样性崩溃是另一种常见的优化问题,尤其在进化搜索或基于种群的搜索中尤为常见。CMA-ES及相关方法之所以强大,在于它们能够应对复杂且不可微的搜索空间;但若未能有效维持多样性,这些方法也可能陷入狭窄的搜索区域[66]。在逆向设计中,这种现象会通过反复提出近乎相同的候选方案而浪费验证资源。因此,应通过引入新颖性指标、构建多样性档案库、采用重启策略、实施聚类分析或制定针对化学结构和构型的明确覆盖率指标等方式,将多样性因素直接纳入优化目标或筛选阶段。

最高层级代表*证据不足与评估失败*的情况。这类问题最为严重,因为它们往往会使基准测试本身失去有效性,而非仅仅削弱某个优化器的表现。隐性分布偏移失败是指模型在回顾性数据上表现可靠,但一旦候选分布发生变化即性能下降的现象。这一问题不仅是数据集偏移场景

下不确定性感知学习的核心挑战[83]，同样常见于区分回顾性性能与前瞻性效用的材料基准测试中[80]。因此，逆向设计研究应超越随机打乱的数据划分方案，纳入更多与实际部署相关的实验方案，例如时间分隔测试、化学分组划分、前瞻性保留样本或外部验证集等。

数据泄露属于高风险类别之一，因为它能够在不被最终评估指标表所察觉的情况下悄然提升模型性能。目前，数据泄露已被公认为科学领域机器学习中的一个持续性问题，在逆向设计中尤其具有破坏性——它会严重影响整个基准测试结果的可信度[84–85]。典型来源包括不同划分集中的重复或近似重复结构、家族层面的数据重叠、基于完整数据集进行的预处理拟合，以及基于未来数据做出的模型选择决策。一旦发现问题，通常需要重新设计实验方案并重新开展研究。因此，数据划分审计、重复检查、严格的预处理隔离措施以及透明化的报告机制都应被视为基准测试流程的重要组成部分。

校准不当的不确定性是难以直接诊断的最棘手问题之一。即使在标准设置下，神经预测模型的校准效果也往往不佳；而在分布偏移的情况下，校准效果还会进一步下降[83, 86]。这一点至关重要，因为不确定性在逆向设计中具有关键应用价值：它决定了哪些候选方案能进入DFT阶段、接下来应探索哪些区域以及如何分配验证预算。因此，校准不准确不仅会影响结果解读，还会降低决策质量。可靠的评估应当在实际分布偏移条件下检验校准效果，比较不同不确定性方法而非依赖单一启发式方法，并探究不确定性是否能提升后续筛选效果，而不仅仅是报告分布内校准分数[80, 83, 86]。

6.1 通过分阶段通过率账本进行基准测试

逆向设计系统本质上极易受到评估方法缺陷的影响。由于其采用激进的优化策略，这类系统会利用基准测试中的任何漏洞，往往能产生表面优势——但一旦对候选方案施加结构松弛、相稳定性筛选或合成相关约束条件，这些优势便会消失[37]。因此，基准测试不应仅停留在单一最终得分上，而应分阶段展示：哪些候选方案能够通过验证、哪些会失败，以及获得可靠结果需要付出多大努力。一种实用的方法是报告基于最小化评估组合得出的*通过率统计结果*：

- *有效性*。第一个问题在于生成的候选结构在最基本的层面上是否具有物理和化学合理性。这包括不存在原子重叠、原子间距离合理、密度或体积合乎实际，且不明显违反化学合理性原则。
- *唯一性*。下一步是验证存活下来的候选方案是否在明确规定的匹配标准（如声明的StructureMatcher公差或简化公式规则）下确实具有独特性。唯一性不应与新颖性混为一谈：若缺乏唯一性，一个流程仅通过多次重现相同的结构模体就可能显得有效[38]。
- *新颖性与多样性*。在去除重复项后，关键在于剩余候选方案是否超越现有认知范围。因此，新颖性评估应同时参照训练集及相关外部数据库，并明确界定组成结构层面的新颖性定义。基于连续相似性的度量指标（而非二元匹配阈值）能为该评估提供更可靠的基础，因其可量化生成集合内的独特性和新颖程度[87]。在定义结构新颖性时，还应考虑晶体学家族关系——包括通过组-亚组转变或共享母相的有序-无序变体所连接的结构——因为仅凭对已

知晶相的对称性降低再发现结果仍可能满足标准匹配准则[89]。局部新颖性距离度量进一步支持针对大型结构数据库进行快速邻近搜索，实现材料空间的地理式导航及实时新颖性评估[88]。多样性应通过分布或覆盖统计指标（如化学扩散范围、对称性及结构变异）来呈现，而非仅依赖少数选定案例[38, 87–89]。

- **稳定性。**稳定性应在实际测量层面进行报告，并区分以下几种类型：*代理*稳定性（基于替代分数推断得出）、*松弛*稳定性（通过结构优化获得）、*相态*稳定性（根据凸包邻近度或壳层上方能量等量值评估）以及*动态*稳定性（利用机器学习原子间势能进行振动分析判定）。动态稳定性筛选能够检测出在静态能量基筛选中仍存在的候选物中的虚声子模式；自动化工作流程可进一步指导对动态不稳定候选物进行结构优化，使其转化为稳定多晶型[90]。
- **效率。**一个高效的逆向设计工作流程不仅需要能够识别出有潜力的候选方案，更需确保这一过程的成本可控。因此，基准测试应报告实际运行时间、计算成本以及每个可信候选方案所需的高保真验证次数——因为不同方法在验证需求与方案质量方面往往存在显著差异[38]。

6.2 不确定性条件下的选择指标

逆向设计归根结底在于判断哪些候选对象值得投入高昂成本进行后续研究。由于仅有有限数量的生成材料能够推进至DFT验证或实验阶段，不确定性只有在通过减少无效评估、提高固定预算内的命中率来优化筛选决策时才具有实际价值[8]。因此，基准测试应超越性质预测精度的范畴，重点考察方法是否能在现实约束条件下支持合理决策。具体而言，不确定性估计值应在分布偏移、优化压力或指导压力下仍保持其意义；性能指标应以验证预算为变量进行报告（例如按弛豫次数、DFT计算次数或实验次数对应的成功候选数），而不仅限于最佳候选结果。稳定性与可合成性之间的差距也必须明确指出：凸包稳定性并不能保证实际合成可行性——动力学障碍、竞争相态以及狭窄的处理窗口仍可能阻碍目标化合物的实现[29, 31–32, 37]。

图5展示了一个满足这些要求的具体编排架构：每个模块均公开明确的接口契约，而中央调度器在明确的预算约束下协调整个提案至验证流程。

6.3 迈向实验阶段：可合成性与多模态设计接口

随着材料筛选方案在生成大量符合密度泛函理论（DFT）预测的候选材料方面日益高效，核心瓶颈已从*方案提出*转向*实施执行*。当前的实际挑战不仅在于推荐那些在计算机模拟中表现良好的材料，更在于识别出能够在实际实验条件下被合成、加工并评估的候选材料。因此，合成与加工方面的考量不应仅作为非正式的附加考虑因素；必须明确纳入模型输入参数、可行性标准及决策流程之中[29, 31–32, 37, 51]。

这一转变带来了三项近期优先事项。首先，合成与工艺约束应直接融入逆向设计流程中——既作为生成过程中的条件化信号，也作为候选方案筛选阶段的可行性过滤器。其次，文本挖掘获得的合成知识、文献衍生的操作信息以及实验元数据均需整合到多模态表示体系中，




图5. 自动驾驶实验室作为逆向材料设计的协同闭环系统。该架构由五个功能模块组成，由中央调度器协调运作。(i)多模态编码器：将来自多种模态的证据映射至共享表示空间，实现相关先例的跨模态检索；(ii)生成器：基于设计意图和检索到的上下文提出新候选方案；(iii)验证器：在进行耗时的实验验证前，通过快速结构松弛分析和热力学稳定性筛选来过滤候选方案；(iv)机器人实验室：执行自动化合成流程；(v)表征模块：测量材料特性并返回实验观测结果。中央调度器通过分配验证预算、应用终止规则以及确定所有模块间的最优后续操作来管理整个循环。实心蓝色箭头表示数据及结果流向调度器；虚线橙色箭头表示从调度器发出的控制信号；深灰色箭头表示模块间的内部反馈回路。

使模型能够对结构、性质及工艺背景进行联合推理。第三，基准测试方案不应仅关注能量合理性；在数据允许的情况下，还应评估生成的候选方案是否与实验观测到的合成结果相符[29, 37]。

在此背景下，多模态学习正逐渐成为一种设计接口。实践中，设计意图通常通过部分特征数据、光谱信息、显微图像、处理背景、已有文献以及文本约束条件来表达。因此，多模态模型能够有效整合这些异构输入数据，检索相关先例，并提出更可能实现实验验证的候选方案或操作区域。因此，切实可行的近期策略并非无限制地实现端到端的文本到材料生成，而应采用混合控制方法：在校准后的不确定性范围内，让多模态模型支持约束条件设定、候选方案筛选以及下一步行动选择[22, 26, 31–32, 40]。

6.4 与自动驾驶实验室的连接：部署限制转化为设计限制

一旦将逆向设计方法应用于自动驾驶实验室，其本质特性就会发生根本性改变。在纯计算型工作流程中，可以快速筛选大量候选方案，并将现实验证环节推迟至最终阶段；而在自主实验循环中，发现过程的速度与可靠性则完全受物理系统本身的制约——仪器可用性、排队延迟、校准漂移、批次间差异、合成失败以及异质性测量噪声等因素，共同决定了优化候选方案的实际

意义。在此背景下，可行性不仅取决于结构设计或热力学特性，更取决于设计方案能否以合理成本实现稳定执行，并获得可重复的实验结果。

因此，自动驾驶实验室领域的文献日益将自动化、鲁棒性及可重复性视为闭环材料发现过程中的核心算法约束条件，而非次要的工程问题[33–36, 46–47]。基准测试研究同样表明，要取得实质性进展，必须如实报告实验室实际运行情况：包括处理量、验证预算、失败率与重试率、校准与质量控制流程，以及反映真实操作环境而非理想化假设的评估方案[38]。这些考量直接适用于生成式逆向设计领域——因为优化器的实际价值最终不取决于其能提出多少候选方案，而在于其能在现实约束条件下高效地将设计方案转化为经过验证的材料。图5展示了一个能够满足这些要求的具体协调架构。

6.5 迈向材料发现领域的递归式自我提升

长期目标不仅在于实现模型与实验之间的闭环衔接，更在于使这一闭环随时间推移不断变得更加具有信息价值。从这个角度来看，逆向设计系统不仅能生成候选方案，还能随着新的实验结果、失败案例及工艺知识的积累而持续优化自身的搜索策略。每个迭代周期都能同步提升多个方面：提案机制得到更精准的校准；替代模型在化学空间的相关区域更具可靠性；不确定性评估为决策提供更丰富的信息支持；系统对哪些合成路径和操作参数范围切实可行也形成了更深入的认知。

这种递归式自我提升的视角正日益成为自主材料发现领域的核心理念。其目标已不再仅仅是单次逆向预测，而是构建一个能够持续从成功经验、失败教训及不确定性中学习的自适应发现系统。在此框架下，生成的候选方案转化为假设；验证结果成为训练信号；而实验室本身则成为提供结构化反馈以优化未来决策的源泉。因此，关键挑战在于设计出不仅能循环迭代、更能实现实质性改进的循环机制：这些机制必须保持多样性，对模型偏差和分布偏移具有鲁棒性，并能合理分配实验资源以同时最大化即时进展与长期学习效果。

从这一角度来看，最具说服力的逆向设计系统将是那些将生成建模、多模态推理、不确定性感知选择以及实验反馈整合到统一改进循环中的系统。这正是逆向设计、多模态建模与自动驾驶实验室开始融合为单一发现范式的关键节点。

7 前景

逆向材料设计正从概念验证模型演示阶段迈向可实际部署的发现系统。现阶段，进展程度越来越不取决于单一架构上的突破，而取决于设计方案、多模态约束条件、不确定性感知选择机制以及验证流程在有限计算资源和实验预算下的协同作用。这一转变也使得若干长期存在的科学挑战无法被视作次要问题，包括：如何准确表征约束条件、在分布偏移情况下实现可靠的确定性评估、合理考量验证成本，以及建立生成候选结构与可行合成路径之间的可操作关联[36–38]。因此，生成的结构不应被视为发现成果，而应视为一种假设。要将此类假设转化为实质性进展，需要采用全流程视角进行设计，确保每个组件均支持闭环运行（第2–6节）。在高效的流程中，候选结构会按照透明的验证层级逐步推进：首先进行快速可行性检验，随后进行结构

松弛与稳定性筛选，并在可行情况下进行实验验证。报告各阶段的通过率至关重要，这不仅有助于系统间的可比性评估，还能揭示其在实际运行条件下的失效点[38]。同理，优秀的逆向设计体系不应仅以生成候选结构的数量作为评判标准，而应关注如何高效地将有限的验证资源转化为经过验证的有效结构。这需要采用明确的选择策略，根据校准后的不确定性及预期信息增益来分配计算与实验资源[38]。同样重要的是，不应将失败案例简单归为噪声。无效结构、不稳定的结构松弛结果以及接近成功的候选结构都能为优化方案策略、重新校准替代模型以及改进可行性筛选条件提供有价值的参考，从而提升后续搜索轮次的效果[38]。由于逆向设计系统会主动利用指标和替代指标中的缺陷，*新材料发现*的结论应得到以下支持：(i)分阶段验证记录；(ii)在分布偏移和标签噪声条件下的稳健性检验；(iii)明确记录验证预算；以及(iv)采用能够将阴性结果和失败模式作为科学记录组成部分的报告规范[38–39]。

7.1 数据缺失、检测方式缺失以及阴性结果

当前多模态逆向设计的发展进展不仅受到模型架构的限制，还受限于数据资源的匮乏。许多对于建模-合成条件、过程-性能关系、实验失效结果以及真实条件下微观结构建模最为重要的分析方法，要么数据稀缺，要么存在系统性报告缺失现象。诸如合成尝试失败或预测结果不稳定等负面结果虽极具价值，却鲜少被公开共享。该领域亟需以下类型的资源支持：将计算预测与实验结果精准匹配的精选数据集；明确奖励真正新型材料发现而非已知稳定相再发现的评估体系；以及要求在公布阳性结果的同时披露验证成本与失败率的报告标准[37–39]。

7.2 迈向基于实验的多模态逆向设计

当前最严峻的开放性挑战在于弥合计算预测与实验验证之间的差距。现有研究流程主要针对可从结构预测得出的特性进行优化，但材料发现领域的真正瓶颈在于：所提出的结构能否在实际条件下被合成、表征并应用。多模态学习为实现基于实验数据的逆向设计提供了途径——通过将合成元数据、处理条件及表征数据作为明确的约束信号纳入分析，未来的系统不仅能提出稳定的结构方案，还能设计出可实际合成的结构。要实现这一愿景，需要更紧密地整合实验室自动化系统、结构化实验元数据以及能够全面考虑物理验证成本的不确定性感知筛选策略。

7.3 可重复性与报告标准

随着逆向设计系统日益复杂，可重复性已成为首要的科学关注点。已报道的各项指标（如有效性、新颖性、稳定性）均对匹配标准、数据库版本、优化方案及评估预算等因素高度敏感；这些参数的细微变化都可能导致性能结果出现显著差异。因此，学术界应采用标准化报告规范，内容应包括：完整的分阶段通过率记录、明确的匹配标准与容差范围、以DFT计算次数或每次命中所需的实际运行时间衡量的验证预算，以及候选分子在各流程阶段中的存活比例[38–39]。

数据与代码的可获取性

本次综述未生成新的数据集或代码。

致谢

本研究由鲁汶天主教大学资助（项目编号： ARH / MKK /01155003）。

作者贡献

A.B.构思了本综述，进行了文献分析，制定了文稿结构并撰写初稿。R.A.G.参与了文献分析、科学框架构建及文稿修订工作。G.M.R.负责项目监督，参与概念框架构建并对文稿进行修订。所有作者均共同讨论了内容并最终批准了终稿。

利益声明

作者声明无利益冲突。

参考文献

1. Curtarolo, S. 及其他. 计算材料设计的高通量捷径. *Nature Materials* **12**, 191–201 (2013). doi:10.1038/nmat3568. <https://doi.org/10.1038/nmat3568>
2. Jain, A. 及其他作者. 评论：材料计划——一种通过材料基因组学加速材料创新的方法. *APL Materials* **1**, 011002 (2013). doi:10.1063/1.4812323. <https://doi.org/10.1063/1.4812323>
3. Ward, L. 等. Matminer: 一种用于材料数据挖掘的开源工具包. *计算材料科学* **152**, 60–69 (2018). doi: 10.1016/j.commatsci.2018.05.018. <https://doi.org/10.1016/j.co/mmatsci.2018.05.018>.
4. Choudhary, K. 及其他. 针对数据驱动材料设计的多种集成模拟联合自动化存储库 (jarvis). *npj Computational Materials* **6**, 173 (2020). doi:10.1038/s41524-020-00440-1. <https://doi.org/10.1038/s41524-020-00440-1>
5. Kirklin, S. 等人. 开放量子材料数据库 (OQMD)：评估DFT形成能的准确性. *npj Computational Materials* **1**, 15010 (2015). doi:10.1038/npjcompumats.2015.10. <https://doi.org/10.1038/npjcompumats.2015.10>
6. 萨尔, J. E. 等. 基于高通量密度泛函理论的材料设计与发现：开放量子材料数据库 (OQMD). *JOM* **65**, 1501–1509 (2013). doi:10.1007/s11837-013-0755-4. <https://doi.org/10.1007/s11837-013-0755-4>
7. 翁·S·P. 等人. Python材料基因组学 (pymatgen)：一个用于材料分析的稳健、开源Python库. *计算材料科学* **68**, 314–319 (2013). doi:10.1016/j.commatsci.2012.10.028. <https://doi.org/10.1016/j-commatsci.2012.10.028>
8. Lookman, T., Balachandran, P. V., Xue, D. 和 Yuan, R. 材料科学中的主动学习：重点探讨利用不确定性进行自适应采样以实现目标导向设计. *npj Computational Materials* **5**, 21 (2019). doi:10.1038/s41524-019-0153-8. <https://doi.org/10.1038/s41524-019-0153-8>
9. Shahriari, B., Swersky, K., Wang, Z., Adams, R. P. 和 de Freitas, N. 将人类因素排除在外：贝叶斯优化综述. *IEEE 会议录* **104**, 148–175 (2016). doi:10.1109/JPROC.2015.2494218. <https://doi.org/10.1109/JPROC.2015.2494218>

10. Snoek, J., Larochelle, H. 和 Adams, R. P. 机器学习算法的实用贝叶斯优化。《神经信息处理系统进展》25 (2012)。 <https://arxiv.org/ab/1206.2944>
11. Frazier, P. I. 关于贝叶斯优化的教程。 *arXiv*(2018)。 arXiv:1807.02811. <https://arxiv.org/abs/1807.02811>
12. Settles, B. Active Learning Literature Survey . 威斯康星大学麦迪逊分校, Computer Sciences Technical Report 1648 (2009)。 <https://minds.wisconsin.edu/handle/1793/60660>
13. Hase, F. 、 Roch, L. M. 和 Aspuru-Guzik, A. Phoenix: 一种用于化学领域的贝叶斯优化器。 *ACS Central Science* 4, 1134–1145 (2018). doi:10.1021/acscentsci.8b00307. <https://doi.org/10.1021/acscentsci.8b00307>
14. Hase, F., Roch, L. M. 和 Aspuru-Guzik, A. Gryffin: 一种基于物理直觉对分类变量进行贝叶斯优化的算法及其在化学领域的应用。 *ACS Central Science* 7, 1230–1237 (2021). doi:10.1021/acscentsci.0c01520. <https://doi.org/10.1021/acscentsci.0c01520>
15. 罗X.等人。用于晶体结构预测的深度学习生成模型。 *npj Computational Materials* 10, 254 (2024). doi:10.1038/s41524-024-01443-y. <https://doi.org/10.1038/s41524-024-01443-y>
16. Xie, T. 等.用于周期性材料生成的晶体扩散变分自编码器. *arXiv*(2021) . arXiv:2110.06197. <https://arxiv.org/abs/2110.06197>
17. Jiao, R. 等.通过联合等变扩散进行晶体结构预测. *arXiv*(2023) . arXiv:2309.04475. <https://arxiv.org/abs/2309.04475>
18. 赵Y.等人。用于晶体生成的概率约束图变分自编码器。 *npj Computational Materials* 9, 30 (2023). doi:10.1038/s41524-023-00987-9. <https://doi.org/10.1038/s41524-023-00987-9>
19. Qiu, J. 等. VQCrystal:一种用于晶体生成的向量量化扩散框架. *npj 计算材料* 11,63 (2025). doi:10.1038/s41524-025-01613-6. <https://doi.org/10.1038/s41524-025-01613-6>
20. Zeni, C. 及其他作者. 一种用于无机材料设计的生成模型 (MatterGen) . *Nature* (2025年) <https://www.nature.com/articles/s41586-025-08628-5>
21. Luo, X. 等. CrystalFlow: 一种基于流的晶体结构预测与材料发现生成模型. 《自然通讯》(2025). <https://www.nature.com/articles/s41467-025-64364-4>
22. Park, C. W. 等. 利用文本引导生成式人工智能探索晶体化学空间. 《自然通讯》(2025). doi:10.1038/s41467-025-59636-y. <https://www.nature.com/articles/s41467-025-59636-y>
23. 任Z.等人。一种用于具有目标性质的无机晶体通用逆向设计的可逆晶体学表示方法。 *Matter* 5, 314–335 (2022). doi:10.1016/j.matt.2021.11.032. <https://doi.org/10.1016/j.matt.2021.11.032>
24. Ho, J. 、 Jain, A. 和 Abbeel, P. 提出的去噪扩散概率模型。 *arXiv*(2020). arXiv:2006.11239. <https://arxiv.org/abs/2006.11239>
25. 宋, Y.、 索尔-迪克斯坦, J.、 金马, D. P.、 库马尔, A.、 埃尔蒙, S. 和普尔, B. 基于随机微分方程的评分生成建模。 *arXiv*(2020). arXiv:2011.13456. <https://arxiv.org/abs/2011.13456>
26. 吴Y.等。一种融合多尺度知识以支持材料设计的通用多模态学习框架。 *npj Computational Materials* (2025) 。 doi:10.1038/s41524-025-01767-3. <https://doi.org/10.1038/s41524-025-01767-3>
27. Moro, V. 等.用于材料性能预测与发现的多模态基础模型. *牛顿* (2025). PII :S2950636025000088. <https://www.sciencedirect.com/science/article/pii/S2950636025000088>

28. Babu, A. 等人. MEIDNet: 用于逆向材料设计的多模态生成式AI框架. arXiv(2026). arXiv:2601.22009. doi:10.48550/arXiv.2601.22009. <https://arxiv.org/abs/2601.22009>
29. Kononova, O. 等. 无机材料合成配方的文本挖掘数据集. 《科学数据》 **6**,203 (2019). doi:10.1038/s41597-019-0224-1. <https://doi.org/10.1038/s41597-019-0224-1>
30. Tshitoyan, V. 等. 无监督词嵌入技术从材料科学文献中捕捉潜在知识. *Nature* **571**, 95–98 (2019). doi: 10.1038/s41586-019-1335-8. <https://doi.org/10.1038/s41586-019-1335-8>
31. Olivetti, E. A. 等. 基于自然语言处理与信息提取的数据驱动材料研究. 《应用物理评论》 **7**,041317 (2020). doi:10.1063/5.0021106. <https://doi.org/10.1063/5.0021106>
32. Venugopal, V. 和 Olivetti, E. A. MatKG: 材料科学领域的知识图谱. *Scientific Data* **11**, 141 (2024). doi: 10.1038/s41597-024-03039-z. <https://doi.org/10.1038/s41597-024-03039-z>
33. Stach, E. 及其他. 材料开发的自主实验系统: 从社区视角出发. *Nature Communications*(2020). doi: 10.1038/s41467-020-19597-w. <https://doi.org/10.1038/s41467-020-19597-w>
34. 伯格, B. 及其他. 一种移动式机器人化学家. *Nature* **583**, 237–241 (2020). doi:10.1038/s41586-020-2442-2. <https://doi.org/10.1038/s41586-020-2442-2>
35. MacLeod, B. P. 等. 用于加速薄膜材料发现的自驱动实验室. 《科学进展》 **6**,eaz8867 (2020). doi:10.1126/sciadv.aaz8867. <https://doi.org/10.1126/sciadv.aaz8867>
36. Flores-Leonar, M. M. 及其他作者. 材料加速平台: 迈向自主实验之路. *Nature Reviews Materials* **5**, 575–590 (2020). doi:10.1038/s41578-020-0226-2. <https://doi.org/10.1038/s41578-020-0226-2>
37. 德·布雷克, W. 及其他. 晶体结构的生成式人工智能: 综述. *npj Computational Materials* (2025). doi: 10.1038/s41524-025-01881-2. <https://doi.org/10.1038/s41524-025-01881-2>
38. Wagner, J. 及其他. 自动驾驶实验室中的机器学习基准测试. *Digital Discovery*(2026). doi:10.1039/D5DD00337G. <https://doi.org/10.1039/D5DD00337G>
39. Dunn, A. 等人. 材料性能预测方法的基准评估: Matbench 测试集与 Automatminer 参考算法. *npj Computational Materials* **6**, 138 (2020). doi:10.1038/s41524-020-00406-3. <https://doi.org/10.1038/s41524-020-00406-3>
40. Kent, P. 及其他. 材料发现的基础模型——现状与未来方向. *npj Computational Materials*(2025). doi:10.1038/s41524-025-01538-0. <https://www.nature.com/articles/s41524-025-01538-0>
41. Butler, K. T., Davies, D. W., Cartwright, H., Isayev, O. 和 Walsh, A. . 分子与材料科学中的机器学习. 《自然》 **559**, 547–555 (2018). doi:10.1038/s41586-018-0337-2. <https://doi.org/10.1038/s41586-018-0337-2>
42. 施密特, J.、马克斯, M. R. G.、博蒂, S. 和马克斯, M. A. L. 固态材料科学中机器学习的最新进展与应用. *npj Computational Materials* **5**, 83 (2019). doi:10.1038/s41524-019-0221-0. <https://doi.org/10.1038/s41524-019-0221-0>
43. Batra, R. 、 Song, L. 和 Ramprasad, R. : 由机器学习驱动的新兴材料智能生态系统. *Nature Reviews Materials* **6**, 655–678 (2021). doi:10.1038/s41578-020-00255-y. <https://doi.org/10.1038/s41578-020-00255-y>
44. Chen, C. 等人. 用于无机固体材料逆向设计的生成模型. 《Materials Informatics 杂志》 (2021年). <https://www.oaepublish.com/articles/jmi.2021.07>
45. Jha, D. 等. ElemNet: 仅通过元素组成实现材料化学的深度学习. *Scientific Reports* **8**, 17593 (2018). doi: 10.1038/s41598-018-35934-y. <https://doi.org/10.1038/s41598-018-35934-y>
46. Fudge, B. 及其他. 自主驱动实验室的设计与实现. *Digital Discovery*(2024). <https://doi.org/10.1039/D4DD00059E>

47. Hysmith, H., Foadian, E., Padhy, S. P., Kalinin, S. V., Moore, R. G., Ovchinnikova, O. S. 与 Ahmadi, M. 自主驱动实验室的未来：从人机交互式人工智能到游戏化。 *Digital Discovery* (2024)。 doi:10.1039/D4DD00040D。 <https://doi.org/10.1039/D4DD00040D>
48. Han, X.-Q. 等人的研究.InvDesFlow-AL:一种基于主动学习的功能材料逆向设计工作流程。*npj Computational Materials*(2025).doi:10.1038/s41524-025-01830-z.<https://doi.org/10.1038/s41524-025-01830-z>
49. Antunes, L. M. 等人的研究:CrystaLLM——一种数据高效的无机晶体结构自回归生成方法。《自然通讯》 **15**,10570 (2024)。 doi:10.1038/s41467-024-54639-7.<https://www.nature.com/articles/s41467-024-54639-7>
50. Chenebua, C. 、 Qi, Y. 和 Ghosh, P. 利用图自动编码器研究晶体形态以实现逆向设计。 *npj Computational Materials* **10**, 129(2024)。 doi:10.1038/s41524-024-01381-9.<https://doi.org/10.1038/s41524-024-01381-9>
51. Davies, D. W. 等人 SMACT：基于类比与化学理论的半导体材料研究。《Open Source 软件杂志》 **4**, 1361 (2019)。 doi:10.21105/joss.01361.<https://doi.org/10.21105/joss.01361>
52. 王, A. Y.-T. 等。基于成分限制的注意力网络用于材料性能预测。 *npj Computational Materials* **7**, 77 (2021)。 doi:10.1038/s41524-021-00545-1.<https://doi.org/10.1038/s41524-021-00545-1>
53. 古道尔, R. E. A. 和李, A. A. 无需晶体结构即可预测材料性质：基于化学计量学的深度表征学习。 *npj Computational Materials* **6**, 148 (2020)。 doi:10.1038/s41524-020-00381-w.<https://doi.org/10.1038/s41524-020-00381-w>
54. Court, C. J. 与 Cole, J. M.：通过表示学习生成三维无机晶体结构并预测其性质。 *J. Chem. Inf. Model.* (2020) <https://pubs.acs.org/doi/10.1021/acs.jcim.0c00048>
55. Kim, B. 及其他。用于晶体结构预测的生成对抗网络。*ACS Central Science*(2020).<https://pubs.acs.org/doi/10.1021/acscentsci.0c00426>
56. Gao, Y. 等。ConditionCDVAE+:基于物理信息的条件晶体生成。《科学报告》(2025年)<https://www.nature.com/articles/s41598-025-06432-9>。
57. Karras, T. 、 Aittala, M. 、 Aila, T. 和 Laine, S.：阐明基于扩散的生成模型的设计空间。 *arXiv* (2022)。 arXiv:2206.00364.<https://arxiv.org/abs/2206.00364>
58. 卡尔波维奇, C.等人。逆向无机材料设计的深度强化学习。 *npj Computational Materials* (2024)。 doi:10.1038/s41524-024-01474-5。 <https://doi.org/10.1038/s41524-024-01474-5>
59. 伊萨耶夫, O.等人。用于预测无机晶体性质的通用片段描述符。 *Nature Communications* **8**, 15679 (2017)。 doi:10.1038/ncomms15679.<https://doi.org/10.1038/ncomms15679>
60. Suzuki, H. 等人。文本与晶体结构的桥梁：面向材料科学的文献驱动对比学习。 *AI4Mat @ NeurIPS* (2024)。 OpenReview: JPL2XhDqeM。 <https://openreview.net/forum?id=JPL2XhDqeM>
61. 小泽, N.等人。无机晶体结构的图文本对比学习——面向无机材料基础模型的研究。 *STAM Methods* (2024)。 doi:10.1080/27660400.2024.2406219。 <https://doi.org/10.1080/27660400.2024.2406219>
62. Das, K. 等人。CrysMMNet: 用于 Crystal Property 预测的 Multimodal Representation。 *Machine Learning 研究会议录 (UAI)* **216** (2023)。 <https://proceedings.mlr.press/v216/das23a.html>
63. Court, C. J., Jain, A. 和 Cole, J. M. 通过科学文献文本挖掘与生成式深度学习实现具有磁热效应材料的逆向设计。《材料化学》 **33**, 7217–7230 (2021)。 doi:10.1021/acs.chemmater.1c01368.<https://pubs.acs.org/doi/10.1021/acs.chemmater.1c01368>

64. 戈麦斯-邦巴雷利, R.、魏, J. N.、杜韦诺, D.、埃尔南德斯-洛巴托, J. M.、桑切斯-伦赫林, B.、谢贝拉, D.、阿吉莱拉-伊帕拉吉雷, J.、希尔泽尔, T. D.、亚当斯, R. P. 和阿斯普鲁-古齐克, A. 基于数据驱动分子连续表征实现自动化学设计。 *ACS Central Science* 4(2), 268–276 (2018). doi:10.1021/acscentsci.7b00572. <https://doi.org/10.1021/acscentsci.7b00572>
65. 肖H、李R、石Q、陈Y、郑L、陈F和徐L. 基于生成式深度学习的固态材料逆向设计中可逆且不变的晶体表征。 *Nature Communications* 14, 7027 (2023). doi:10.1038/s41467-023-42870-7. <https://doi.org/10.1038/s41467-023-42870-7>
66. Hansen, N. The CMA Evolution Strategy : 一份教程。 *arXiv*(2016)。 arXiv:1604.00772。 <https://arxiv.org/abs/1604.00772>
67. 韦林, M. 和特赫, Y. W. 基于随机梯度朗之万动力学的贝叶斯学习。 载于第28届国际机器学习会议论文集, 第681–688页 (2011年)。 https://icml.cc/2011/papers/398_icmlpaper.pdf
68. 李, C.、陈, C.、卡尔森, D. 和卡林, L. 《深度神经网络的预条件随机梯度朗之万动力学》。 载于第30届美国人工智能协会人工智能会议论文集 30(1), 1788–1794 (2016)。 <https://ojs.aaai.org/index.php/AAAI/article/view/10200>
69. Ho, J. 与 Salimans, T. 分类器的 Free Diffusion 指南。 *arXiv 预印本* arXiv:2207.12598 (2022)。 <https://arxiv.org/abs/2207.12598>
70. 舒尔曼, J.、沃尔斯基, F.、达里瓦尔, P.、拉德福德, A. 和克利莫夫, O. 近端策略优化算法。 *arXiv 预印本* arXiv:1707.06347 (2017)。 <https://arxiv.org/abs/1707.06347>
71. Banik, S., Dhabal, D., Chan, H., Manna, S., Cherukara, M., Molinero, V. 和 Sankaranarayanan, S. K. R. S. 等: 基于注意力机制神经网络从成分推导晶体结构。 *npj Computational Materials* 9, 117 (2023). doi:10.1038/s41524-023-01094-5. <https://doi.org/10.1038/s41524-023-01094-5>
72. 库斯内, A. G.、余, H.、吴, C.、张, H.、哈特里克-辛普斯, J.、德科斯特, B.、萨克尔, S.、奥塞斯, C.、托赫, C.、库尔塔罗洛, S.、达维多夫, A. V.、阿加瓦尔, R.、本德斯基, L. A.、李, M.、梅塔, A. 和竹内, I. 基于贝叶斯主动学习的实时闭环材料发现。 *《自然·通讯》* 11, 5966 (2020). doi:10.1038/s41467-020-19597-w. <https://doi.org/10.1038/s41467-020-19597-w>
73. Merchant, A.、Batzner, S.、Schoenholz, S. S.、Aykol, M.、Cheon, G. 和 Cubuk, E. D. : 面向材料发现的深度学习方法。 *《自然》* 624, 80–85 (2023). doi:10.1038/s41586-023-06735-9. <https://doi.org/10.1038/s41586-023-06735-9>
74. Volk, A. A. 与 Abolhasani, M. 自主流动化学平台: 基准测试与评估标准。 *Nature Communications* 15, 5433 (2024). doi:10.1038/s41467-024-49716-4. <https://doi.org/10.1038/s41467-024-49716-4>
75. Szymanski, N. J. 等。 一个用于新型材料快速合成的自主实验室。 *Nature* 624, 86–91 (2023). doi:10.1038/s41586-023-06734-w. <https://doi.org/10.1038/s41586-023-06734-w>
76. Rombach, R.、Blattmann, A.、Lorenz, D.、Esser, P. 和 Ommer, B. : 基于潜在扩散模型的高分辨率图像合成。 *CVPR* (2022)。 doi:10.1109/CVPR52688.2022.01042。 <https://doi.org/10.1109/CVPR52688.2022.01042>
77. Diwale, S. 及其他. 基于含噪声及不可靠测量数据的材料发现过程贝叶斯优化方法。 *Molecular Systems Design & Engineering*(2022). <https://doi.org/10.1039/D1ME00154J>
78. 田K. 等。 基于目标导向贝叶斯优化的材料设计 (t-EGO)。 *npj Computational Materials* (2025)。 doi:10.1038/s41524-025-01704-4。 <https://doi.org/10.1038/s41524-025-01704-4>
79. Chitturi, K. 及其他. 基于贝叶斯算法执行的靶向材料发现。 *npj Computational Materials* 10, 126 (2024). doi:10.1038/s41524-024-01326-2. <https://doi.org/10.1038/s41524-024-01326-2>

80. Riebesell, J., Goodall, R. E. A., Benner, P., Chiang, Y., Deng, B., Ceder, G., Asta, M., Lee, A. A., Jain, A. 和 Persson, K. A. 评估机器学习晶体稳定性预测的框架。《自然·机器学习》7, 836–847 (2025). doi:10.1038/s42256-025-01055-3. <https://doi.org/10.1038/s42256-025-01055-3>
81. 斯凯尔斯, J.、豪, N. H. R.、克拉申尼科夫, D. 和克鲁格, D. 《奖励游戏的定义与特征描述》。《神经信息处理系统进展》35 (2022)。 <https://arxiv.org/abs/2209.13085>
82. Amodei, D.、Olah, C.、Steinhardt, J.、Christiano, P.、Schulman, J. 和 Mane, D. 在《人工智能安全》期刊上发表的 Concrete Problems。arXiv(2016)。arXiv:1606.06565。 <https://arxiv.org/abs/1606.06565>
83. 奥瓦迪亚, Y.、费蒂格, E.、任, J.、纳多, Z.、斯卡利, D.、诺沃津, S.、狄龙, J. V.、拉克什米纳拉扬, B. 和 斯诺克, J. 你能信任模型的不确定性吗? 评估数据集变化下的预测不确定性。神经信息处理系统进展32 (2019)。 <https://arxiv.org/abs/1906.02629>
84. Kapoor, S. 与 Narayanan, A. 泄漏以及基于机器学习的科学研究中的可重复性危机。模式4(9), 100804(2023). doi:10.1016/j.patter.2023.100804. <https://doi.org/10.1016/j.patter.2023.100804>
85. 卡普尔, S. 及其他。改革: 基于共识的机器学习科学实践建议。《科学进展》10(18), eadk3452 (2024)。doi:10.1126/sciadv.adk3452。 <https://doi.org/10.1126/sciadv.adk3452>
86. 郭慈、普莱斯·G·、孙宇和温伯格·K·Q. 《现代神经网络的校准》。载于第34届国际机器学习会议论文集70, 1321–1330 (2017)。 <https://arxiv.org/abs/1706.04599>
87. Negishi, M.、Park, H.、Mastej, K. O. 和 Walsh, A. Continuous Uniqueness 及 Novelty Metrics, 用于 Inorganic Crystals 的 Generative Modeling。arXiv(2025)。arXiv:2510.12405。 <https://arxiv.org/abs/2510.12405>
88. Widdowson, D. 并 Kurlin, V. 采用本地新颖性距离的地理风格地图, 有助于在材料空间中进行导航。Scientific Reports 15, 27588 (2025)。doi:10.1038/s41598-025-10672-0. <https://doi.org/10.1038/s41598-025-10672-0>
89. 山崎, S.、黄, Y.、彼得森, M. H.、农, W. 和希帕尔加翁卡尔, K. 通过群组-子群转换导航有序(无序)谱系树。arXiv(2026)。arXiv:2604.21386. <https://arxiv.org/abs/2604.21386>
90. Gouvea, R. A. 和 Rignanese, G.-M. VibroML: 一种利用机器学习势能对晶体材料进行高通量振动分析及动态不稳定性校正的自动化工具包。arXiv(2026)。arXiv:2604.27685. <https://arxiv.org/abs/2604.27685>