

利用生成式人工智能进行无机化合物的逆向设计


汉内斯·克奈丁¹、卢克·莫兰·冈萨雷斯¹、尼沙莫尔·库里亚科塞¹、艾娜拉·诺瓦¹以及大卫·巴尔塞尔斯^{1, *}

¹ 海勒拉斯量子分子科学中心，奥斯陆大学化学系，邮政信箱1033，布林德恩，0315奥斯陆，挪威

*david.balcells@kjemi.uio.no

摘要

机器学习正在彻底改变化学领域。除了预测模型在加速虚拟筛选方面的价值外，生成式人工智能还致力于实现逆向设计，将化合物到性质的预测范式转变为从性质到化合物的生成过程。如今，化学家已能使用一套丰富的AI工具箱应用于有机化学研究（包括药物研发）。然而，这些方法在无机化合物领域的应用仍受到其固有特性带来的挑战限制。本综述分析了如何应对这些挑战，涵盖从分子到晶体、过渡金属配合物及微孔材料等广泛多样的体系，并重点探讨生成式AI方法如何演进为能够全面处理无机化合物复杂性的数据-表征-模型流程——包括其化学组成、几何结构、对称性及电子结构。文中还讨论了未来发展方向，如基准标准化及合成可行性指标的开发。



引言

无机化合物的开发与应用既受到经验性发现的推动，也得益于理性设计的指导。过去一个世纪见证了范式的转变：先是配位化学的出现，随后是固态理论以及定制孔隙率概念的提出。

配位化学的基础于1893年随着阿尔弗雷德·维尔纳的开创性工作而奠定，他首次提出了金属-配体键合的结构描述。¹这一概念为过渡金属配合物（TMCs）奠定了基础——其中金属中心与一组配体结合（图1a）。由配体以及金属配位数、几何构型和氧化态所决定的分子结构多样性，已被广泛应用于极其广泛的领域。现代有机合成依赖于TMC催化的不对称氢化反应^{2,3}及C-C交叉偶联反应⁴⁻⁷，这些反应从微摩尔级的发现研究到数千克规模的工业化生产均被常规应用。⁸除上述核心作用外，TMCs还催生了经过临床验证的金属药物⁹、介导C-H键活化反应¹⁰，并推动了可再生能源技术的发展。^{11,12}表征技术与计算化学领域的重大进展使得金属-配体相互作用的电子建模成为可能。^{13,14}这种更深入的认知进而推动了光氧化还原催化技术的发展¹⁵⁻¹⁷、双金属体系设计¹⁸以及复杂TMC催化路径的全面阐明¹⁹。当前TMC化学的研究前沿包括利用地球常见金属进行催化反应²⁰以及下一代金属药物及其在量子信息科学中的应用。²²

早期的晶体学技术揭示了固体的原子排列结构，但其理性设计最初仍难以实现。这一状况随着网状化学的发展而开始改变——该方法将构建单元组装成具有可控孔隙率的扩展框架。²³此后，金属有机框架（MOFs）作为一类典型的模块化结晶微孔固体应运而生（图1c）。其结构允许在不改变底层网络拓扑结构的前提下系统地调控孔径、几何形状及化学功能特性，这一概念性突破被授予2025年诺贝尔化学奖。²⁴⁻²⁶MOFs凭借卓越的可调性和高内表面积，成为气体捕获²⁷⁻³¹与储存³²⁻³⁴以及液相分子分离³⁵领域的理想材料，这些应用均广泛应用于能源相关技术领域。³⁶尽管早期实例往往缺乏耐久性，但基于铬和锆的框架材料^{37,38}通过结合大体积孔隙与高稳定性，使得MOFs能够在严苛的电化学³⁹及催化^{40,41}条件下得到应用。

早在网状化学理论被正式确立之前，关于可控孔隙率的相关概念已在沸石领域得到探索。⁴²与MOFs不同，沸石由更为有限的铝硅酸盐四面体框架组成（图1c）。每个结构均具有固定的通道尺寸，并通过表示其底层拓扑结构的三位字母代码进行分类。刚性的SiO₄/AlO₄网络结构，结合可调控的 Brønsted 值和路易斯酸性，赋予了沸石优异的稳定性和显著的形状选择性^{43,44}，使其成为石化工业中大规模分离过程和异相催化领域的理想材料⁴⁵⁻⁴⁹；现代合成方法^{50 51} 52 53 相关策略重点强调采用更环保的路线、通过孤立金属单位点进行成分调控，以及构建固有的介观/微

观多孔通道体系。⁵⁴与此同时，计算方法学正将催化作用的固态与分子描述符⁵⁵整合到设计过程中。将沸石作为纳米反应器，同时考虑扩散效应和限制效应。⁵⁶




图1.本综述涵盖的无机化合物。**a)**过渡金属配合物由一组配体支撑的金属中心构成。**b)**非多孔无机晶体由金属或离子组成，形成致密的周期性结构。**c)**微孔无机材料具有由金属节点连接体（MOFs）或铝硅酸盐（沸石）构建单元组成的多孔网状结构；在MOFs中，金属节点亦可为单原子阳离子。

虽然MOFs和沸石的大部分应用价值源于其内部表面积，但非多孔无机晶体则通过致密、长程的周期性堆积结构实现功能特性。诸如合金⁵⁷和二维层状材料⁵⁸等致密无机材料，凭借连续轨道重叠效应实现了高强韧性和高载流子迁移率的结合。具有通式 ABX_3 （图1b）的钙钛矿材料同时具备缺陷耐受性、带隙可调性及多种光学性能⁵⁹⁻⁶¹，这些特性使其在光伏器件^{62,63}、X射线探测器⁶⁴以及电催化剂⁶⁵中得到迅速应用。当前研究致力于将单电池效率提升至单结理论极限⁶⁶⁻⁶⁸；另一方向则聚焦于提升长期运行稳定性^{61,69,70}并降低铅泄漏至环境中的风险。⁷¹

日益增长的能源需求、抗菌药物耐药性以及气候变化所引发的危机，推动了无机化合物的进一步发展。应对这些挑战的核心技术需要更具活性和选择性的催化剂^{72,73}与金属药物⁷⁴，以及更高效的用于能量存储与转换的微孔及晶体材料^{75,76}。在此背景下，机器学习（ML）乃至更广泛的人工智能（AI）正加速新型无机化合物的研究与发现。与侧重于化合物-性质预测的判别式AI不同，生成式AI通过逆向性质-化合物方法实现了新型分子与材料的反向设计^{77,78}。本文综述中，我们将探讨生成式AI如何成为无机化学领域的有力工具，并分析这些方法的优势与局限性如何界定应用边界并揭示协同创新机遇。下一节将概述最相关的方法。

生成式人工智能系统

用于逆向设计的生成式AI方法（框1）可分为深度学习（DL）和进化计算（EC）两大类。深度学习方法利用神经网络学习内部表征——即潜在空间，并据此生成化合物。当前最先进的方法包括扩散模型（DMs）、⁷⁹变分自编码器（VAEs）⁸⁰以及大型语言模型（LLMs）⁸¹。诸如生成对抗网络（GANs）⁸²（尤其是深度强化学习）⁸³等深度学习方法在该领域的发展相对滞后，因其更适用于图像生成和决策问题等其他任务。生成式AI方法可通过随机生成化合物（无条件生成）突破百万体系规模限制来探索化学空间⁸⁴，随后通过高通量虚拟筛选（HTVS）验证其性质。然而鉴于无机化合物空间近乎无限庞大，条件生成法的逆向设计更为优选，因其能直接引导生成过程聚焦于满足目标特性要求的有限化合物集合。例如，在催化剂和能源材料的逆向设计中，这些特性分别可表现为能垒和带隙。

在EC方法中，⁸⁵逆向设计是优化适应度函数的核心要素，该函数用于评估候选解满足目标属性的程度。遗传算法（GAs）作为最成熟的EC方法之一（见框1），通过遗传操作结合选择过程来实现这一目标，使候选解群体朝着最大适应度值方向演化。由于无机化合物具有模块化特性，遗传算法特别适用于此类研究——这使得改变或交换结构单元的遗传操作能够被明确定义；例如在金属有机框架（MOFs）中，金属节点与有机连接基团即构成典型示例（图1c）。

框1. 选定的生成式人工智能方法：深度学习。

扩散模型 (DM)。该模型通过受控的随机过程将化合物表征转化为噪声，随后利用神经网络学习逆去噪过程以恢复原始表征。去噪与表征重建过程均采用顺序化、逐步化的处理方式。在逆向设计中，去噪步骤会同时考虑表征信息及条件概率分布中的目标性质；经过模型训练后，该方法可引导设计过程聚焦于满足目标性质约束的化学空间区域。流模型可视为扩散模型的一种变体，其去噪过程采用学习得到的微分方程而非随机过程实现。

生成对抗网络 (GAN)。该模型基于两个相互竞争的神经网络：一个从随机噪声中生成化合物（*生成器*），另一个将这些化合物与训练数据分布区分开来（*判别器*）。GAN通过迭代训练，直至生成化合物的分布与训练数据分布无法区分（*纳什均衡*）。对于逆向设计任务，模型还会输入目标属性的已知值，从而约束生成器仅生成符合该属性的化合物。

大语言模型 (LLM)。一种利用复杂神经网络（*Transformer*）处理如化学式等字符串格式化学信息的模型。通过能够感知生成过程中整个字符串状态的机制（*自注意力机制*），LLM可预测构成化合物名称的字符串中下一个片段（*标记*）（*自回归机制*）。通用型LLM可通过提供特定信息的数据集进行再训练（*微调*），例如针对大量无机化合物所需性质的数据集。在逆向设计中，LLM通过工程化提示词（*思维链*）引导对话（*上下文窗口*），使化学家能够请求生成具有指定性质的化合物。在代理式AI系统中，LLM还作为“封装器”承载核心生成式AI模型（如遗传算法），充当与用户的交互界面。

变分自编码器 (VAE)。该模型首先学习将输入化合物编码为内部表征（*潜在空间*），随后再学习将其解码为重建后的原始化合物。编码器和解码器通常采用图神经网络结构，经过训练可最大化重建质量，并使潜在空间向正态分布靠拢。在逆向设计中，还会额外添加一个神经网络，并与编码器和解码器联合训练，将潜在空间映射至目标属性值。这使得能够在潜在空间中导航，从而找到并解码具有所需属性值的化合物。

框1（续）：精选生成式人工智能方法：进化计算。

遗传算法（GA）。一种优化算法，通过多次迭代（*种群*），利用随机变化（*突变*）和交换（*交叉*）操作，对化合物的模块化表示（*染色体中的基因*）进行复制与多样化。该算法无需训练数据，而是在每一代探索化学空间的过程中实时生成。进化过程由每代根据目标属性的适应度函数筛选出最适化合物（*存活者*）来驱动；通过概率选择存活者，确定能够通过遗传操作产生下一代（*后代*）的化合物（*父代*）。逆向设计是这种针对极端值的无梯度适应度优化方法的核心特征。多目标优化还可用于探索多个目标的联合最优区域（帕累托前沿）。

数据与数据表征对于构建框1中总结的人工智能模型也至关重要。数据的质量（包括其正确性与覆盖范围）尤为关键，因为这直接决定了模型在训练过程中所需达到的质量标准。虽然遗传算法等进化计算方法无需训练数据，但仍需数据来定义遗传操作中涉及的构建单元。尽管这类数据仍比有机化合物数据更为稀缺，但可用于生成式人工智能的无机化合物数据集库正在不断扩充，涵盖了TMC、MOF、沸石及无机晶体空间中的广泛且多样化的区域（表1）。

生成式人工智能需要在输入层面（用于训练模型）和输出层面（用于生成结果）都具备化学化合物的机器可读表示形式。这些表示形式包含成分与结构信息，根据数据集的特性（表1），可以是实验性的（如X射线衍射结构（CIF文件；CIF=晶体学信息文件））或计算性的（如通过密度泛函理论（DFT）计算优化得到的几何结构（XYZ文件，含原子 x 、 y 、 z 笛卡尔坐标））。相较于有机分子，无机化合物在化学组成、电子结构和几何构型方面具有更高的复杂性：涉及更广泛的元素种类、 d 和 f 轨道对成键的贡献，以及受对称约束影响的周期性特征。此外，生成式AI所需的表示形式必须具备可逆性，因为它们既是模型的输入也是输出。表2列出了适用于生成式AI的无机化合物表示形式示例。在这些模型中纳入化学数据并结合物理原理进行应用，可显著提升其在逆向设计任务中的性能表现。

表1.针对无机化合物生成式AI模型训练所选数据集。

Name ^a	尺寸	目录	摩尔数/物质 ^b	Ref.
CSD	1.4M	实验组成与结构数据	都	86
COD	0.5M	实验组成与结构数据	都	87
无机化学结构数据库	328k	实验性、计算性的组成与结构数据	都	88
PCD	395k	实验性、计算性的组成与结构数据	母亲	89
MP	785k	计算结构、量子及热力学数据	都	90
OQMD	1.4M	计算结构、量子及热力学数据	母亲	91
OC22	62k	计算异质催化数据	都	92
OMat24	110M	计算结构、量子及热力学数据	母亲	93
OMol25	83M	计算结构、量子及热力学数据	Mol	94
tmQM	108k	TMC的计算结构与量子数据	Mol	95–97
核心：核心要素	40k	MOF 实验数据、计算数据、组成数据及结构数据	母亲	98,99
hMOF	138k	MOF 构建结构数据	母亲	100
L2M3	40k	MOF 实验合成与性质数据	母亲	101
Zeo-1	33k	沸石的计算结构与量子数据	母亲	102

^a缩写：CSD = 剑桥结构数据库；COD = 晶体学开放数据库；ICSD = 无机化合物数据库

晶体结构数据库；PCD = 皮尔逊晶体数据；MP = 材料项目；OQMD = 开放量子材料数据库；OC22 = 开放催化剂2022；OMat 24 = 开放材料2024；OMol25 = 开放分子2025；tmQM = 过渡金属量子力学；CoRE = 计算就绪实验；hMOF = 高阶有机框架。

假设 MOF 中：Zeo = 岩棉；^b Mol = 分子；Mater = 材料。

虽然预测性机器学习模型只需通过测量其预测误差与训练数据真实值的差异即可进行评估，但生成式人工智能模型的质量则更难量化。从本质上讲，生成的无机化合物只有在具备独特性、新颖性和有效性时才具有价值。生成化合物的稳定性、多样性以及在实验实验室中的制备便捷性等也是关键考量因素。由于这类化合物的表征存在诸多挑战，相较于有机分子，AI生成的无机化合物更难以评估。在本综述的展望部分，我们提出了一系列评估指标（见框2），可用于构建系统的评估流程以制定标准化基准。

迄今为止，对无机化合物生成式AI模型的评估表明，深度学习方法需要大量训练数据和复杂的表征方式才能实现较高的化学有效性。此外，基于多种目标属性的逆向设计任务仍面临挑战。最先进的深度学习模型不仅能支持目标属性的欧几里得不变性等高级特征，还能大规模生成多样化、独特且新颖的化合物。虽然电子化学方法在此方面的性能稍逊，但它们也具备补充深度学习的优势：所需数据量更少、表征方式更简洁，并能针对多目标逆向设计任务采用多目标优化算法。下文将探讨生成式AI在不同类型无机化合物中的应用发展历程（图2）。

表2.无机化合物生成式AI方法的精选表示方法。

代表；形象；象征	格式化	连接。	异构现象	3D geom.	周期的	Mol /材料	DL/GA
SMILES ^b	细绳	是	Partial ^c	不	不	Mol	都
SELFIES ^b	细绳	是	Partial ^c	不	不	Mol	都
切片；薄层	细绳	是	是	是	是	母亲	都
令牌	细绳	是	是	是	是	都	DL
图表 ^d	图	是	可选 ^e	可选 ^e	是	都	都
3D网格 ^f	点网格	不	是	是	是	母亲	DL
Voxels ^f	立方网格	不	是	是	是	母亲	DL
点云	Coordinates ^g	不	是	是	是	都	DL
维克夫位置 ^f	对称点	不	是	是	是	母亲	DL
染色体	基因	是	Partial ^c	不	不	都	GA

^a数学上：向量（字符串和基因）、矩阵（坐标和对称点）或张量（图结构和三维网格）；^b对无机化合物的支持有限；^c不包含旋转构象异构体；^d难以从三维几何结构构建；^e可通过节点与边的属性设定纳入；^f可利用欧几里得不变性；^g可被纳入要么是笛卡尔型（分子），要么是分数型（晶体）。




图2.针对无机化合物（包括过渡金属配合物（TMCs）、非多孔晶体、金属有机框架（MOFs）和沸石）的选定生成式AI方法时间线，涵盖遗传算法（GAs）、生成对抗网络（GANs）、变分自编码器（VAEs）、扩散模型（DMs）以及大型语言模型（LLMs）。

术语表

CIF文件。该晶体学信息文件包含晶体学数据，包括分数坐标、晶格参数、空间群及热力学参数。

条件生成。一种生成任务，其中深度学习模型的输出被调整以满足一个或多个目标属性的设定值。

凸包。组成与形成能/原子关系图。凸包上方的能量常被用作界定无机材料稳定性与亚稳态之间的分界线。

晶体结构预测 (CSP)。一种逆向设计任务，旨在生成在成分和对称性约束条件下使系统能量最小化的晶体结构。

深度学习 (DL)。一种利用多层神经网络来学习 $X \rightarrow y$ (预测) 或 $X \leftarrow y$ (逆向设计) 映射关系的人工智能方法。 X 表示具有目标性质 y 的给定化合物的机器可读表征。

密度泛函理论 (DFT)。作为计算无机化学领域的核心方法，它将电子密度定义为原子核与电子坐标的空间函数，从而在计算精度与计算成本之间取得平衡。

判别式人工智能。 $X \rightarrow y$ 分类与回归机器学习方法，该方法通过化合物的组成与结构 (X) 表示来预测其性质 (y)。

欧几里得不变性。当将E(3)群（旋转、平移和反射）应用于分子或材料时，其物理性质（包括用于逆向设计的性质）可能发生变化（变体）、保持不变（不变性）或相应改变（等变性）。

进化计算 (EC)。一种通过优化实现逆向设计的生成式人工智能方法论。该方法借鉴生物进化原理（如遗传算法）开发算法，用于生成具有最优性能参数的化学化合物。

适应度函数。在遗传算法中，用于优化（通常为最大化）以驱动进化过程的函数。根据其用于单目标优化还是多目标优化，该函数可涉及一个或多个目标属性。

生成式AI。 $X \leftarrow y$ 是一种机器学习方法，能够无条件（不带明确偏置）或有条件地（偏向目标属性 y ）生成化合物 X 。

大正则蒙特卡洛方法 (GCMC)。一种随机抽样技术，用于在恒定温度、体积和化学势条件下探索化学系统的构型空间。

图神经网络 (GNN)。一种利用化学与物理信息的神经网络，其架构能够反映分子或晶体图的拓扑结构。这些信息通过消息传递机制获取——图中的节点（原子）通过边（键）相互交换信

息。现代模型能高效利用欧几里得不变性。

高通量虚拟筛选。该筛选技术通过根据计算特性设定的阈值或范围对化合物进行筛选，从而探索庞大的明确化学空间。

逆向设计。一种从性质目标出发推导化学化合物的设计方法。**潜在空间。**深度学习模型所学习到的内部表征。

损失函数。一种可微函数，用于量化模型生成结果与训练数据中已知的真实值之间的偏差。人工智能模型通过最小化该函数来训练（即优化）。

金属有机框架（MOF）。一种结晶性微孔材料，其金属节点通过有机连接基团相连，形成具有特定拓扑结构的孔隙网络。

多目标优化。通过优化多个目标属性至最大或最小值来解决逆向设计任务。

神经网络。一种数学模型，它通过一系列交替执行线性与非线性运算的操作步骤，结合概率论与优化理论。神经网络利用权重、偏置等参数来预测化合物的性质或表征，这些参数通过学习（即优化）过程以最小化损失函数。

帕累托前沿。在多目标优化中，指生成的化合物集合中至少包含一种相对于所有其他化合物均为最优（最小或最大）的特性。

钙钛矿。由立方晶格结构定义的晶体材料，其通式为 ABX_3 ，其中大尺寸(A)和小尺寸(B)阳离子被阴离子(X)所包围。

SUN指标。稳定性、唯一性和新颖性（SUN）指标可部分评估人工智能模型在分子及材料生成方面的质量。

过渡金属配合物（TMC）。一种无机化合物，其中一个或少数金属原子与配体结合，这些配体可为有机、无机或有机金属类。

无条件生成。一种生成任务，其中深度学习模型的输出在所学分布范围内无任何偏见地生成。

XYZ文件。一种采用文本格式的文件，包含原子序数和笛卡尔坐标，用于定义分子的化学组成及三维几何结构。

沸石。由 SiO_4 与 AlO_4 四面体通过角共享形成的结晶微孔材料。

过渡金属配合物

虽然化学领域的生成式人工智能主要聚焦于小分子有机化合物^{77,103}及药物研发^{104,105}，但人们对分子无机化合物（尤其是过渡金属配合物TMCs）^{106,107}的兴趣日益增长，这源于它们在催化、医学及可再生能源领域的应用价值。这些化合物复杂的化学结构要求对小分子研究方法进行调整，这一挑战深刻塑造了该领域的发展方向。此类调整需应对多种氧化态、不同电荷与自旋多重性、高价态（涉及不同的配位数与几何构型）及其相互作用等问题。尽管生成对抗网络（GAs）在TMC逆向设计领域拥有最悠久的历史研究传统，但近年来基于深度学习（DL）的方法（包括VAE、LLM和DM模型）也取得了显著进展（见框1、图2）。

构成任何TMC（图1a）的金属基团与配体模块共同构成了一个模块化框架，非常适合基因算法的应用（图3a）。在逆向设计过程中，可固定金属中心的配位数和几何构型，同时对配体化学空间进行探索——既可通过配体片段进行局部探索，也可通过完整配体进行全局探索。全局方法通过tmQMg-L等预定义配体库实现¹⁰⁸；该库已用于探索庞大的化学空间：以包含252种配体（仅占tmQMg-L总量的0.7%）为例，[PdL₄]骨架结构的组合组合可生成10.1亿种独特的TMC。全局基因算法能高效探索这些空间，并通过分析演化过程实现便捷解读。然而，依赖固定配体库会限制所生成TMC的新颖性。尽管如此，这仍是文献中最为广泛采用的研究方法之一。已报道的应用实例包括：优化用于共聚反应的茂金属催化剂¹⁰⁹、适用于催化氧化过程的自旋交叉型催化剂¹¹⁰及金属氧杂三元金属配合物（TMCs）¹¹¹，以及用于可持续光捕获的广谱水溶性发色团¹¹²。除这些具体应用外，仍需开发能够普遍支持所有可能金属-配体配位模式的通用基因算法（GAs）。

在局部遗传算法中，配体是通过从预定义片段动态组合而成的。这些片段的结构与多样性决定了配体在优化过程中的演变方式——该过程既能提升创新性，又需要引入诸如设定尺寸限制等约束规则。在Chu及其团队的开创性研究中¹¹³，过渡金属催化中心（TMC）被建模为由静态部分和动态部分组成的图结构：静态部分代表金属中心及其周围环境，动态部分则包含被预定义片段占据的取代位点。由于这些片段可能含有更多取代位点，结构演化过程可形成分支以探索多种构型。通过引入受控突变和交叉操作，研究人员能够通过对第一代催化剂进行演化，重新发现用于烯烃复分解反应的第二代Grubbs催化剂，并用卡宾取代原有的膦配体。近年来，Nav-iCatGA软件包进一步推广了这一方法，并在其他应用领域取得显著成效，例如成功演化出用于芳基醚C-O键断裂反应的镍基TMC催化剂。¹¹⁴字符串表示法¹¹⁵可用于简化调控约束的实现过程，将每个配体视为独立分子，并基于结合能定义金属锚点。¹¹⁶⁻¹¹⁸随后可采用Jensen图形式化方法实现子代生成¹¹⁹，其中遗传操作可通过图编辑和子图交换运算便捷实现。该方法在氮固定催化剂的逆向设计^{116,117}以及Miyaura-Suzuki交叉偶联反应中均取得成功¹¹⁸。更稳健的字符串表示法（如自拍式字符串¹²⁰）在此背景下也展现出优势：利用首字符编码金属结合信息，并通过子字符串层面的遗传算法演化TMC分子磁体¹²¹。




图3.针对过渡金属催化剂（TMCs）的精选生成式AI方法。**a)**在帕累托前沿问题中运用遗传运算、适应度优化与选择机制的遗传算法；**b)**用于帕累托前沿选定区域方向性多目标优化的PL-MOGA 遗传算法；**c)**通过压缩潜在空间表示实现金属配体的 VAE 编码与解码；**d)**CatDRX VAE 同时编码过渡金属催化剂及其反应条件，用于新型催化剂的逆向设计。

为抑制向复杂配体发展的趋势，可将合成可及性评分^{122,123}作为额外目标纳入考量，并利用遗传算法的多目标优化能力¹¹⁶⁻¹¹⁸。这可通过采用由多个指数项组成的聚合适度函数来实现，每个指数项对应不同的目标指标（例如金属氧杂三甲基碳化合物的稳定性和HOMO能量）¹¹¹。该方法还可用于将进化过程约束在化学空间的特定区域^{106,110}，但存在一个关键局限：需要定义合理的归一化因子以平衡不同目标的优化效果。帕累托前沿优化法通过将适应度视为一组独立的目标函数来解决此问题——仅保留非劣化的三甲基碳化合物（即在所有目标中均未被其他化合物超越的化合物），从而实现均衡优化。PL-MOGA 算法为TMCs实现了这一方法，¹⁰⁸并增加了将

多目标优化导向帕累托前沿中用户自定义特定区域的功能（图3b）。除了适应度函数的构建外，遗传算法还需要利用molSimplify¹²⁴或Architector¹²⁵等工具自动组装TMC几何结构，随后进行优化及性质计算，通常需采用DFT等量子化学方法。此外，对于柔性配体和通式金属中心，还应考虑构象搜索。¹¹⁶⁻¹¹⁸通过使用图自相关性等定制特征表示TMCs，^{126,127}可利用DFT机器学习替代指标以较低计算成本评估适应度。^{106,110,111,121}从更广泛的角度来看，EC与DL方法之间的协同效应前景广阔¹²⁸，但目前仍鲜有研究深入探讨。诸如g-xTB¹²⁹这类半经验方法，其精度已接近密度泛函理论（DFT）水平，也将很快通过加速适应度评估而发挥关键作用。

除了生成对抗网络（GAs）之外，最早尝试将深度学习应用于过渡态催化剂（TMCs）的研究之一是TS-GAN¹³⁰——该模型能够根据反应物和产物的简单表示来生成催化反应中的过渡态几何结构。然而，作为最早出现的深度学习方法之一，GAN在处理TMC复杂性时存在局限性，因此研究领域迅速转向学习更平滑潜在空间的方法，其中就包括变分自编码器（VAEs）（图3c）。JT-VAE方法¹³¹尤其适用于TMCs研究，因为它通过连接树（JT）形式化框架促进复杂结构的生成——该框架将分子图粗粒化为包含键和环的簇组。JT-VAE模型可用于TMCs的逆向设计，并可根据场强调配体生成¹³²。为优化生成过程，模型的潜在空间通过神经网络进行结构化建模，以预测目标属性（例如氧化加成反应能量），从而实现交叉偶联催化剂的逆向设计。¹³³在这些应用中，微笑结构¹¹⁵或自拍序列¹²⁰既可以单独使用¹³²来表示单个配体，也可以聚合使用¹³³来表示完整的金属-配体复合物（TMC）。通过在微笑结构语法中使用断裂标记符，无需明确定义金属-配体键即可获得聚合表示。尽管这种方法操作简便，但若配体包含多个结合基团则易产生歧义。Strandgaard及其团队通过开发一种支持含齿状或触状配体的TMC中金属锚点的微笑结构编码方案解决了这一问题¹³⁴。由此产生的JT-VAE模型能够完成具有高新颖性、有效性和唯一性的生成任务（框2），这些任务可分别或联合基于多种属性进行条件设定，包括TMC金属电荷与HOMO-LUMO能隙、配体体积大小及溶解度等。对于催化领域中更为复杂的逆向设计，CatDRX VAE模型¹³⁵（图3d）能够学习一个潜在空间，该空间不仅编码催化剂信息，还包含反应物及反应条件（如添加剂、溶剂和时间），并支持使用通用数据集对模型进行预训练以提升效率与可持续性。CatDRX模型已在有机催化反应和金属催化反应（包括C-C交叉偶联反应）中展现出优异性能。尽管已取得显著进展，VAE模型仍无法完全支持全TMC结构的生成；不过近期关于字符串表示方法的研究有望很快解决这一问题。^{136,137}

为应对使用字符串和图结构表示TMCs的挑战，并顺应生成三维结构的需求（这类结构在不对称催化等应用中具有重要价值），DMs正逐渐成为VAEs的强大替代方案。例如，LigandDiff DM模型¹³⁸可通过将特定配位点上的配体生成条件设定为依赖于所有其他固定配体来实现TMCs的多样化构建，这在催化剂和光敏剂等体系中尤为适用——其中特定配体起主导作用，而其他配体则作为辅助角色。LigandDiff将TMCs编码为原子序数与位置构成的点云，并将每个原子与其配体

关联起来以简化去噪过程。¹³⁸在扩展对单齿配体的原始实现后，LigandDiff现已支持更高齿数阶次的生成条件设定，并可处理单个或多个配体。¹³⁹而在OM-Diff DM模型¹⁴⁰中，几何结构生成与性质条件设定均在整体TMC层面完成。除了为交叉偶联反应生成催化剂外，OM-Diff还能利用E(3)等变性¹⁴¹在成分和几何构型约束条件下生成过渡态¹⁴²——这一点已在瓦斯卡配合物周围化学空间中H₂活化反应中得到验证¹⁴³。尽管面临高昂计算成本的挑战，且距离涵盖定义过渡金属催化中心空间的诸多变量仍有较大差距，但密度矩阵方法仍是当前研究领域中的一个活跃且尚处于起步阶段的研究方向。

大型语言模型（LLM）所蕴含的广泛化学知识同样可有效应用于过渡金属催化剂（TMCs）的逆向设计。例如，在自主化学实验室自动化应用领域，基于GPT的CoScientist模型可通过迭代反馈循环辅助优化催化交叉偶联反应¹⁴⁴。¹⁴⁵在针对Suzuki-Miyaura反应和Buchwald-Hartwig反应的实验数据集上测试时，CoScientist不仅超越了标准贝叶斯优化方法，还为其推荐方案提供了化学原理支持。这一范式在LLM-EO模型¹⁴⁶中得到进一步拓展：该模型利用遗传算法生成过渡金属催化剂，并同时优化其HOMO- LUMO 能隙与极化率这两个目标参数，充分展现了深度学习与化学工程相结合方法的潜力¹²⁸。

选择用于TMC逆向设计的生成模型时，应综合考虑其本质特性及数据可获取性。变分自编码器（VAE）和深度马尔可夫模型（DM）非常适合进行广泛探索，但需要庞大的训练数据集；其中深度马尔可夫模型在配体齿数、金属中心配位数及几何结构方面具有极高的灵活性，而变分自编码器则更易于训练。尽管两种模型均支持条件生成，但所需训练数据通常难以获取或成本过高。相比之下，生成对抗网络（GAN）特别适用于数据匮乏场景，能实现高效的多目标优化；大型语言模型（LLM）虽较为稀缺，最适合用于探索性研究，但其应用范围可扩展至化学家-机器交互界面领域。所有方法在催化等复杂应用场景中均已展现出潜力，不过实验验证仍较为有限。

非多孔无机晶体

除了分子TMC的逆向设计外，生成式人工智能还被应用于探索涵盖非多孔无机晶体的广阔化学空间。¹⁴⁷除钙钛矿材料外¹⁴⁸⁻¹⁵²，还包括二维材料¹⁵³、催化金属表面^{73,154,155}、纳米颗粒¹⁵⁶⁻¹⁵⁸、电池材料^{159,160}、合金^{161,162}以及金属氧化物¹⁶³。但超越定制化模型之外，学界对能将逆向设计范围推广至任何紧凑型非多孔晶体材料的模型也表现出浓厚兴趣（图1b）。^{78,164-166}除了化学有效性与欧几里得不变性（这些特性在分子TMCs中已至关重要）外，无机晶体还存在另一项复杂因素：其结构周期性固有的几何约束条件以及230种可能空间群的对称性。生成式AI应对这些挑战的方式及程度，是选择最适宜方法的关键标准，并决定了该领域如何从遗传算法发展到深度学习模型，再经由生成对抗网络、变分自编码器，直至近期的大型语言模型（见框1、图2）。

与TMCs的逆向设计类似，遗传算法（GA）定义了一个稳健的基准，现代深度学习模型可据此进行性能评估，同时该算法也被用于自动化生成训练数据。^{163,167}在确定化学组成后，可设计遗传算法的适应度函数以寻找能最小化能量的结构。由此，遗传算法实现了晶体结构预测（CSP）的目标¹⁶⁸——这也是早期某些深度学习方法的核心目标¹⁶⁹。受学界对CSP研究兴趣的推动，多个研究团队开发了用于将遗传算法应用于无机晶体的软件平台，包括calypso¹⁷⁰、USPEX¹⁷¹和XtalOpt¹⁷²等程序。其中USPEX和XtalOpt基于可处理多目标问题的遗传算法优化器，而calypso则采用不同的EC算法（粒子群优化算法）¹⁷³；其他差异还包括化学组成与结构如何根据不同的化学计量比和对称性进行定义与变化。除了CSP之外，遗传算法及其他EC算法还能够根据多种特性生成晶体化合物¹⁷⁴，例如钛氧化物的带隙¹⁷⁵以及磁性材料的状态密度¹⁷⁶。此外，人们对混合深度学习/EC方法及其应用的兴趣日益增长，例如在VQCrystal模型中利用遗传算法探索VAE潜在空间¹⁷⁷以优化带隙和形成能，以及逆向设计用于CO₂还原的电催化剂¹⁵⁵。

在生成对抗网络（GAN）及其他进化计算方法中，晶体的周期性几何结构与对称性是其表征的重要组成部分，并且能够以精确、确定性的方式保持或修改。这与通常基于密度泛函理论（DFT）水平进行的适应度第一性原理计算相一致，这也正是该方法的主要缺点：计算成本高昂。另一个问题是这些算法需满足成分与结构约束条件，从而限制了所生成化合物的多样性。这些局限性推动了用于无机晶体逆向设计的深度学习方法的发展，其中生成对抗网络（GAN）属于较早的研究尝试之一。典型代表包括CrystalGAN¹⁷⁸、MatGAN¹⁷⁹、DCGAN¹⁶²、CubicGAN¹⁸⁰以及PGCGM¹⁸¹。GAN及所有其他深度学习方法的一个共同特征是需要使用超大规模数据集；例如，MatGAN和CubicGAN均基于从OQMD和MP数据集等来源提取的超过35万种结晶材料进行训练。这些模型在用于捕捉几何结构与对称性的表示方式上也存在差异，从简单的二维晶体图到编码丰富晶体学信息的复杂张量不等。最新的PGCGM GAN模型通过引入对称性约束，显著提升了生成晶体的物理合理性。¹⁸¹在应用层面，CubicGAN能够根据结构特性生成新颖的晶体结构：例如ABC₆D₆和AB₈C₁₂分别针对空间群216和221进行了逆向设计。¹⁸⁰尽管运行GAN模型无需进行密度泛函理论（DFT）计算，但该方法仍被广泛应用于模型评估及训练数据的生成。

致谢

D.B.感谢RCN FRIPRO 计划提供的开创性研究支持（CATLEGOS项目；编号325003）。L.M.-G.感谢欧盟委员会通过HE- MSCA -PF计划提供的资助（BiFUCCO2基金；编号101206288）。N.K.感谢欧洲研究理事会（ERC）在欧盟“地平线2020”计划框架下提供的经费支持（CuBE基金；编号856446）。所有作者均感谢RCN国家卓越中心计划对Hylleraas中心（项目编号262695）的支持。

作者贡献

H.K.、L.M.G.、N.K.、A.N.和D.B.均参与了科学讨论以及稿件的审阅与编辑工作；H.K.、L.M.G.、N.K.和D.B.共同参与了稿件数据的研究与撰写；D.B.负责提出了综述的整体框架设计。

竞争性利益

作者声明无利益冲突。